

اسأل قبل أن يتصرّف

وكلاء الذكاء الاصطناعي، المرحلة الإعدادية، الدرس ٣

في هذا الدرس سوف

- تصنّف الأفعال: القراءة فقط، اسأل أولًا، مسموح، أبدًا.
- تقرأ الفعل بالضبط قبل أن توافق.
- تكتب فحصًا بلغة Python لا يرسل إلا بعد الموافقة.

الأفكار الأساسية

- القراءة خطرها قليل، والتصرّف يحتاج إلى موافقتك.
- سؤال النموذج سلوك متعلَّم، وقد يفشل.
- يتحقّق التطبيق من الموافقة في الكود، ويحتفظ بسجلّ.

تصنيف الأذونات

١. التمهيد (٣ دقائق): اذكر فعلًا لا يمكن التراجع عنه أبدًا.

٢. التصنيف (٧ دقائق): اثنتا عشرة بطاقة وأربع لافتات.

٣. النقاش (٦ دقائق): اتفقوا على أصعب ثلاث بطاقات.

٤. الكود (٤ دقائق): تتبّع فحص الموافقة على الورق.

اكتب بطاقات الأفعال قبل أن تبدأ. واستعمل أسماء خيالية فقط، ولا تستعمل أبدًا رسالة أو صورة لشخص حقيقي.

لنتناقش

١. ما الأفعال التي لن تسمح لوكيل بفعلها أبدًا، حتى مع موافقتك؟

٢. لماذا لا يكفي سؤال النموذج المؤدّب؟

٣. ماذا يجب أن يُظهر سجلّ الأفعال في التطبيق؟

بطاقة الخروج

- اكتب فعلًا واحدًا لكل مستوى: القراءة فقط، اسأل أولًا، مسموح، أبدًا.