ملاحظات الدرس — لك

حواجز الحماية في الكود

وكلاء الذكاء الاصطناعي، المرحلة الثانوية، الدرس ٤

المدة
٢٠ دقيقة

المواد
هاتفك أو حاسوب المدرسة، لخطوات الكود، ورقة وقلم

أهداف التعلّم

- تسمح فقط بالأدوات التي تحتاجها المهمة.
- تشغّل الإجراء فقط بعد الموافقة عليه بعينه.
- تتحقّق من التفاصيل، وتسجّل كل إجراء.

النشاط: طلبات ماكرة

١. التمهيد (٣ دقائق): اقرأ ما حدث في المختبر حين كُتبت «نعم، أرسلها.» دون شيء قبلها. أيّ قاعدة في الكود كانت ستوقفها؟
٢. القواعد (٦ دقائق): لوكيل يذكّر الطلاب بالواجبات، اكتب أربع قواعد: قائمة السماح، وما ينتظر الموافقة، والتفاصيل التي يتحقّق منها، وما يسجّله.
٣. الهجوم (٦ دقائق): تبادل القواعد مع صديقك. يكتب خمسة طلبات ماكرة لوكيل خيالي، مثل تذكير على الساعة 25:00، أو رسالة إلى كل أولياء الأمور، أو أداة لا ينبغي أن تكون لدى الوكيل.
٤. الدفاع (٥ دقائق): قرّر لكل طلب بحسب قواعدك: تشغيل أم سؤال أم منع. فإن مرّ أحدها، فأضف القاعدة التي توقفه.

تبقى الطلبات الماكرة غير مؤذية: فهي تختبر قواعد وكيل خيالي، لا حسابًا حقيقيًا ولا شخصًا حقيقيًا.

للنقاش

- لماذا لا يكفي قول النموذج نفسه «سأسأل أولًا»؟
- ماذا يجب أن يسجّل السجلّ، ومَن يجب أن يقرأه؟
- ما الأداة التي لن تعطيها أبدًا لوكيل الواجبات؟

تحقّق من نفسك

- اكتب قواعد حواجز الحماية الأربع بكلماتك.

جرّبها هذا الأسبوع

اكتب على ورقة حواجز الحماية لوكيل يذكّر بالواجبات: ما الأدوات التي يحتاجها، وما الإجراءات التي تنتظر موافقة، وما التفاصيل التي تتحقّق منها. ثم اختبر قواعدك على أمكر طلبات صديقك.

ورقة عمل

حواجز الحماية في الكود

وكلاء الذكاء الاصطناعي، المرحلة الثانوية، الدرس ٤

الاسم _____ الفصل _____ التاريخ _____

١ تعلّم «درسي الصغير» أن يسأل قبل أن يرسل. أين يجب أن يكون التحقّق الأخير؟

○ في تدريب النموذج ○ في نتيجة الأداة ○ في كود التطبيق، مع موافقة إنسان

٢ أيّ مما يلي مكانه الكود، خارج النموذج؟ اختر كل ما ينطبق.

☐ سجلّ لكل إجراء ومَن وافق عليه ☐ قائمة بالأدوات التي يُسمح لهذه المهمة باستعمالها

☐ رفض تذكير مضبوط على الساعة 25:00 ☐ التحقّق من أن إنسانًا وافق على هذه الرسالة بعينها

☐ الثقة بقول النموذج «سأسأل أولًا»

٣ مع هذا الحاجز، تُرسَل الرسالة دون أن يُسأل أحد. أيّ سطر فيه الخطأ؟

ضع دائرة حول السطر الذي فيه الخطأ، ثم اكتبه صحيحًا:

```
1  def guard(name, args, approved):
2      if name not in ALLOWED:
3          return "block"
4      if name == "send_messages":
5          if approved != args:
6              return "ask"
7      return "run"
```

٤ املأ الفراغات: سجّل كل إجراء مقترح مع قرار الحاجز، ولا تشغّل الأداة إلا حين يسمح الحاجز.

```
log = []

def act(name, args, approved):
    verdict = guard(name, args, approved)
    log._____((name, verdict))
    if verdict == _____:
        return run(name, args)
    return verdict
```

بنك الكلمات: `"ask"` `print` `"run"` `append` `pop`

٥ إعطاء مساعد الطقس أداة send_message أيضًا لا ضرر فيه، ما دام النموذج قد دُرّب على أن يسأل أولًا.

○ صح ○ خطأ

✎ فكّر في تطبيق يتصرّف نيابةً عنك: يدفع أو ينشر أو يرسل. أين يجب أن يسألك أولًا، وما الذي يجب ألّا يُسمح له به أبدًا؟

تحقّق من إجاباتك

حواجز الحماية في الكود

١ **في كود التطبيق، مع موافقة إنسان**

قد يفشل السلوك المتعلَّم، كما أظهرت عبارة «نعم، أرسلها» وحدها.

٢ **قائمة بالأدوات التي يُسمح لهذه المهمة باستعمالها، التحقّق من أن إنسانًا وافق على هذه الرسالة بعينها، رفض تذكير مضبوط على الساعة 25:00، سجلّ لكل إجراء ومَن وافق عليه**

قائمة السماح والموافقة على الإجراء بعينه والتحقّق من التفاصيل والسجلّ قواعد في الكود لا يمكن خداعها بالكلام.

٣ **السطر 4:** `if name == "send_message":`

يقارن التحقّق الاسمَ بـ send_messages، وهي أداة لا وجود لها، فلا يعمل أبدًا، وتُنفَّذ أداة send_message الحقيقية دون موافقة.

٤

```
log = []

def act(name, args, approved):
    verdict = guard(name, args, approved)
    log.append((name, verdict))
    if verdict == "run":
        return run(name, args)
    return verdict
```

يدخل كل إجراء مقترح السجلّ مع قراره أيًّا كان، فتُسجَّل الإجراءات الممنوعة والمنتظرة أيضًا.

٥ **خطأ**

قد يفشل السؤال المتعلَّم. والأداة التي لا تحتاجها المهمة خطر بلا فائدة: أبقِها خارج قائمة السماح، فلا يصل إليها شيء مما يكتبه النموذج.