حواجز الحماية في الكود

وكلاء الذكاء الاصطناعي، المرحلة الثانوية، الدرس ٤

في هذا الدرس سوف

- تسمح فقط بالأدوات التي تحتاجها المهمة.
- تشغّل الإجراء فقط بعد الموافقة عليه بعينه.
- تتحقّق من التفاصيل، وتسجّل كل إجراء.

الأفكار الأساسية

- الأمان المتعلَّم قد يفشل، ومكان حاجز الحماية هو الكود.
- قائمة السماح، والموافقة على الإجراء بعينه، والتحقّق من التفاصيل، والسجلّ.
- النموذج يقترح، وكودك والإنسان يقرّران.

النشاط: طلبات ماكرة

١. التمهيد (٣ دقائق): لماذا مرّت «نعم، أرسلها.» وحدها؟

٢. القواعد (٦ دقائق): اكتب أربعة حواجز حماية لوكيل تذكير.

٣. الهجوم (٦ دقائق): يكتب صديقك خمسة طلبات ماكرة.

٤. الدفاع (٥ دقائق): تشغيل أم سؤال أم منع، لكل طلب.

تبقى الطلبات الماكرة غير مؤذية: فهي تختبر قواعد وكيل خيالي، لا حسابًا حقيقيًا ولا شخصًا حقيقيًا.

لنتناقش

١. لماذا لا يكفي قول النموذج نفسه «سأسأل أولًا»؟

٢. ماذا يجب أن يسجّل السجلّ، ومَن يجب أن يقرأه؟

٣. ما الأداة التي لن تعطيها أبدًا لوكيل الواجبات؟

بطاقة الخروج

- اكتب قواعد حواجز الحماية الأربع بكلماتك.