ملاحظات الدرس — لك

عدّة وكلاء لمهمة واحدة

وكلاء الذكاء الاصطناعي، الجامعة، الدرس ٢

المدة
٢٠ دقيقة

المواد
بطاقات ورقية وقلم، قائمة بقواعد المدقّق الخمس، مطبوعة أو منسوخة باليد، هاتفك، للمختبر

أهداف التعلّم

- تقسيم الوكيل إلى مخطّط ومدقِّق ومنفِّذ وإنسان.
- كتابة قواعد صارمة توقف الاستدعاء الخاطئ قبل تنفيذه.
- موازنة كلفة الأدوار الإضافية: التوكنز وتضاعف الأخطاء.

النشاط: مخطّط ومدقِّق

١. التحضير (٣ دقائق): كوّنوا مجموعات من ثلاثة. يأخذ المخطّط بطاقات وقلمًا، ويأخذ المدقّق قائمة القواعد الخمس، ويحمل المنفِّذ جدولًا خياليًا وقائمة بالطقس.

٢. اللعب (١٠ دقائق): تكتب مجموعة أخرى طلبًا على بطاقة. يكتب المخطّط له استدعاء أداة على بطاقة جديدة. ويختبر المدقّق الاستدعاء بالقواعد الخمس، فإما أن يمرّره إلى المنفِّذ وإما أن يوقفه مع اسم القاعدة. ولا يجيب المنفِّذ إلا عن الاستدعاءات التي مرّت.

٣. التبديل (٥ دقائق): بدّلوا الأدوار. يحاول المخطّط الجديد تمرير خطأ من المدقّق: اسمًا منسوخًا خطأً، أو وقتًا مثل 25:00، أو خطوة بعد فشل، أو فعلًا دون موافقة.

٤. النقاش (دقيقتان): شاركوا أيّ خطأ مرّ، وأيّ قاعدة تضيفونها لالتقاطه.

اكتبوا القواعد الخمس بخط كبير يقرؤه المدقّق بنظرة واحدة. واستعملوا أسماء وفصولًا خيالية فقط.

للنقاش

- ما الأخطاء التي لا تستطيع القواعد الصارمة التقاطها أبدًا؟
- متى يستحق نموذج ثانٍ كلفته مدقِّقًا؟
- لماذا يجب أن يعود الاستدعاء الموقوف إلى إنسان بدل إعادة محاولة صامتة؟

تحقّق من نفسك

- اكتب قاعدة واحدة للمدقِّق بلغة Python أو بكود وصفي، وخطأ واحدًا ستوقفه.

جرّبها هذا الأسبوع

اختر مهمة تحب أن يؤدّيها وكيل، كحجز قاعة للمذاكرة. ارسم أدوارها واكتب خمس قواعد صارمة للمدقِّق، ثم اخترع خطأً واحدًا ستفوّته قواعدك رغم ذلك.

ورقة عمل

عدّة وكلاء لمهمة واحدة

وكلاء الذكاء الاصطناعي، الجامعة، الدرس ٢

الاسم | الفصل | التاريخ

١ **ينفّذ وكيل ثلاث خطوات، كلٌّ منها صحيحة في ٩٠٪ من المرات. كم مرة تكون الخطوات الثلاث كلها صحيحة؟**

○ نحو ٢٧٪ ○ نحو ٩٠٪ ○ نحو ٧٣٪

٢ **اكتب مدقِّقًا بثلاث قواعد. الاستدعاء قاموس مثل {"tool": "weather", "args": {"place": "Kafi"}}. تعيد check(call, text, on, failed) قائمة بالقواعد التي يخالفها الاستدعاء: "tool" إن لم تكن call["tool"] في on، و"said" إن كانت أي كلمة في قيم call["args"] غير موجودة في text (الطلب والنتائج) عند البحث بـ in، و"after" إن كانت failed صحيحة (True). والقائمة الفارغة تعني أن الاستدعاء يمكن أن يُنفَّذ. (لا نموذج هنا: الاستدعاءات معطاة.)**

```
def check(call, text, on, failed):
    broken = []
    return broken
```

اكتب برنامجك:

٣ **رتّب خطوات الفريق: يقترح المخطّط، ويراجع المدقّق، ولا يُنفَّذ الاستدعاء إلا إن لم تُخالَف أي قاعدة.**

رقّم الأسطر بالترتيب (١، ٢، ٣...)، وارسم أمام السطر سهمًا → عن كل إزاحة يحتاج إليها. اشطب أي سطر لا ينتمي إلى البرنامج.

- ☐ `broken = check(call, text, ON, failed)`
- ☐ `if broken:`
- ☐ `result = run(request)`
- ☐ `call = planner(request)`
- ☐ `print("Stopped:", broken)`
- ☐ `else:`
- ☐ `result = run(call)`

٤ **لماذا نبدأ بقواعد صارمة في الكود مدقِّقًا، بدل نموذج لغوي ثانٍ؟ اختر كل ما ينطبق.**

☐ القواعد رخيصة وسريعة في كل خطوة ☐ قد يُخدع النموذج المدقّق بالطريقة نفسها التي يُخدع بها المخطّط

☐ القواعد لا تخمّن أبدًا، ولا يمكن إقناعها بالعدول ☐ القواعد تلتقط كل خطأ ممكن

☐ القواعد تفهم النبرة والمعنى أفضل من النموذج

٥ **يجب أن يكون المدقّق نموذج ذكاء اصطناعي منفصلًا.**

○ صح ○ خطأ

فكّر في مهمة يكون لخطأ واحد فيها أثر كبير، كمراسلة فصل كامل. أيّ دور تأتمن عليه نموذجًا، وأيّ دور تُبقيه كودًا أو إنسانًا؟

تحقّق من إجاباتك

عدّة وكلاء لمهمة واحدة

١ **نحو ٧٣٪**

لأن ٠٫٩ × ٠٫٩ × ٠٫٩ ≈ ٠٫٧٣. فاحتمالات الصواب تتضاعف بالضرب، ولذلك تحتاج السلاسل الطويلة إلى فحص في كل خطوة.

٢

```
def check(call, text, on, failed):
    broken = []
    if call["tool"] not in on:
        broken.append("tool")
    words = []
    for v in call["args"].values():
        words += str(v).split()
    if any(w not in text for w in words):
        broken.append("said")
    if failed:
        broken.append("after")
    return broken
```

كل قاعدة اختبار بسيط لا يخمّن أبدًا: هل الأداة مسموحة، وهل جاءت كل كلمة من مكان ما، وهل فشلت خطوة سابقة؟

٣ **من الأعلى إلى الأسفل: ٢، ٣، ✗، ١، ٤، ٥، ٦**

```
call = planner(request)
broken = check(call, text, ON, failed)
if broken:
    print("Stopped:", broken)
else:
    result = run(call)
```

المخطّط يقترح فقط، والمدقّق يعمل قبل أن يحدث أي شيء، والأداة تُشغَّل في فرع else، فلا يصلها استدعاء مخالف أبدًا.

٤ **القواعد لا تخمّن أبدًا، ولا يمكن إقناعها بالعدول، القواعد رخيصة وسريعة في كل خطوة، قد يُخدع النموذج المدقّق بالطريقة نفسها التي يُخدع بها المخطّط**

القواعد متوقَّعة ورخيصة ولا تنطلي عليها الحيل التي تخدع النماذج.

٥ **خطأ**

قد يكون المدقّق نموذجًا آخر، أو النموذج نفسه بتعليمات مختلفة، أو كودًا عاديًا.