قياس أداء الوكيل

المدة
٢٠ دقيقة

المواد
ورق وقلم، آلة حاسبة أو حاسبة الهاتف، هاتفك، للمختبر

أهداف التعلّم

- بناء مجموعة اختبار ثابتة فيها صيغ وأسماء محجوبة.
- التصحيح بتطابق تام، وتفصيل النتيجة حسب المجموعة.
- قول مدى اليقين في النتيجة بصدق، وإعادة الاختبار بعد التغييرات.

النشاط: اكتب امتحان الوكيل

١. الكتابة (٦ دقائق): في أزواج، اكتبا عشرة طلبات لوكيل جدول خيالي: خمسة بصيغ بسيطة («ما حصص 4A يوم الاثنين؟») وخمسة بصيغ غير مألوفة («الاثنين، 4A: ماذا هناك؟»).
٢. مفتاح الإجابة (٤ دقائق): على ورقة منفصلة، اكتبا الاستدعاء الدقيق الذي يجب أن يُنتجه كل طلب، بالأداة وكل تفصيل، قبل أن يمثّل أحد دور الوكيل.
٣. التبادل والتشغيل (٦ دقائق): تبادلا الطلبات مع زوج آخر. يمثّل أحدكما الوكيل ولا يستعمل إلا قائمة عبارات اتفقتما عليها مسبقًا، ويكتب الآخر كل استدعاء يكتبه الوكيل.
٤. التصحيح (٤ دقائق): صحّحا بمفتاح الإجابة، بالتطابق التام فقط، وأعطيا مجموعة الصيغ البسيطة ومجموعة الصيغ غير المألوفة نتيجتين منفصلتين. وناقشا ما الذي أخفق، وإلى أيّ حد تمنحكما عشرة طلبات يقينًا.

استعملوا فصولًا وأيامًا خيالية فقط. فقائمة العبارات الثابتة لـ«الوكيل» تجعل الصيغ غير المألوفة تُخفق، تمامًا كما يحدث مع نموذج صغير.

للنقاش

- لماذا يجب أن تُكتب الأجوبة قبل تشغيل الوكيل؟
- ماذا تحتاج كي تثق بنتيجة تكفي لاعتماد وكيل؟
- أيّ أدوات دراستك لم تُختبر قط بلغتك؟

تحقّق من نفسك

- شيء واحد يجب أن تضمه مجموعة الاختبار العادلة، ولماذا لا تعني ٢٩ من ٣٢ نسبة ٩١٪ بالضبط.

جرّبها هذا الأسبوع

اكتب عشرة طلبات اختبار لمساعد تستعمله، خمسة منها بصيغ غير مألوفة، واكتب الجواب الصحيح لكل طلب قبل أن تشغّلها. ثم صحّحها، ولاحظ أيّ مجموعة أخطأت أكثر.

ورقة عمل

قياس أداء الوكيل

وكلاء الذكاء الاصطناعي، الجامعة، الدرس ٣

الاسم _____ الفصل _____ التاريخ _____

١ مجموعة اختبار لا تضم إلا صيغًا تدرّب عليها النموذج، فحصل على ١٠٠٪. ماذا يُظهر ذلك؟

○ أنه يتذكّر ما تدرّب عليه ○ أنه آمن لتقديمه للمستخدمين ○ أنه يفهم أيّ صيغة

٢ كل حالة اختبار ثلاثية (group, want, got): مجموعتها، والاستدعاء المطلوب، والاستدعاء الذي كتبه الوكيل، في صورة قواميس. اكتب score(cases) لتعيد قاموسًا يعطي لكل مجموعة نسبة حالاتها التي يطابق فيها got المطلوبَ want تمامًا. (استدعاءات الوكيل معطاة: لا يعمل نموذج هنا.)

```
def score(cases):
    out = {}
    return out
```

اكتب برنامجك:

٣ ماذا يطبع هذا البرنامج؟

```
want = {"tool": "glossary",
    "args": {"term": "battery"}}
got = {"tool": "glossary",
    "args": {"term":
        "the term battery"}}
print(got["tool"] == want["tool"],
      got == want)
```

○ False False ○ True False ○ True True

٤ أيّ مما يلي مكانه في مجموعة اختبار جيدة لوكيل؟ اختر كل ما ينطبق.

☐ طلبات جديدة تمامًا في كل تشغيل، كي لا يحفظها الوكيل ☐ صيغ وأسماء محجوبة عن التدريب

☐ طلبات بكل لغة يكتب بها مستخدموه ☐ الجواب الصحيح لكل طلب، محدّدًا قبل التشغيل

☐ الطلبات التي أصاب فيها في المرة الماضية فقط

٥ رتّب خطوات التقييم الصادق.

☐ صحّح كل حالة بالطريقة الصارمة نفسها

☐ اجمع طلبات حقيقية، بصيغ جديدة وباللغتين

☐ أعد تشغيل المجموعة نفسها بعد كل تغيير

☐ اكتب الجواب الصحيح لكل طلب، قبل تشغيل أي شيء

☐ شغّل الوكيل على المجموعة كلها

☐ فصّل النتيجة واقرأ كل خطأ

✎ فكّر في أداة ذكاء اصطناعي تعتمد عليها أنت أو زملاؤك. ماذا تضم مجموعة اختبار عادلة لها، وما النتيجة التي تحتاجها قبل أن تأتمنها على أمر مهم؟

تحقّق من إجاباتك

قياس أداء الوكيل

وكلاء الذكاء الاصطناعي، الجامعة، الدرس ٣

١ أنه يتذكّر ما تدرّب عليه

الصيغ المدرَّب عليها تقيس الحفظ. ولا يُظهر قدرته على التعامل مع طلبات لم يرها إلا الصيغ والأسماء المحجوبة عن التدريب: ينخفض «درسي الصغير» فيها من ١٦/١٦ إلى ١٣/١٦.

٢

```
def score(cases):
    hits, total = {}, {}
    for g, want, got in cases:
        total[g] = total.get(g, 0) + 1
        if got == want:
            hits[g] = hits.get(g, 0) + 1
    out = {}
    for g in total:
        out[g] = hits.get(g, 0) / total[g]
    return out
```

التصحيح حسب المجموعة يُظهر أين يخطئ الوكيل، وهذا ما يخفيه رقم إجمالي واحد.

٣ True False

الأداتان متطابقتان (كلتاهما glossary)، فالمقارنة الأولى True، لكن التفاصيل مختلفة («the term battery» مقابل «battery»)، فالاستدعاءان غير متساويين.

٤ طلبات بكل لغة يكتب بها مستخدموه، صيغ وأسماء محجوبة عن التدريب، الجواب الصحيح لكل طلب، محدّدًا قبل التشغيل

غطِّ كل لغة، وضمّن صيغًا وأسماء محجوبة، وحدّد الأجوبة مسبقًا.

٥ من الأعلى إلى الأسفل: ٤، ١، ٦، ٢، ٣، ٥

تأتي الأجوبة قبل التشغيل كي لا تُطوّعها لتناسب النتائج، ويأتي التصحيح الصارم قبل قراءة الأخطاء، ثم يُعاد تشغيل المجموعة الثابتة بعد كل تغيير لالتقاط التراجع.