ملاحظات الدرس — لك

الضبط الدقيق وحواجز الحماية

وكلاء الذكاء الاصطناعي، الجامعة، الدرس ٤

المدة
٢٠ دقيقة

المواد
ورق وقلم، هاتفك مشحونًا أو موصولًا بالشاحن، للمختبر (قد يستغرق التدريب نحو ١١ دقيقة على هاتف قديم)

أهداف التعلّم

- قياس ما يعلّمه الضبط الدقيق وما يُنسيه للنموذج.
- شرح لماذا لا يكون الأمان المتعلَّم ضمانًا.
- تصميم حواجز حماية متعدّدة الطبقات في الكود: الأدوات، والموافقة، والفحوص، والسجلات، والاختبارات.

النشاط: طبقات الحماية

١. الاختيار (٣ دقائق): في أزواج، اختارا وكيلًا (مساعدًا لمجموعة مذاكرة، أو معينًا لنادٍ) وفعلًا خطِرًا واحدًا قد يقوم به، كمراسلة الجميع أو حجز قاعة.

٢. الطبقات (٧ دقائق): اكتبا خمسة حواجز على بطاقات منفصلة: أقل الأدوات، والموافقة على الفعل نفسه، وفحص التفاصيل، والسجل، وإعادة الاختبار بعد التغييرات. واكتبا تحت كل حاجز ما يمنعه.

٣. الهجوم (٧ دقائق): يصف زميلك فشلًا (النموذج يعيد صياغة طلب رفض، أو يختلق رسالة بعد «نعم»، أو ينسى بعد ضبط دقيق) ويزيل بطاقة واحدة في كل مرة. وقرّرا بعد كل إزالة: هل سيظل الفعل ممنوعًا؟

٤. النقاش (٣ دقائق): اتفقا على أهم حاجز، وعلى الفشل الذي لا تمنعه أي بطاقة وحدها.

استعملا وكلاء وأشخاصًا ورسائل خيالية فقط. وتكفي خمس بطاقات أو مربعات ورق ممزّقة.

للنقاش

- متى يستحق الضبط الدقيق عناءه، ومتى تكفي أداة جديدة أو تعليمات أوضح؟
- لماذا لا يكفي وعد النموذج بأن يسأل أولًا؟
- أيّ حاجز حماية لن تزيله أبدًا، ولماذا؟

تحقّق من نفسك

- شيء واحد قد يُنسيه الضبط الدقيق للنموذج، والحاجز في الكود الذي يظل يحميك.

جرّبها هذا الأسبوع

اكتب في صفحة واحدة خطة لحواجز الحماية في وكيلٍ تحب أن تبنيه: أقل الأدوات التي يحتاجها، والأفعال التي تحتاج إلى موافقة على الفعل نفسه، والفحوص في الكود، وما يسجّله، والاختبارات التي ستعيد تشغيلها بعد كل تغيير.

ورقة عمل

الضبط الدقيق وحواجز الحماية

وكلاء الذكاء الاصطناعي، الجامعة، الدرس ٤

الاسم | الفصل | التاريخ

١ تعلّم نموذج أن يسأل قبل أن يرسل رسالة. فلماذا نتحقّق من الموافقة في الكود أيضًا؟

- ○ لأن الكود أسرع من النموذج
- ○ لأن السلوك المتعلَّم قد يفشل مع صيغ جديدة أو بعد الضبط الدقيق
- ○ لأن النموذج لا يستطيع إرسال الرسائل أصلًا

٢ اكتب gate(call, approved, log). تضيف إلى log الزوج (tool, ok)، حيث تعني ok أن call هو الاستدعاء الموافَق عليه approved تمامًا، ولا تعيد "run" إلا عندئذ، وإلا أعادت "ask again". وتكون approved هي None حين لا توجد موافقة. (لا نموذج هنا: الاستدعاءات معطاة.)

```
def gate(call, approved, log):
    return "run"
```

اكتب برنامجك:

٣ صِل كل تشغيل في مختبر التعليم بنتيجة «درسي الصغير» في ٨ طلبات للحافلات و٨ مهارات قديمة.

قبل التعليم	الحافلات ٧/٨، والقديمة ١/٨
دون خلط محادثات قديمة	الحافلات ٥/٨، والقديمة ٨/٨
مع خلط ١٦ محادثة قديمة	الحافلات ٠/٨، والقديمة ٨/٨
مع خلط ٤٨ محادثة قديمة	الحافلات ٧/٨، والقديمة ٥/٨

٤ في بوابة الموافقة هذه سطر واحد يسمح بمرور رسالة مختلفة بعد «نعم» واحدة. أيّ سطر؟

ضع دائرة حول السطر الذي فيه الخطأ، ثم اكتبه صحيحًا:

```
1  def gate(call, shown, reply, log):
2      if reply != "yes":
3          return "ask"
4      log.append(call["tool"])
5      if call["tool"] == shown["tool"]:
6          return "run"
7      return "ask"
```

٥ أيّ مما يلي يستمر في حمايتك حتى لو فشل الأمان الذي تعلّمه النموذج؟ اختر كل ما ينطبق.

- ☐ قائمة سماح بالأدوات في الكود لكل مهمة
- ☐ سطر في التعليمات: «اسأل دائمًا قبل الإرسال.»
- ☐ سجل لكل فعل، مسموحًا كان أو مرفوضًا
- ☐ مقارنة كل استدعاء بالاستدعاء الموافَق عليه في الكود
- ☐ الثقة بالرفض الذي تعلّمه في التدريب

✎ فكّر في وكيلٍ تحب أن تبنيه أو تستعمله. أيّ سلوكياته يجب أن يصمد في كل مرة، وأيّ طبقة من الكود تضمن كلًّا منها؟

تحقّق من إجاباتك

الضبط الدقيق وحواجز الحماية

وكلاء الذكاء الاصطناعي، الجامعة، الدرس ٤

١ **لأن السلوك المتعلَّم قد يفشل مع صيغ جديدة أو بعد الضبط الدقيق**

السؤال قبل الإرسال عادة متعلَّمة، والعادات قد تفشل: فعبارة «نعم، أرسلها.» وحدها تجعل «درسي الصغير» يختلق رسالة، والضبط الدقيق قد يمحو العادة.

٢

```
def gate(call, approved, log):
    ok = call == approved
    log.append((call["tool"], ok))
    if ok:
        return "run"
    return "ask again"
```

ربط الموافقة بالاستدعاء نفسه يعني أن «نعم» لرسالة لا يمكن أن تُرسل رسالة أخرى، وتسجيل التنفيذ والرفض كليهما يترك سجلًّا للمراجعة.

٣ **قبل التعليم — الحافلات ٠/٨، والقديمة ٨/٨**

دون خلط محادثات قديمة — الحافلات ٧/٨، والقديمة ١/٨

مع خلط ١٦ محادثة قديمة — الحافلات ٧/٨، والقديمة ٥/٨

مع خلط ٤٨ محادثة قديمة — الحافلات ٥/٨، والقديمة ٨/٨

دون إعادة القديم تُتعلَّم الأداة الجديدة لكن المهارات القديمة تنهار (النسيان الكارثي)، وكلما زادت المحادثات القديمة المعادة بقي من المهارات القديمة أكثر، بكلفة صغيرة على الأداة الجديدة.

٤ **السطر 5:** `if call == shown:`

مقارنة الأداة وحدها تعني أن أي استدعاء send_message يمرّ ما دام الشخص وافق على واحد: فقد يغيّر النموذج النص أو المستلم.

٥ **قائمة سماح بالأدوات في الكود لكل مهمة، مقارنة كل استدعاء بالاستدعاء الموافَق عليه في الكود، سجل لكل فعل، مسموحًا كان أو مرفوضًا**

قوائم السماح وفحوص الموافقة على الفعل نفسه والسجلات موجودة في الكود، وتصمد مهما كتب النموذج.