الضبط الدقيق وحواجز الحماية

وكلاء الذكاء الاصطناعي، الجامعة، الدرس ٤

في هذا الدرس سوف

- قياس ما يعلّمه الضبط الدقيق وما يُنسيه للنموذج.
- شرح لماذا لا يكون الأمان المتعلَّم ضمانًا.
- تصميم حواجز حماية متعدّدة الطبقات في الكود: الأدوات، والموافقة، والفحوص، والسجلات، والاختبارات.

الأفكار الأساسية

- الضبط الدقيق يعلّم ويُنسي: دون إعادة القديم، ٧/٨ في الجديد و١/٨ في القديم.
- الرفض والسؤال المتعلَّمان قد يفشلان: ٢٨٪ و١٢٪ من الرفض المعاد صوغه حصل على استدعاء.
- احرس الأفعال بالكود: أقل الأدوات، والموافقة على الفعل نفسه، والفحوص، والسجلات، وإعادة الاختبار.

النشاط: طبقات الحماية

١. الاختيار (٣ دقائق): وكيل وفعل واحد خطِر.

٢. الطبقات (٧ دقائق): اكتب خمسة حواجز، بطاقة لكل حاجز.

٣. الهجوم (٧ دقائق): يزيل زميلك البطاقات واحدة تلو الأخرى.

٤. النقاش (٣ دقائق): أيّ حاجز كان الأهم؟

استعملا وكلاء وأشخاصًا ورسائل خيالية فقط. وتكفي خمس بطاقات أو مربعات ورق ممزّقة.

لنتناقش

١. متى يستحق الضبط الدقيق عناءه، ومتى تكفي أداة جديدة أو تعليمات أوضح؟

٢. لماذا لا يكفي وعد النموذج بأن يسأل أولًا؟

٣. أيّ حاجز حماية لن تزيله أبدًا، ولماذا؟

بطاقة الخروج

- شيء واحد قد يُنسيه الضبط الدقيق للنموذج، والحاجز في الكود الذي يظل يحميك.