ملاحظات المراجعة — لك

# هندسة الوكلاء: التخطيط وتعدّد الوكلاء والتقييم وحواجز الحماية: اختبار الوحدة

وكلاء الذكاء الاصطناعي، الجامعة، اختبار الوحدة

المدة
٢٠ دقيقة

المواد
ورق وقلم. لا حاجة إلى جهاز.

## أهداف التعلّم

- الخطط والذاكرة
- عدّة وكلاء لمهمة واحدة
- قياس أداء الوكيل
- الضبط الدقيق وحواجز الحماية

## النشاط: مراجعة تصميم وكيل

١. التمهيد (٣ دقائق): اكتب بكلماتك فكرة واحدة من كل درس من الدروس الأربعة.
٢. التصميم (٨ دقائق): ارسم وكيلًا لمهمة حقيقية في جامعتك، كالإجابة عن أسئلة مقرّر أو حجز القاعات: خطواته، وما يبقيه في نافذته، وأدواره، وأدواته.
٣. المراجعة (٧ دقائق): تبادل التصميم مع زميلك، وافحص تصميمه بما تعلّمته في الوحدة: أين تنتقل الأخطاء من خطوة إلى أخرى، وما الذي قد يسقط من الذاكرة، وكيف سيختبره، وأيّ الأفعال محروسة في الكود؟
٤. المشاركة (دقيقتان): يشارك كل زوج أضعف نقطة وجدها، وكيف سيصلحها.

**استعملوا أسماء وبيانات خيالية في كل تصميم. فالمهم هو المراجعة، لا وكيل مثالي.**

## للنقاش

- أيّ فكرة من هذه الوحدة تغيّر طريقة بنائك لوكيل؟
- ما الذي يقنعك بأن وكيلًا جاهز لمستخدمين حقيقيين؟
- أيّ حاجز ستضيفه أولًا إلى أداة ذكاء اصطناعي تستعملها الآن؟

## تحقّق من نفسك

- أنفع فكرة من هذه الوحدة + المشروع الذي سأستعملها فيه.

### جرّبها هذا الأسبوع

اختر من هذه الوحدة العادة التي تحتاجها أكثر (فحص كل خطوة، أو تثبيت الحقائق المهمة، أو مجموعة اختبار ثابتة، أو الموافقة على الفعل نفسه في الكود) واستعملها في مشروع حقيقي هذا الأسبوع.

ورقة الاختبار

# هندسة الوكلاء: التخطيط وتعدّد الوكلاء والتقييم وحواجز الحماية: اختبار الوحدة

وكلاء الذكاء الاصطناعي، الجامعة، اختبار الوحدة

الاسم _____ الفصل _____ التاريخ _____

**١** **كل خطوة من خطوات وكيل ذي أربع خطوات صحيحة في ٩٠٪ من المرات. كم مرة تقريبًا تكون المهمة كلها صحيحة؟**

○ نحو ٦٦٪ ○ نحو ٩٠٪ ○ نحو ٣٦٪

**٢** **نافذة سياق النموذج هي ذاكرته الوحيدة في المحادثة: ما يسقط منها يُنسى.**

○ صح ○ خطأ

**٣** **أيّ مما يلي يساعد الوكيل على الاحتفاظ بالمهم كلما طالت المحادثة؟ اختر كل ما ينطبق.**

☐ الاحتفاظ بكل شيء حتى تفيض النافذة ☐ ملاحظات قصيرة مكان الحوارات المنتهية

☐ استرجاع الجزء الذي تحتاجه الخطوة فقط من المستند ☐ تثبيت الحقائق المهمة، كالتواريخ والأماكن

☐ إسقاط أقدم الأدوار، دون ملاحظات

**٤** **صِل كل دور في فريق الوكيل بمهمته.**

| | | |
|---|---|---|
| المخطّط | • • • • | يشغّل الأداة ويعيد النتيجة |
| المدقّق | • • • • | يوافق على الأفعال ويتولّى ما يُوقَف |
| المنفِّذ | • • • • | يقترح استدعاء الأداة التالي |
| الإنسان | • • • • | يختبر الاستدعاء بقواعد صارمة |

**٥** **مجموعة اختبار صُحّحت حسب المجموعات. ماذا يطبع هذا البرنامج؟**

```
hits = {"en": 15, "ar": 14}
total = {"en": 16, "ar": 16}
print(hits["ar"] / total["ar"])
```

○ 0.875 ○ 0.9375 ○ 14

**٦** **رتّب خطوات التقييم الصادق.**

☐ شغّل الوكيل وصحّح كل حالة بتطابق تام

☐ أعد تشغيل المجموعة نفسها بعد كل تغيير

☐ حدّد الأجوبة الصحيحة قبل التشغيل

☐ اجمع الطلبات، ومنها صيغ محجوبة

☐ فصّل النتيجة واقرأ الأخطاء

**٧** **الوكيل الذي يحصل على ١٦ من ١٦ في الصيغ التي تدرّب عليها سيؤدي بالقدر نفسه تقريبًا مع الصيغ الجديدة.**

○ صح ○ خطأ

**٨** **أكمل بوابة الموافقة: لا تشغّل الاستدعاء إلا إن كان هو الموافَق عليه تمامًا، وتسجّل كل قرار.**

```
def gate(call, approved, log):
    ok = call __________ approved
    log.__________((call["tool"], ok))
    if ok:
        return "run"
    return "ask again"
```

**بنك الكلمات:** `!=` `==` `pop` `append`

**٩** **ضبطٌ دقيق دون خلط محادثات قديمة يصيب ٧/٨ في أداة الحافلات الجديدة، لكن ١/٨ في المهارات القديمة. ماذا يحدث؟**

○ النسيان الكارثي: التعلّم الجديد محا المهارات القديمة ○ أداة الحافلات أصعب من غيرها ببساطة

○ مجموعة الاختبار أصغر من أن تُظهر شيئًا

**١٠** **أيّ مما يلي يظل يحميك إذا فشل الأمان الذي تعلّمه النموذج؟ اختر كل ما ينطبق.**

☐ الرفض الذي تعلّمه في التدريب ☐ مقارنة كل استدعاء بالاستدعاء الموافَق عليه

☐ الأدوات التي تحتاجها المهمة فقط، مفروضة في الكود ☐ سجل لكل فعل

☐ أن تطلب من النموذج في تعليماته أن يكون حذرًا

تحقّق من إجاباتك

# هندسة الوكلاء: التخطيط وتعدّد الوكلاء والتقييم وحواجز الحماية: اختبار الوحدة

وكلاء الذكاء الاصطناعي، الجامعة، اختبار الوحدة

**١** **نحو ٦٦٪**

الاحتمالات تُضرب: ٠٫٩ × ٠٫٩ × ٠٫٩ × ٠٫٩ ≈ ٠٫٦٦.

**٢** **صح**

لا يرى النموذج إلا التوكنز التي في نافذته (٣٨٤ لـ«درسي الصغير»).

**٣** **ملاحظات قصيرة مكان الحوارات المنتهية، تثبيت الحقائق المهمة، كالتواريخ والأماكن، استرجاع الجزء الذي تحتاجه الخطوة فقط من المستند**

الملاحظات والحقائق المثبّتة والاسترجاع تحفظ الأساسي بتوكنز أقل.

**٤** **المخطّط — يقترح استدعاء الأداة التالي**
**المدقّق — يختبر الاستدعاء بقواعد صارمة**
**المنفِّذ — يشغّل الأداة ويعيد النتيجة**
**الإنسان — يوافق على الأفعال ويتولّى ما يُوقَف**

تقسيم العمل يتيح لجزء أن يفحص جزءًا آخر قبل أن يحدث شيء: فالنموذج يقترح فقط، والكود يفحص وينفّذ، ويبقى للإنسان القول الفصل في الأفعال.

**٥** **0.875**

في المجموعة العربية ١٤ إصابة من ١٦ حالة، و١٤ ÷ ١٦ = ٠٫٨٧٥.

**٦** **من الأعلى إلى الأسفل: ٣، ٥، ٢، ١، ٤**

تُحدَّد الأجوبة قبل التشغيل كي لا تُطوَّع لتناسب النتائج، ويكون التصحيح بتطابق تام، وتُقرأ الأخطاء حسب المجموعة، وتُعاد المجموعة نفسها لالتقاط التراجع.

**٧** **خطأ**

الصيغ المدرَّب عليها تقيس الحفظ: فـ«درسي الصغير» ينخفض من ١٦/١٦ إلى ١٣/١٦ مع الصيغ الجديدة، وإلى ٧٨–٨٠٪ على آلاف منها.

**٨**

```
def gate(call, approved, log):
    ok = call == approved
    log.append((call["tool"], ok))
    if ok:
        return "run"
    return "ask again"
```

تقارن == الاستدعاء كله، الأداة وكل تفصيل، بالاستدعاء الموافَق عليه، وتضيف append القرار إلى السجل، سواء نُفّذ أم لا.

**٩** **النسيان الكارثي: التعلّم الجديد محا المهارات القديمة**

التدريب على الأمثلة الجديدة وحدها غيّر أرقامًا كانت المهارات القديمة تعتمد عليها.

**١٠** **الأدوات التي تحتاجها المهمة فقط، مفروضة في الكود، مقارنة كل استدعاء بالاستدعاء الموافَق عليه، سجل لكل فعل**

الحواجز في الكود تصمد مهما كتب النموذج. أما التعليمات والرفض المتعلَّم فهما سلوك النموذج نفسه، وقد يفشلان مع الصيغ الجديدة (حصل ٢٨٪ و١٢٪ من الطلبات التي يجب رفضها، بصيغ جديدة، على استدعاء أداة) أو بعد الضبط الدقيق.