خطة المحاضرة، لعضو هيئة التدريس

تقييم الوكلاء

المدة
٦٠ دقيقة

المواد
جهاز عرض أو سبّورة، شرائح المحاضرة وورقة الحلقة النقاشية من الحزمة، هواتف أو حواسيب فيها «درسي»، للمختبر

أهداف التعلّم

- نعرّف pass@k.
- نقيس عدم اليقين.
- نقيّم دقة التقييم.

النشاط: دقّق تقييمًا

١. التمهيد (٥ دقائق): اعرض جدولي نتائج واسأل الطلاب أيّهما يصدّقون.
٢. الحساب (١٥ دقيقة): يحسب كل زوجين pass@1 وpass@3 من عينة تشغيلات.
٣. الفترة (١٥ دقيقة): أضف فترات ثقة ٩٥٪ وقرّر أيّ الفروق حقيقية.
٤. التدقيق (٢٠ دقيقة): اسرد ما أغفله تقرير كل فريق وأعد كتابة أحدهما بأمانة.
٥. الختام (٥ دقائق): يكتب الطلاب أكثر نقطة غامضة في المحاضرة وسؤالًا واحدًا، واقرأها قبل الأسبوع القادم.

للنقاش

- كم كان عرض الفترة؟
- أيّ إغفال كان الأهم؟
- كيف ستزن الدقة؟

بطاقة الخروج

- اكتب الجملة الواحدة التي يجب أن تتضمنها كل نتيجة وكيل.

جرّبها في محاضرتك القادمة

اعرض نتائج فريقين، إحداهما مضخّمة والأخرى أمينة، دون أن تقول أيّهما، فيسرد كل زوجين ما عرضه كل فريق وما لم يعرضه، ثم يصوّتون على النتيجة التي يثقون بها.

ورقة الحلقة النقاشية، للطلاب

تقييم الوكلاء

وكلاء الذكاء الاصطناعي، الجامعة، المحاضرة ٣

الاسم _____ المجموعة _____ التاريخ _____

١ **أيّ نتيجة أجدر بالثقة في مشروع وكيل طلابي؟**

○ pass@1 على 5 تشغيلات بمهام منفصلة ○ pass@10 على مهام التطوير ○ أفضل تشغيلة واحدة

٢ **احسب المقاييس.**

مع $p = 0.5$، تكون pass@3 = _____ . وعلى ١٠٠ مهمة عند $\hat{p} = 0.5$، يكون الخطأ المعياري _____ .

بنك الكلمات: 0.75، 0.05، 0.875، 0.5

٣ **أيّها يجعل تقييم الوكيل أجدر بالثقة؟ اختر كل ما ينطبق.**

☐ عرض أفضل تشغيلة فقط ☐ قراءة نصوص النجاحات ☐ عدة تشغيلات مع فترة ثقة

☐ مهام منفصلة عن التطوير

٤ **إذا حقق الوكيل A نسبة ٦٢٪ والوكيل B نسبة ٥٨٪ على ٥٠ مهمة في تشغيلة واحدة، فقد يكون الفارق مجرد ضوضاء.**

○ صح ○ خطأ

٥ **طابق كل تهديد لصلاحية التقييم مع علاجه.**

الضبط على مهام الاختبار	• • • •	عدة تشغيلات وفترات ثقة
العشوائية بين التشغيلات	• • • •	مهام جديدة غير منشورة
الوكيل يعدّل الاختبارات	• • • •	مجموعة منفصلة
المعيار في بيانات التدريب	• • • •	فاحصات محمية ومراجعة النصوص

الإجابات، لعضو هيئة التدريس

تقييم الوكلاء

وكلاء الذكاء الاصطناعي، الجامعة، المحاضرة ٣

١ **pass@1 على 5 تشغيلات بمهام منفصلة**

منفصلة ومتكررة وأمينة.

٢ **مع p = 0.5، تكون 0.875 = pass@3. وعلى ١٠٠ مهمة عند p̂ = 0.5، يكون الخطأ المعياري 0.05.**

تفشل المحاولات الثلاث كلها باحتمال 0.5^3، لذا pass@3 = 1 − 0.5^3 = 0.875.

٣ **عدة تشغيلات مع فترة ثقة، مهام منفصلة عن التطوير، قراءة نصوص النجاحات**

عرض الأفضل فقط يضخّم النتائج.

٤ **صح**

الفترة نحو ±١٤ نقطة، وفارق ٤ نقاط ضمن الضوضاء.

٥ **الضبط على مهام الاختبار — مجموعة منفصلة**
العشوائية بين التشغيلات — عدة تشغيلات وفترات ثقة
الوكيل يعدّل الاختبارات — فاحصات محمية ومراجعة النصوص
المعيار في بيانات التدريب — مهام جديدة غير منشورة

المجموعة المنفصلة تمنع الضبط على الاختبار، وتعدد التشغيلات مع فترات الثقة يقيس العشوائية، والفاحصات المحمية ومراجعة النصوص تكشف الوكيل الذي يعدّل الاختبارات، والمهام الجديدة غير المنشورة تتجنب التلوّث.

✎ **لتفكّر فيه**

كيف يعرض طلابك حاليًا نتائج مشاريع الوكلاء أو النماذج، وماذا ستشترط الفصل القادم؟