خطة المحاضرة، لعضو هيئة التدريس

وكلاء آمنون وقابلون للمساءلة

وكلاء الذكاء الاصطناعي، الجامعة، المحاضرة ٤

المدة
٦٠ دقيقة

المواد
جهاز عرض أو سبّورة، شرائح المحاضرة وورقة الحلقة النقاشية من الحزمة، هواتف أو حواسيب فيها «درسي»، للمختبر

أهداف التعلّم

- نصنّف أفعال الوكيل.
- نطبّق أقل صلاحية والموافقة.
- نستخدم أُطر الحوكمة.

النشاط: راجع المخاطر

١. التمهيد (٥ دقائق): اقرأ حادثة البريد واطلب من الطلاب تحديد المسؤولية.
٢. السرد (١٥ دقيقة): تسرد المجموعات كل أداة لمساعد الحرم الجامعي وأسوأ سوء استخدام لها.
٣. الضبط (٢٠ دقيقة): حدد حدًا أو موافقة أو تسجيلًا أو منعًا لكل أداة.
٤. الحوكمة (١٥ دقيقة): اربط الإجراءات الوقائية بوظائف NIST: الحوكمة والتحديد والقياس والإدارة.
٥. الختام (٥ دقائق): يكتب الطلاب أكثر نقطة غامضة في المحاضرة وسؤالًا واحدًا، واقرأها قبل الأسبوع القادم.

للنقاش

- أيّ أداة كانت الأخطر؟
- أين سيظهر إرهاق الموافقة؟
- من يملك الوكيل؟

بطاقة الخروج

- سمِّ أداة واحدة ستمنعها عن الوكيل تمامًا.

جرّبها في محاضرتك القادمة

أعطِ المجموعات قائمة أدوات وكيل مساعد للحرم الجامعي، فتملأ كلٌّ منها جدولًا بأسوأ سوء استخدام وإمكانية التراجع والتحكم لكل أداة، ثم قارنوا الجداول واتفقوا على قواعد الموافقة.

ورقة الحلقة النقاشية، للطلاب

وكلاء آمنون وقابلون للمساءلة

وكلاء الذكاء الاصطناعي، الجامعة، المحاضرة ٤

الاسم _____ المجموعة _____ التاريخ _____

١ **أيّ تصميم كان سيمنع البريد إلى جميع الطلاب؟**

○ تعليمات ألطف ○ حد للمستلمين وموافقة على الإرسال الجماعي ○ نموذج أسرع

٢ **اضبط الحدود.**

ينبغي أن يرسل وكيل التذكير إلى _____ مستلم كحد أقصى لكل مهمة، وأن يحتاج أي إرسال جماعي إلى _____ إنسان.

بنك الكلمات: مراجعة لاحقة، موافقة، 1، الجميع

٣ **أيّ الأفعال ينبغي أن تتطلب عادةً موافقة إنسان؟ اختر كل ما ينطبق.**

☐ مراسلة الكلية كلها ☐ حذف سجلات الطلاب ☐ دفع فاتورة ☐ قراءة جدول عام

٤ **اشتراط موافقة إنسان على كل فعل، حتى القراءة، قد يجعل الوكيل أقل أمانًا.**

○ صح ○ خطأ

٥ **طابق كل إجراء وقائي مع الخطر الذي يعالجه.**

أقل صلاحية	• • • •	مساءلة غير واضحة
بوابة الموافقة	• • • •	حلقة خارجة عن السيطرة
سجل التدقيق	• • • •	أداة بصلاحيات زائدة
مفتاح الإيقاف	• • • •	فعل لا رجعة فيه

الإجابات، لعضو هيئة التدريس

وكلاء آمنون وقابلون للمساءلة

وكلاء الذكاء الاصطناعي، الجامعة، المحاضرة ٤

١ **حد للمستلمين وموافقة على الإرسال الجماعي**

توقف الحدود والموافقة الفعل نفسه.

٢ **ينبغي أن يرسل وكيل التذكير إلى 1 مستلم كحد أقصى لكل مهمة، وأن يحتاج أي إرسال جماعي إلى موافقة إنسان.**

حدّد الأداة على قدر المهمة واضبط الأفعال واسعة التأثير بموافقة.

٣ **دفع فاتورة، حذف سجلات الطلاب، مراسلة الكلية كلها**

القراءة فقط لبيانات عامة لا تغيّر شيئًا.

٤ **صح**

المراجعون الغارقون يوافقون دون تمعّن، فاحجز الموافقة للأفعال التي تستحقها.

٥ **أقل صلاحية — أداة بصلاحيات زائدة**

بوابة الموافقة — فعل لا رجعة فيه

سجل التدقيق — مساءلة غير واضحة

مفتاح الإيقاف — حلقة خارجة عن السيطرة

تغطي الإجراءات الوقائية المتعددة الطبقات إخفاقات مختلفة.

لتفكّر فيه

إذا تسبب وكيل طالب في ضرر في مشروع مقرر، فمن المسؤول بموجب قواعدك الحالية؟