

وكلاء آمنون وقابلون للمساءلة

وكلاء الذكاء الاصطناعي، الجامعة، المحاضرة ٤

في هذه المحاضرة

- نصنّف أفعال الوكيل.
- نطبّق أقل صلاحية والموافقة.
- نستخدم أُطر الحوكمة.

تذكّر

- صنّف حسب التراجع.
- وافق على ما لا رجعة فيه.
- سجّل وسمِّ مالكًا.

راجع المخاطر

١. التمهيد (٥ دقائق): Read the email incident and ask students to assign responsibility.

٢. السرد (١٥ دقيقة): الأدوات.

٣. الضبط (٢٠ دقيقة): الحدود والموافقة.

٤. الحوكمة (١٥ دقيقة): المساءلة.

٥. الختام (٥ دقائق): ورقة الدقيقة الواحدة.

لنتناقش

١. أيّ أداة كانت الأخطر؟

٢. أين سيظهر إرهاق الموافقة؟

٣. من يملك الوكيل؟

بطاقة الخروج

- سمِّ أداة واحدة ستمنعها عن الوكيل تمامًا.