أوامر مخبّأة في البيانات

أمن الذكاء الاصطناعي، المستوى ٢، الدرس ١

سنتعلّم اليوم

- نشرح كيف يمكن لأمر مخبّأ في نص أن يوجّه الذكاء الاصطناعي.
- نحدّد أين قد تصل الأوامر المخبّأة إلى أدوات الذكاء الاصطناعي في المدرسة.
- نسمّي الدفاعات التي تصمد.

تذكّر

- عند النموذج، تعليماتك والبيانات كلها نص.
- الحقن إما يُكتب مباشرةً، وإما يختبئ فيما يقرؤه الذكاء الاصطناعي.
- النص الخارجي بيانات، والقرار لإنسان قبل أي فعل.

روبوت الدردشة البشري

١. التمهيد (٥ دقائق): مَن يقرأ بريدكم ورسائلكم وواجباتكم؟

٢. الشرح (٨ دقائق): الذكاء الاصطناعي يقرأ كل شيء كنص واحد متصل.

٣. روبوت الدردشة البشري (١٥ دقيقة): يلخّص تلميذ رسالة متّبعًا كل سطر فيها.

٤. جولة ثانية (٧ دقائق): القاعدة الجديدة: الرسالة بيانات، وليست المدير.

٥. الختام (٥ دقائق): قائمة بأدوات تقرأ كلام الآخرين، ثم بطاقة الخروج.

اكتب الرسالة قبل الحصة، وضع الأمر المخبّأ في وسطها بالخط نفسه، حتى لا يلفت النظر. واختر أمرًا غير مؤذٍ، مثل إعلان أنه لا واجبات.

لنتناقش

١. لماذا اتّبع المساعد الأمر المخبّأ؟

٢. أين تقرأ التطبيقات التي تستخدمونها كلامًا كتبه آخرون؟

٣. أيّ قاعدة توقف الأمر المخبّأ؟

بطاقة الخروج

- اكتب موضعًا واحدًا يقرأ فيه الذكاء الاصطناعي نصًا كتبه غيرك، وقاعدة واحدة تحفظ الأمان.