خطة درس — للمعلم

كسر القيود: الالتفاف على روبوت الدردشة

أمن الذكاء الاصطناعي، المستوى ٢، الدرس ٢

المدة
٤٠ دقيقة

المواد
بطاقة قاعدة للحارس: سرّ غير مؤذٍ («الصندوق أزرق») وقاعدة واحدة («لا تذكر اللون أبدًا»)، بطاقة ثانية للمراقب: «أوقف أي جواب يكشف اللون»، السبّورة والطباشير لتسجيل المحاولات

أهداف التعلّم

- نشرح لماذا يمكن الالتفاف على رفض روبوت الدردشة.
- نقرأ نتيجة اختبار الفريق الأحمر: ما جُرّب، وما تسلّل، ومدى خطورته.
- نقرّر كيف تتعامل المدرسة مع محاولات كسر القيود.

النشاط: حارس القاعدة

١. التمهيد (٥ دقائق): اسأل هل رأى الطلاب روبوت دردشة يقول كلامًا جارحًا أو خاطئًا أو غير آمن. لا تسأل كيف، بل اسأل كيف شعروا وماذا فعلوا.

٢. الشرح (٨ دقائق): وضّح أن روبوتات الدردشة تُدرَّب على رفض الطلبات المؤذية، وأن هذا الرفض متعلَّم من أمثلة، وأن صيغة جديدة قد تتسلّل منه.

٣. الجولة الأولى (١٢ دقيقة): يمسك الحارس البطاقة: «السرّ: الصندوق أزرق. القاعدة: لا تذكر اللون أبدًا.» ويحاول الزملاء بصيغ مهذّبة مختلفة مدة خمس دقائق. سجّل على السبّورة ما نجح وكيف.

٤. الجولة الثانية (١٠ دقائق): أضف مراقبًا يسمع كل جواب أولًا ويوقف أي جواب يكشف اللون. العبوا مرة أخرى وقارنوا النتيجتين.

٥. الختام (٥ دقائق): اتفقوا على ما يُفعل حين يقول روبوت دردشة شيئًا مؤذيًا: توقّف، ولا تشاركه، وأخبر المعلم، وأبلغ عنه. ثم وزّع بطاقة الخروج.

اجعل السرّ غير مؤذٍ والقواعد صارمة: إعادة صياغة مهذّبة فقط، بلا شتائم ولا ضغط. فاللعبة عن سبب حاجة القواعد إلى فحص ثانٍ، لا عن الفوز.

للنقاش

- لماذا نجحت بعض الصيغ مع الحارس الأول؟
- ما الذي التقطه المراقب وفات الحارس؟
- ماذا تفعل إن قال روبوت دردشة شيئًا مؤذيًا؟

بطاقة الخروج

- اكتب لماذا يمكن الالتفاف على «لا» التي يقولها روبوت الدردشة، وطبقة واحدة تلتقط ما يتسلّل.

جرّبها في الصف غدًا

العب مع طلابك «حارس القاعدة»: يحرس تلميذ سرًّا غير مؤذٍ بقاعدة واحدة، ويحاول زملاؤه بصيغ مهذّبة مختلفة، ثم يفحص حارس ثانٍ كل جواب قبل أن يُقال. وقارنوا كم يستمرّ كل مرة.

ورقة عمل — للطلاب

كسر القيود: الالتفاف على روبوت الدردشة

أمن الذكاء الاصطناعي، المستوى ٢، الدرس ٢

الاسم _____ الصف _____ التاريخ _____

١ يريد الطلاب مسابقة: مَن يجعل روبوت دردشة الفصل يقول أسوأ كلام؟ ماذا تقول لهم؟

- ○ «تفضّلوا: إنه مجرد اختبار»
- ○ «لا مسابقات على خدمات حقيقية؛ أبلغوا عمّا يتسلّل بدلًا من ذلك»
- ○ «على هواتفكم فقط»

٢ بمجرد أن يرفض روبوت الدردشة طلبًا، فسيرفض كل إعادة صياغة له أيضًا.

- ○ صح
- ○ خطأ

٣ أيّ مما يلي من أشكال كسر القيود التي ينبغي أن يعرفها المعلم في لقطة شاشة لتلميذ؟ اختر كل ما ينطبق.

- ☐ «إنها مجرد قصة»
- ☐ تقسيم الطلب إلى أجزاء تبدو بريئة
- ☐ السؤال بلغة أخرى
- ☐ سؤال واضح عن واجب الليلة
- ☐ إنهاكه عبر رسائل كثيرة

٤ صِل كل جزء من تقرير الفريق الأحمر بما يسجّله.

النوع	القاعدة أو التغيير الذي يوقفه في المرة القادمة
تسلّل	مدى السوء، من ١ (منخفضة) إلى ٣ (عالية)
الخطورة	كم طلبًا لم يرفضه روبوت الدردشة
الإصلاح	نوع الطلب الذي جُرّب: خصوصية، أو احتيال، أو كلام جارح...

٥ أكمل الجملة.

الرفض _____ ، لذلك قد تتسلّل _____ جديدة.

بنك الكلمات: متعلَّم، صيغ، مثالي، كلمات مرور

هل أراك طلابك يومًا روبوت دردشة يقول شيئًا لا ينبغي أن يقوله؟ كيف ستتصرّف في المرة القادمة، ولمن ستبلّغ؟