كسر القيود: الالتفاف على روبوت الدردشة

أمن الذكاء الاصطناعي، المستوى ٢، الدرس ٢

سنتعلّم اليوم

- نشرح لماذا يمكن الالتفاف على رفض روبوت الدردشة.
- نقرأ نتيجة اختبار الفريق الأحمر: ما جُرّب، وما تسلّل، ومدى خطورته.
- نقرّر كيف تتعامل المدرسة مع محاولات كسر القيود.

تذكّر

- الرفض متعلَّم، لذلك قد تتسلّل الصيغ الجديدة.
- لا تعتمد على النموذج وحده: أضف طبقات حوله.
- اختبر بإذن، وأبلغ عمّا يتسلّل.

حارس القاعدة

١. التمهيد (٥ دقائق): هل رأيتم روبوت دردشة يقول ما لا ينبغي؟

٢. الشرح (٨ دقائق): الرفض متعلَّم، وإعادة الصياغة قد تتسلّل.

٣. الجولة الأولى (١٢ دقيقة): يحاول الزملاء استخراج سرّ غير مؤذٍ.

٤. الجولة الثانية (١٠ دقائق): أضيفوا مراقبًا، والعبوا مرة أخرى وقارنوا.

٥. الختام (٥ دقائق): ماذا نفعل حين يقول روبوت دردشة شيئًا مؤذيًا.

اجعل السرّ غير مؤذٍ والقواعد صارمة: إعادة صياغة مهذّبة فقط، بلا شتائم ولا ضغط. فاللعبة عن سبب حاجة القواعد إلى فحص ثانٍ، لا عن الفوز.

لنتناقش

١. لماذا نجحت بعض الصيغ مع الحارس الأول؟

٢. ما الذي التقطه المراقب وفات الحارس؟

٣. ماذا تفعل إن قال روبوت دردشة شيئًا مؤذيًا؟

بطاقة الخروج

- اكتب لماذا يمكن الالتفاف على «لا» التي يقولها روبوت الدردشة، وطبقة واحدة تلتقط ما يتسلّل.