خطة درس — للمعلم

حواجز الحماية: قواعد حول النموذج

أمن الذكاء الاصطناعي، المستوى ٢، الدرس ٣

المدة
٤٠ دقيقة

المواد
بطاقة عليها خمس كلمات محظورة لـ«الروبوت»، مثل: واجب، إجابات، انسخ، اختبار، غش، قصاصات ورق للرسائل، السبّورة والطباشير لتسجيل النتائج

أهداف التعلّم

- نصف ثلاثة أنواع من حواجز الحماية حول نموذج الذكاء الاصطناعي.
- نشرح لماذا تفوّت قوائم الكلمات إعادة الصياغة وتحظر النص البريء.
- نشرح لماذا يصمد فحص الفعل.

النشاط: روبوت قائمة الكلمات

١. التمهيد (٥ دقائق): اسأل كيف تقرّر بوابة المدرسة من يدخل: بقائمة الممنوعين، أم بتصريح يجب أن يحمله الداخل؟ وأيّهما ينجح أكثر مع شخص غريب؟

٢. الشرح (٨ دقائق): وضّح حواجز الحماية الثلاثة حول الذكاء الاصطناعي: مرشّح لما يدخل، ومرشّح لما يخرج، وفحص لما يوشك أن يفعله. وبيّن لماذا تفوّت قائمة الكلمات إعادة الصياغة.

٣. الجولة الأولى (١٢ دقيقة): يمسك الروبوت بطاقة الكلمات المحظورة الخمس، ويوقف كل قصاصة تستخدم إحداها. ويعيد الزملاء الصياغة ليتجاوزوه. سجّلوا ما مرّ، وأي قصاصة بريئة أُوقفت.

٤. الجولة الثانية (١٠ دقائق): الآن تحتاج كل قصاصة إلى موافقتك قبل أن تُمرَّر. العبوا مرة أخرى وقارنوا النتيجتين.

٥. الختام (٥ دقائق): اتفقوا على أن فحص الفعل ينجح مهما كانت الصياغة، وأن أفضل دفاع هو الطبقات. ثم وزّع بطاقة الخروج.

الرسائل تطلب إجابات الواجب فقط، لا شيء مؤذيًا. وانتبه للقصاصات البريئة التي يوقفها الروبوت: إنها الإنذارات الكاذبة التي تستحق النقاش.

للنقاش

- لماذا تجاوزت الرسائل المعاد صياغتها الروبوت؟
- أيّ رسالة بريئة أوقفها الروبوت؟
- لماذا نجحت موافقة المعلم مهما كانت الصياغة؟

بطاقة الخروج

- اكتب نقطة ضعف واحدة في مرشّح الكلمات، وحاجز حماية واحدًا يصمد مهما كانت الصياغة.

جرّبها في الصف غدًا

اصنع مع طلابك «روبوت قائمة الكلمات»: يوقف تلميذ الرسائل التي فيها كلمات محظورة، ويعيد زملاؤه صياغة رسالة غير مؤذية ليتجاوزوه، ثم يجب أن يوافق المعلم على كل رسالة. وقارنوا ما مرّ في كل طريقة.

ورقة عمل — للطلاب

حواجز الحماية: قواعد حول النموذج

أمن الذكاء الاصطناعي، المستوى ٢، الدرس ٣

الاسم _____ الصف _____ التاريخ _____

١ أيّ حاجز حماية يوقف رسالة لم يوافق عليها أحد، مهما كانت صياغتها؟

- ○ قائمة أطول من الكلمات المحظورة
- ○ فحص في الكود يتأكد أنها طُلبت ووُوفق عليها
- ○ مرشّح للمخرجات بالإنجليزية فقط

٢ صِل كل حاجز حماية بما يفحصه.

مرشّح المدخلات	• • • •	ما تسلّل من كل ما سبق
مرشّح المخرجات	• • • •	هل طُلب هذا الفعل ووُوفق عليه
فحص الفعل في الكود	• • • •	ما يوشك النموذج أن يقوله
الأشخاص والبلاغات	• • • •	ما يكتبه الشخص

٣ مرشّح الكلمات الجيد يحظر الرسائل المؤذية دون أن يحظر الرسائل البريئة أبدًا.

- ○ صح ○ خطأ

٤ رتّب الطبقات بحسب ترتيب مرور الرسالة بها.

- ☐ يتأكد الكود من الموافقة، ثم يرسل
- ☐ يفحص مرشّح المخرجات الرسالة
- ☐ يكتب النموذج رسالة
- ☐ يفحصه مرشّح المدخلات
- ☐ يكتب الشخص طلبًا

٥ أيّ مما يلي يجعل روبوت دردشة المدرسة أكثر أمانًا بوصفه طبقات؟ اختر كل ما ينطبق.

- ☐ مرشّح للمدخلات
- ☐ فحص في الكود قبل أي فعل
- ☐ أشخاص يقرؤون بلاغات المشكلات
- ☐ الثقة بأن النموذج لا يخطئ أبدًا

✎ فكّر في أداة ذكاء اصطناعي في مدرستك، أو في أداة قد تختارها. عن أيّ حواجز حماية ستسأل مقدّم الخدمة، وأيّ فعل تريد أن يوافق عليه إنسان؟