خطة درس — للمعلم

حواجز الحماية: قواعد حول النموذج

أمن الذكاء الاصطناعي، المستوى ٢، الدرس ٣

المدة
٤٠ دقيقة

المواد
بطاقة عليها خمس كلمات محظورة لـ«الروبوت»، مثل: واجب، إجابات، انسخ، اختبار، غش، قصاصات ورق للرسائل، السبّورة والطباشير لتسجيل النتائج

أهداف التعلّم

- نصف ثلاثة أنواع من حواجز الحماية حول نموذج الذكاء الاصطناعي.
- نشرح لماذا تفوّت قوائم الكلمات إعادة الصياغة وتحظر النص البريء.
- نشرح لماذا يصمد فحص الفعل.

النشاط: روبوت قائمة الكلمات

١. التمهيد (٥ دقائق): اسأل كيف تقرّر بوابة المدرسة من يدخل: بقائمة الممنوعين، أم بتصريح يجب أن يحمله الداخل؟ وأيّهما ينجح أكثر مع شخص غريب؟

٢. الشرح (٨ دقائق): وضّح حواجز الحماية الثلاثة حول الذكاء الاصطناعي: مرشّح لما يدخل، ومرشّح لما يخرج، وفحص لما يوشك أن يفعله. وبيّن لماذا تفوّت قائمة الكلمات إعادة الصياغة.

٣. الجولة الأولى (١٢ دقيقة): يمسك الروبوت بطاقة الكلمات المحظورة الخمس، ويوقف كل قصاصة تستخدم إحداها. ويعيد الزملاء الصياغة ليتجاوزوه. سجّلوا ما مرّ، وأي قصاصة بريئة أُوقفت.

٤. الجولة الثانية (١٠ دقائق): الآن تحتاج كل قصاصة إلى موافقتك قبل أن تُمرَّر. العبوا مرة أخرى وقارنوا النتيجتين.

٥. الختام (٥ دقائق): اتفقوا على أن فحص الفعل ينجح مهما كانت الصياغة، وأن أفضل دفاع هو الطبقات. ثم وزّع بطاقة الخروج.

الرسائل تطلب إجابات الواجب فقط، لا شيء مؤذيًا. وانتبه للقصاصات البريئة التي يوقفها الروبوت: إنها الإنذارات الكاذبة التي تستحق النقاش.

للنقاش

- لماذا تجاوزت الرسائل المعاد صياغتها الروبوت؟
- أيّ رسالة بريئة أوقفها الروبوت؟
- لماذا نجحت موافقة المعلم مهما كانت الصياغة؟

بطاقة الخروج

- اكتب نقطة ضعف واحدة في مرشّح الكلمات، وحاجز حماية واحدًا يصمد مهما كانت الصياغة.

جرّبها في المدرسة غدًا

اصنع مع طلابك «روبوت قائمة الكلمات»: يوقف تلميذ الرسائل التي فيها كلمات محظورة، ويعيد زملاؤه صياغة رسالة غير مؤذية ليتجاوزوه، ثم يجب أن يوافق المعلم على كل رسالة. وقارنوا ما مرّ في كل طريقة.

أسئلة للتدريب — لك

حواجز الحماية: قواعد حول النموذج

أمن الذكاء الاصطناعي، المستوى ٢، الدرس ٣

١ **أيّ حاجز حماية يوقف رسالة لم يوافق عليها أحد، مهما كانت صياغتها؟**

- ○ قائمة أطول من الكلمات المحظورة
- ○ فحص في الكود يتأكد أنها طُلبت ووُوفق عليها
- ○ مرشّح للمخرجات بالإنجليزية فقط

٢ **صِل كل حاجز حماية بما يفحصه.**

مرشّح المدخلات	• • • •	هل طُلب هذا الفعل ووُوفق عليه
مرشّح المخرجات	• • • •	ما يكتبه الشخص
فحص الفعل في الكود	• • • •	ما تسلّل من كل ما سبق
الأشخاص والبلاغات	• • • •	ما يوشك النموذج أن يقوله

٣ **مرشّح الكلمات الجيد يحظر الرسائل المؤذية دون أن يحظر الرسائل البريئة أبدًا.**

○ صح ○ خطأ

٤ **رتّب الطبقات بحسب ترتيب مرور الرسالة بها.**

- ☐ يفحص مرشّح المخرجات الرسالة
- ☐ يكتب النموذج رسالة
- ☐ يتأكد الكود من الموافقة، ثم يرسل
- ☐ يكتب الشخص طلبًا
- ☐ يفحصه مرشّح المدخلات

٥ **أيّ مما يلي يجعل روبوت دردشة المدرسة أكثر أمانًا بوصفه طبقات؟ اختر كل ما ينطبق.**

- ☐ مرشّح للمدخلات
- ☐ أشخاص يقرؤون بلاغات المشكلات
- ☐ فحص في الكود قبل أي فعل
- ☐ الثقة بأن النموذج لا يخطئ أبدًا

✎ **فكّر في أداة ذكاء اصطناعي في مدرستك، أو في أداة قد تختارها. عن أيّ حواجز حماية ستسأل مقدّم الخدمة، وأيّ فعل تريد أن يوافق عليه إنسان؟**

تحقّق من إجاباتك

حواجز الحماية: قواعد حول النموذج

أمن الذكاء الاصطناعي، المستوى ٢، الدرس ٣

١ **فحص في الكود يتأكد أنها طُلبت ووُوفق عليها**

القائمة الأطول تفوّتها الصيغ الجديدة واللغات الأخرى أيضًا.

٢ **مرشّح المدخلات — ما يكتبه الشخص**

مرشّح المخرجات — ما يوشك النموذج أن يقوله

فحص الفعل في الكود — هل طُلب هذا الفعل ووُوفق عليه

الأشخاص والبلاغات — ما تسلّل من كل ما سبق

كل طبقة تنظر إلى لحظة مختلفة: الطلب، والردّ، والفعل، وما بعد ذلك.

٣ **خطأ**

مرشّحات الكلمات تقع في الخطأين: تفوّت الهجمات المعاد صياغتها، وتحظر النص البريء، مثل درس يذكر كلمات المرور.

٤ **من الأعلى إلى الأسفل: ٤، ٣، ٥، ١، ٢**

يُرشَّح الطلب عند دخوله، ثم يكتب النموذج، ثم يُرشَّح الردّ عند خروجه، وآخر بوابة قبل أن يحدث أي شيء هي فحص الكود لموافقة الإنسان.

٥ **مرشّح للمدخلات، فحص في الكود قبل أي فعل، أشخاص يقرؤون بلاغات المشكلات**

المرشّحات وفحوص الأفعال والأشخاص، يلتقط كلٌّ منها بعض ما يفوت غيره.