حواجز الحماية: قواعد حول النموذج

أمن الذكاء الاصطناعي، المستوى ٢، الدرس ٣

سنتعلّم اليوم

- نصف ثلاثة أنواع من حواجز الحماية حول نموذج الذكاء الاصطناعي.
- نشرح لماذا تفوّت قوائم الكلمات إعادة الصياغة وتحظر النص البريء.
- نشرح لماذا يصمد فحص الفعل.

تذكّر

- حواجز الحماية قواعد حول النموذج: للمدخلات والمخرجات والأفعال.
- قوائم الكلمات تفوّت إعادة الصياغة وتوقف البريء.
- افحص الفعل، واسمح بالمسموح بدل المنع وحده، ورصّ الطبقات.

روبوت قائمة الكلمات

١. التمهيد (٥ دقائق): كيف تقرّر بوابة المدرسة من يدخل؟

٢. الشرح (٨ دقائق): ثلاثة حواجز؛ ولماذا تُخطئ قوائم الكلمات.

٣. الجولة الأولى (١٢ دقيقة): يحظر الروبوت الكلمات، ويعيد الزملاء الصياغة.

٤. الجولة الثانية (١٠ دقائق): يوافق المعلم على كل قصاصة، ثم نقارن.

٥. الختام (٥ دقائق): أيّ قاعدة صمدت، ولماذا؟ ثم بطاقة الخروج.

الرسائل تطلب إجابات الواجب فقط، لا شيء مؤذيًا. وانتبه للقصاصات البريئة التي يوقفها الروبوت: إنها الإنذارات الكاذبة التي تستحق النقاش.

لنتناقش

١. لماذا تجاوزت الرسائل المعاد صياغتها الروبوت؟

٢. أيّ رسالة بريئة أوقفها الروبوت؟

٣. لماذا نجحت موافقة المعلم مهما كانت الصياغة؟

بطاقة الخروج

- اكتب نقطة ضعف واحدة في مرشّح الكلمات، وحاجز حماية واحدًا يصمد مهما كانت الصياغة.