اسأل قبل أن يتصرّف

أمن الذكاء الاصطناعي، المستوى ٢، الدرس ٤

سنتعلّم اليوم

- نميّز بين الأدوات التي تقرأ والأدوات التي تتصرّف.
- نختار أقل الأدوات التي تحتاج إليها المهمة.
- نشرح لماذا يجب أن يتحقّق الكود من موافقة الإنسان.

تذكّر

- أدوات القراءة قد تسرّب في أسوأ الأحوال، وأدوات الفعل قد تنقلب ضدك.
- أقل الصلاحيات: أقل الأدوات، ولأقصر مدة.
- موافقة إنسان يتحقّق منها الكود، وسجلّ لكل فعل.

تصاريح للروبوتات

١. التمهيد (٥ دقائق): ماذا يستطيع عريف الفصل أن يفعل دون أن يسأل؟

٢. الشرح (٨ دقائق): أدوات القراءة والفعل؛ وأقل الصلاحيات؛ وموافقة الإنسان.

٣. التصميم (١٥ دقيقة): تكتب كل مجموعة تصريحًا لمهمة روبوت واحدة.

٤. التبادل (٧ دقائق): ابحثوا عن أدوات غير لازمة وأفعال بلا موافقة.

٥. الختام (٥ دقائق): اتفقوا على قاعدة الفصل، ثم بطاقة الخروج.

اكتب بطاقات الأدوات الثماني على السبّورة قبل الحصة. لا حاجة إلى أجهزة: فالروبوت موجود على الورق فقط.

لنتناقش

١. لماذا تكون الأداة التي تتصرّف أخطر من التي تقرأ؟

٢. أيّ أداة مُنحت ولم تكن المهمة تحتاج إليها؟

٣. لماذا يجب أن يتحقّق الكود من الموافقة، لا أن تُطلب فقط؟

بطاقة الخروج

- اكتب مهمة واحدة لمساعد ذكاء اصطناعي، والأدوات التي يحتاج إليها فقط، ومن يجب أن يوافق قبل أن يتصرّف.