خطة درس — للمعلم

خداع الذكاء الاصطناعي والدفاع عنه: اختبار الوحدة

أمن الذكاء الاصطناعي، المستوى ٢، اختبار الوحدة

المدة
٤٥ دقيقة

المواد
سبّورة، طباشير، ورق. لا حاجة إلى أجهزة.

أهداف التعلّم

- أوامر مخبّأة في البيانات
- كسر القيود: الالتفاف على روبوت الدردشة
- حواجز الحماية: قواعد حول النموذج
- اسأل قبل أن يتصرّف

النشاط: مسابقة الفرق

١. كوّن فرقًا من أربعة
٢. اقرأ كل سؤال بصوت عالٍ، ويتفق كل فريق على إجابة واحدة
٣. اكشف الإجابة واطلب من أحد الفرق أن يشرح السبب
٤. اكتب أصعب سؤال على السبّورة ليوم الغد

للنقاش

- أيّ أداة ذكاء اصطناعي في مدرستك تقرأ نصوصًا كتبها آخرون؟
- أيّ سؤال فاجأك، ولماذا؟
- ماذا ستسأل في المرة القادمة التي يعرض فيها أحد على المدرسة وكيل ذكاء اصطناعي؟

بطاقة الخروج

- دفاع واحد سأطالب به، وأين سأطالب به

جرّبها في الصف غدًا

اختر من هذه الوحدة الدفاع الذي تحتاج إليه مدرستك أكثر (النص الخارجي بيانات، أو الإبلاغ عمّا يتسلّل، أو فحص الفعل، أو الأدوات التي تحتاج إليها المهمة فقط)، واسأل عنه في المرة القادمة التي يقترح فيها أحد أداة ذكاء اصطناعي جديدة.

ورقة عمل — للطلاب

خداع الذكاء الاصطناعي والدفاع عنه: اختبار الوحدة

أمن الذكاء الاصطناعي، المستوى ٢، اختبار الوحدة

الاسم _____ الصف _____ التاريخ _____

١ ما حقن الأوامر؟

○ أمر مخبّأ في نص يقرؤه الذكاء الاصطناعي، وقد يتّبعه ○ فيروس يُحقن في الهاتف ○ خطأ كتابي في الطلب

٢ يستطيع النموذج اللغوي دائمًا أن يميّز تعليماتك من الكلمات الموجودة داخل ملف يقرؤه.

○ صح ○ خطأ

٣ صِل كل مصطلح بمعناه.

الحقن المباشر	• • • •	اختبار روبوت دردشة عن قصد وبإذن
الحقن غير المباشر	• • • •	الالتفاف على قواعد الأمان في روبوت الدردشة
كسر القيود	• • • •	أمر مخبّأ في رسالة يلخّصها الذكاء الاصطناعي
اختبار الفريق الأحمر	• • • •	أمر يُكتب في المحادثة

٤ لماذا قد يتجاوز طلب معاد الصياغة رفض روبوت الدردشة؟

○ لأن رفضه متعلَّم من الصيغ التي رآها ○ لأن روبوت الدردشة يتعب بعد بضعة أسئلة

○ لأن إعادة الصياغة تحذف قواعد الأمان فيه

٥ جعل الطلاب روبوت دردشة المدرسة يكتب شيئًا جارحًا. أيّ التصرّفات منطقية؟ اختر كل ما ينطبق.

☐ سجّل ما جُرّب وما تسلّل ☐ أبلغ مقدّم الخدمة ☐ أضف فحصًا أو قاعدة، ثم اختبر من جديد

☐ نظّم مسابقة لاكتشاف المزيد