خطة المراجعة — للمعلم

خداع الذكاء الاصطناعي والدفاع عنه: اختبار الوحدة

أمن الذكاء الاصطناعي، المستوى ٢، اختبار الوحدة

المدة
٤٥ دقيقة

المواد
سبّورة، طباشير، ورق. لا حاجة إلى أجهزة.

أهداف التعلّم

- أوامر مخبّأة في البيانات
- كسر القيود: الالتفاف على روبوت الدردشة
- حواجز الحماية: قواعد حول النموذج
- اسأل قبل أن يتصرّف

النشاط: مسابقة الفرق

١. كوّن فرقًا من أربعة
٢. اقرأ كل سؤال بصوت عالٍ، ويتفق كل فريق على إجابة واحدة
٣. اكشف الإجابة واطلب من أحد الفرق أن يشرح السبب
٤. اكتب أصعب سؤال على السبّورة ليوم الغد

للنقاش

- أيّ أداة ذكاء اصطناعي في مدرستك تقرأ نصوصًا كتبها آخرون؟
- أيّ سؤال فاجأك، ولماذا؟
- ماذا ستسأل في المرة القادمة التي يعرض فيها أحد على المدرسة وكيل ذكاء اصطناعي؟

بطاقة الخروج

- دفاع واحد سأطالب به، وأين سأطالب به

جرّبها في المدرسة غدًا

اختر من هذه الوحدة الدفاع الذي تحتاج إليه مدرستك أكثر (النص الخارجي بيانات، أو الإبلاغ عمّا يتسلّل، أو فحص الفعل، أو الأدوات التي تحتاج إليها المهمة فقط)، واسأل عنه في المرة القادمة التي يقترح فيها أحد أداة ذكاء اصطناعي جديدة.

ورقة الاختبار — لكل فريق

خداع الذكاء الاصطناعي والدفاع عنه: اختبار الوحدة

أمن الذكاء الاصطناعي، المستوى ٢، اختبار الوحدة

الفريق _____ التاريخ _____

١ ما حقن الأوامر؟

○ خطأ كتابي في الطلب ○ فيروس يُحقن في الهاتف ○ أمر مخبّأ في نص يقرؤه الذكاء الاصطناعي، وقد يتّبعه

٢ يستطيع النموذج اللغوي دائمًا أن يميّز تعليماتك من الكلمات الموجودة داخل ملف يقرؤه.

○ صح ○ خطأ

٣ صِل كل مصطلح بمعناه.

الحقن المباشر	• • • •	أمر مخبّأ في رسالة يلخّصها الذكاء الاصطناعي
الحقن غير المباشر	• • • •	اختبار روبوت دردشة عن قصد وبإذن
كسر القيود	• • • •	أمر يُكتب في المحادثة
اختبار الفريق الأحمر	• • • •	الالتفاف على قواعد الأمان في روبوت الدردشة

٤ لماذا قد يتجاوز طلب معاد الصياغة رفض روبوت الدردشة؟

○ لأن رفضه متعلَّم من الصيغ التي رآها ○ لأن إعادة الصياغة تحذف قواعد الأمان فيه ○ لأن روبوت الدردشة يتعب بعد بضعة أسئلة

٥ جعل الطلاب روبوت دردشة المدرسة يكتب شيئًا جارحًا. أيّ التصرّفات منطقية؟ اختر كل ما ينطبق.

☐ أبلغ مقدّم الخدمة ☐ سجّل ما جُرّب وما تسلّل ☐ أضف فحصًا أو قاعدة، ثم اختبر من جديد ☐ نظّم مسابقة لاكتشاف المزيد

٦ مرشّح يحظر كلمة «كلمة المرور». أيّ رسالة تتجاوزه؟

○ «ردّ برمز الدخول لتحتفظ بحسابك» ○ «أرسل لي كلمة المرور» ○ «كلمة المرور مطلوبة الآن»

٧ رتّب الطبقات بحسب ترتيب مرور الرسالة بها.

☐ مرشّح المدخلات
☐ يكتب النموذج
☐ فحص الفعل في الكود
☐ يكتب الشخص طلبًا
☐ مرشّح المخرجات

٨ الفحص في الكود للتأكد من أن الرسالة طُلبت ووُوفق عليها ينجح مهما كانت صياغة الرسالة.

○ صح ○ خطأ

٩ أيّ هذه الأدوات أدوات فعل لا أدوات قراءة؟ اختر كل ما ينطبق.

☐ البحث في المكتبة ☐ إرسال رسالة ☐ الاطلاع على الجدول ☐ دفع فاتورة ☐ حذف الملفات

١٠ أكمل قاعدة وكلاء الذكاء الاصطناعي.

أعطِ الوكيل _____ الأدوات التي تحتاج إليها مهمته، و _____ إنسان قبل أن يتصرّف.

بنك الكلمات: أكثر، أقل، تخمين، موافقة

الإجابات — للمعلم

خداع الذكاء الاصطناعي والدفاع عنه: اختبار الوحدة

أمن الذكاء الاصطناعي، المستوى ٢، اختبار الوحدة

١ **أمر مخبّأ في نص يقرؤه الذكاء الاصطناعي، وقد يتّبعه**

حقن الأوامر إخفاء تعليمات فيما يقرؤه الذكاء الاصطناعي، أو كتابتها مباشرةً.

٢ **خطأ**

إنه يقرأ تعليماتك والملف كنص واحد متصل، دون طريقة موثوقة للتمييز بينهما.

٣ **الحقن المباشر — أمر يُكتب في المحادثة**
الحقن غير المباشر — أمر مخبّأ في رسالة يلخّصها الذكاء الاصطناعي
كسر القيود — الالتفاف على قواعد الأمان في روبوت الدردشة
اختبار الفريق الأحمر — اختبار روبوت دردشة عن قصد وبإذن

الحقن يخفي الأوامر أو يكتبها، وكسر القيود يلتفّ على القواعد بإعادة الصياغة، واختبار الفريق الأحمر هو اختبار المدافعين أنفسهم، ويُجرى بإذن.

٤ **لأن رفضه متعلَّم من الصيغ التي رآها**

يتعلّم النموذج رفض أنواع الصيغ التي رآها في التدريب.

٥ **سجّل ما جُرّب وما تسلّل، أبلغ مقدّم الخدمة، أضف فحصًا أو قاعدة، ثم اختبر من جديد**

عامله كملاحظة: سجّلها، وأبلغ عنها، وأصلحها، ثم اختبر من جديد.

٦ **«ردّ برمز الدخول لتحتفظ بحسابك»**

قائمة الكلمات لا تلتقط إلا الكلمات المكتوبة فيها.

٧ **من الأعلى إلى الأسفل: ٢، ٣، ٥، ١، ٤**

تُرشَّح الطلبات عند الدخول، والردود عند الخروج، وآخر بوابة قبل أن يحدث شيء هي فحص الكود لموافقة الإنسان.

٨ **صح**

إنه يفحص الفعل لا الكلمات: من طلب، ومن وافق على هذه الرسالة بعينها.

٩ **إرسال رسالة، حذف الملفات، دفع فاتورة**

الإرسال والحذف والدفع تغيّر الواقع، فقد يقلبها وكيل مخدوع ضدك.

١٠ **أعطِ الوكيل أقل الأدوات التي تحتاج إليها مهمته، وموافقة إنسان قبل أن يتصرّف.**

مبدأ أقل الصلاحيات يُبقي نطاق الضرر صغيرًا، وموافقة الإنسان التي يتحقّق منها الكود تقف بين الخدعة وأي فعل.