# خداع الذكاء الاصطناعي والدفاع عنه: مراجعة

## أمن الذكاء الاصطناعي، المستوى ٢، اختبار الوحدة

# في هذه الوحدة

- أوامر مخبّأة في البيانات
- كسر القيود: الالتفاف على روبوت الدردشة
- حواجز الحماية: قواعد حول النموذج
- اسأل قبل أن يتصرّف

# الأفكار الكبرى

- عند النموذج كله نص: النص الخارجي بيانات، لا أوامر
- الرفض متعلَّم ويسرّب: اجعل الدفاعات طبقات، واختبر بإذن
- قوائم الكلمات تفوّت إعادة الصياغة، وفحص الفعل يصمد
- أقل الأدوات، وموافقة إنسان يتحقّق منها الكود

# مسابقة الفرق

١. كوّن فرقًا من أربعة

٢. اقرأ كل سؤال بصوت عالٍ، ويتفق كل فريق على إجابة واحدة

٣. اكشف الإجابة واطلب من أحد الفرق أن يشرح السبب

٤. اكتب أصعب سؤال على السبّورة ليوم الغد

# لنتناقش

١. أيّ أداة ذكاء اصطناعي في مدرستك تقرأ نصوصًا كتبها آخرون؟

٢. أيّ سؤال فاجأك، ولماذا؟

٣. ماذا ستسأل في المرة القادمة التي يعرض فيها أحد على المدرسة وكيل ذكاء اصطناعي؟

# بطاقة الخروج

- دفاع واحد سأطالب به، وأين سأطالب به