البيانات المسمَّمة

أمن الذكاء الاصطناعي، المستوى ٣، الدرس ١

سنتعلّم اليوم

- نشرح كيف تُفسد البياناتُ المسمَّمة والأبوابُ الخلفية النموذج.
- نجد الأمثلة البعيدة عن وسيط مجموعتها.
- نخطّط لفحوص قبل دخول بيانات جديدة إلى التدريب.

تذكّر

- أمثلة خاطئة تدخل، ونموذج خاطئ يخرج: لا يحتاج المهاجم إلا إلى البيانات.
- الوسيط بالكاد يتحرّك لقيمة خاطئة واحدة: أشِر إلى ما يبعد عنه.
- افحص قبل أن تحذف، وسجّل ما حذفته، واحتفظ بمجموعة اختبار نظيفة.

ابحث عن السمّ

١. التمهيد (٥ دقائق): كيف تعلّم آلة أن تفرّق بين المانجو والليمون؟

٢. القياس (١٠ دقائق): قيسوا عيّنات من نوعين وصنّفوها.

٣. التسميم (٥ دقائق): بدّل ثلاث تسميات سرًّا.

٤. البحث (١٥ دقيقة): جدوا وسيط كل نوع وأشيروا إلى القيم البعيدة.

٥. الختام (٥ دقائق): ما كُشف وما فات والإشارات الصادقة، ثم بطاقة الخروج.

لا ميزان لديك؟ استخدم أطوال أوراق أو أعواد تُقاس بالمسطرة، أو اطبع جدولًا من ١٥ قياسًا. واختر نوعين لا تتداخل قيمهما كثيرًا، لتظهر التسميات المبدَّلة.

لنتناقش

١. لماذا قد يغيّر السمّ النموذج مع أن أحدًا لم يلمسه؟

٢. أيّ العيّنات الصادقة أُشير إليها، ولماذا؟

٣. ما القواعد التي تُبقي بيانات صفّنا نظيفة؟

بطاقة الخروج

- اكتب طريقة يدخل بها السمّ إلى البيانات، وفحصًا واحدًا يكشفه.