نماذج تحفظ أكثر من اللازم

أمن الذكاء الاصطناعي، المستوى ٣، الدرس ٢

سنتعلّم اليوم

- نشرح الحفظ في النماذج واستنتاج العضوية.
- نحذف المعرِّفات من النص قبل استخدامه.
- نوازن بين الخصوصية والفائدة، ونطرح الأسئلة الصحيحة.

تذكّر

- قد تُحفظ التفاصيل النادرة وتتكرّر حرفًا بحرف.
- حين تدرّب البياناتُ نموذجًا يصعب إخراجها منه.
- أبقِها خارجًا، واحجب ما لا بد من إدخاله، واختبر بالكناري.

اطمسها

١. التمهيد (٥ دقائق): ماذا قد يخبر سجلّ الصف غريبًا؟

٢. الشرح (٨ دقائق): كيف تحفظ النماذج؛ وما المعرِّفات.

٣. اطمسها (١٢ دقيقة): تحذف المجموعات كل المعرِّفات.

٤. التبادل والفحص (٨ دقائق): ابحثوا عمّا فات المجموعة الأخرى.

٥. الختام (٧ دقائق): اتفقوا على قاعدة، ثم بطاقة الخروج.

استخدم أسماء وأرقامًا خيالية فقط. ولا تستخدم سجلًّا حقيقيًا أبدًا. وأخفِ تفصيلين أو ثلاثة نادرة («التلميذ الوحيد الذي يأتي مشيًا من قرية النهر») ليتعلّم الطلاب أن المعرِّفات ليست الأسماء والأرقام فقط.

لنتناقش

١. أيّ المعرِّفات كان الأصعب اكتشافًا، ولماذا؟

٢. لماذا لا يكفي حذف الملف بعد أن يتعلّم منه النموذج؟

٣. متى يستحق الأمر جعل النموذج أقل فائدة لحماية الخصوصية؟

بطاقة الخروج

- اكتب ثلاثة أنواع من المعرِّفات، وسؤالًا واحدًا تطرحه قبل إرسال أي بيانات للطلاب إلى خدمة ذكاء اصطناعي.