خطة درس — للمعلم

صور تخدع النموذج

أمن الذكاء الاصطناعي، المستوى ٣، الدرس ٣

المدة
٤٠ دقيقة

المواد
مجموعة رسومات بسيطة على بطاقات (دوائر وعلامات ضرب وخطوط)، أو ورق لرسمها، قاعدة تصنيف سرّية مكتوبة على بطاقة مطوية، السبّورة والطباشير

أهداف التعلّم

- نشرح كيف تخدع تغييراتٌ صغيرة مختارة النموذج.
- نختبر هشاشة إجابة بدفعات صغيرة.
- نقرّر أين يجب أن يراجع إنسان إجابة النموذج.

النشاط: اخدع المصنِّف

١. التمهيد (٥ دقائق): اسأل الطلاب كيف يفرّقون بين البقرة والماعز. ثم اسأل: ماذا لو لم تروا الأبقار إلا على العشب؟ وقدّم فكرة الاختصار.

٢. الشرح (٨ دقائق): وضّح أن نماذج الذكاء الاصطناعي تتعلّم اختصارات أيضًا، وأن تغييرًا صغيرًا مختارًا قد يقلب إجابتها بينما لا يرى الناس فرقًا. واذكر مثالًا: ملصقات على لافتة طريق.

٣. اخدع المصنِّف (١٥ دقيقة): يلعب أحد الطلاب دور «النموذج» ببطاقة القاعدة السرّية ويصنّف رسومات الفصل. وتبحث المجموعات عن أصغر تغيير يقلب إجابته دون أن يتغيّر شكل الرسمة في أعين الناس.

٤. قوِّها (٧ دقائق): اكشف القاعدة. وتعيد المجموعات كتابتها لتصبح أصعب خداعًا (مثلًا: انظر إلى الشكل كله، لا إلى زاوية واحدة)، ثم تختبرها من جديد.

٥. الختام (٥ دقائق): اسأل: أين يجب أن يراجع إنسان إجابة الآلة دائمًا؟ الدرجات، والصحة، والمال، والسلامة. ثم وزّع بطاقة الخروج.

اجعل القاعدة السرّية تعتمد على تفصيل صغير (نقطة في زاوية، أو خط أطول قليلًا)، كما تتعلّق النماذج بتفاصيل صغيرة. وأبقِ الرسومات بسيطة لتستطيع كل مجموعة اللعب.

للنقاش

- لماذا خدع تغييرٌ صغير «نموذجنا» ولم يخدعنا؟
- إن كان النموذج متأكدًا بنسبة ٩٩٪، فهل نثق به؟ ومتى؟
- أين يجب أن تكون الكلمة الأخيرة لإنسان دائمًا؟

بطاقة الخروج

- اكتب موضعًا واحدًا لا يجب أن يحسم فيه جواب الذكاء الاصطناعي الأمر وحده، ومن يجب أن يراجعه.

جرّبها في المدرسة غدًا

العب مع طلابك «اخدع المصنِّف»: يصنّف أحد الطلاب رسومات بقاعدة سرّية، ويبحث الفصل عن أصغر تغيير يقلب الإجابة. ثم تحدّثوا عن جعل القاعدة أصعب خداعًا، ولماذا يجب أن يراجع إنسان الإجابات المهمة.

أسئلة للتدريب — لك

صور تخدع النموذج

أمن الذكاء الاصطناعي، المستوى ٣، الدرس ٣

١ **تخطّط مدرسة لتسجيل الحضور بكاميرا للتعرّف على الوجوه دون أي شيء آخر. ما الخطة الأكثر أمانًا؟**

○ ارفع إعداد الثقة فيها ○ ثق بالكاميرا: إنها دقيقة جدًا ○ استخدمها مساعدًا، مع إنسان يراجع وطريقة أخرى للتسجيل

٢ **تقول label(score) «sick» من 0.5 فما فوق. أكمل fragile(score, eps): تكون True حين يعطي دفع الدرجة إلى الأسفل بمقدار eps وإلى الأعلى بمقدار eps تصنيفين مختلفين.**

```
def label(score):
    if score >= 0.5:
        return "sick"
    return "healthy"

def fragile(score, eps):
    # True if a nudge of eps either way
    # changes the label
    return False

print(fragile(0.52, 0.05))
print(fragile(0.90, 0.05))
```

اكتب برنامجك:

٣ **أكمل البرنامج ليعدّ كم إجابة من إجابات النموذج هشّة.**

```
scores = [0.91, 0.52, 0.08, 0.47, 0.66]
flips = 0
for s in scores:
    if _____(s, 0.05):
        flips = flips + 1
print(flips, "of", _____(scores))
```

بنك الكلمات: `label` `fragile` `max` `len`

٤ **أيّ مما يلي أمثلة خادعة، أي غُيّرت عن قصد لخداع نموذج؟ اختر كل ما ينطبق.**

☐ ملصقات توضع على لافتة طريق كي يخطئ قارئ اللافتات ☐ صوت لا يكاد الناس يسمعونه يوجّه مساعدًا صوتيًا

☐ حروف قليلة مبدَّلة كي يمرّ احتيال من مرشّح ☐ صورة ضبابية التُقطت تحت المطر

٥ **بعد التدريب على الأمثلة الخادعة، لم يعد ممكنًا خداع النموذج.**

○ صح ○ خطأ

✎ **أين يحسم جواب ذكاء اصطناعي أمرًا في مدرستك، أو في حياة طلابك؟ ماذا سيحدث لو أمكن خداعه، ومن يراجعه؟**

تحقّق من إجاباتك

صور تخدع النموذج

١ **استخدمها مساعدًا، مع إنسان يراجع وطريقة أخرى للتسجيل**

حتى النموذج الدقيق قد يُخدَع أو يخطئ ببساطة مع بعض الطلاب.

٢

```
def label(score):
    if score >= 0.5:
        return "sick"
    return "healthy"

def fragile(score, eps):
    a = label(score - eps)
    b = label(score + eps)
    return a != b

print(fragile(0.52, 0.05))
print(fragile(0.90, 0.05))
```

إذا اختلف التصنيف قليلًا تحت الدرجة عنه قليلًا فوقها، فالإجابة على حدّ السكين: يستطيع المهاجم، أو مجرد ضجيج، أن يقلبها.

٣

```
scores = [0.91, 0.52, 0.08, 0.47, 0.66]
flips = 0
for s in scores:
    if fragile(s, 0.05):
        flips = flips + 1
print(flips, "of", len(scores))
```

تختبر fragile(s, 0.05) كل درجة، وlen(scores) عددها.

٤ **ملصقات توضع على لافتة طريق كي يخطئ قارئ اللافتات، حروف قليلة مبدَّلة كي يمرّ احتيال من مرشّح، صوت لا يكاد الناس يسمعونه يوجّه مساعدًا صوتيًا**

الملصقات والحروف المبدَّلة والأصوات الخفية اختيرت عن قصد لخداع النموذج.

٥ **خطأ**

يجعل التدريب على الأمثلة الخادعة خداعَ النموذج أصعب (ففي المختبر تنخفض الهجمات من نحو ١٤ من ١٨ إلى نحو ٧ من ١٨)، لكنه لا يجعله مستحيلًا.