صور تخدع النموذج

أمن الذكاء الاصطناعي، المستوى ٣، الدرس ٣

سنتعلّم اليوم

- نشرح كيف تخدع تغييراتٌ صغيرة مختارة النموذج.
- نختبر هشاشة إجابة بدفعات صغيرة.
- نقرّر أين يجب أن يراجع إنسان إجابة النموذج.

تذكّر

- الأمثلة الخادعة: غُيّرت عن قصد، لا نراها، ويخطئ فيها النموذج.
- قد يكون النموذج متأكدًا ومخطئًا: فالثقة ليست ضمانًا.
- درّبه على المقاومة، واختبره، وأبقِ إنسانًا يقرّر ما هو مهم.

اخدع المصنِّف

١. التمهيد (٥ دقائق): كيف تفرّق بين البقرة والماعز؟

٢. الشرح (٨ دقائق): الاختصارات، والتغييرات الصغيرة التي تخدع النماذج.

٣. اخدع المصنِّف (١٥ دقيقة): جِدوا أصغر تغيير يقلب الإجابة.

٤. قوِّها (٧ دقائق): أعيدوا كتابة القاعدة واختبروها من جديد.

٥. الختام (٥ دقائق): أين يجب أن يراجع إنسان؟ ثم بطاقة الخروج.

اجعل القاعدة السرّية تعتمد على تفصيل صغير (نقطة في زاوية، أو خط أطول قليلًا)، كما تتعلّق النماذج بتفاصيل صغيرة. وأبقِ الرسومات بسيطة لتستطيع كل مجموعة اللعب.

لنتناقش

١. لماذا خدع تغييرٌ صغير «نموذجنا» ولم يخدعنا؟

٢. إن كان النموذج متأكدًا بنسبة ٩٩٪، فهل نثق به؟ ومتى؟

٣. أين يجب أن تكون الكلمة الأخيرة لإنسان دائمًا؟

بطاقة الخروج

- اكتب موضعًا واحدًا لا يجب أن يحسم فيه جواب الذكاء الاصطناعي الأمر وحده، ومن يجب أن يراجعه.