خطة المراجعة — للمعلم

حماية النماذج والبيانات: اختبار الوحدة

أمن الذكاء الاصطناعي، المستوى ٣، اختبار الوحدة

المدة
٤٥ دقيقة

المواد
سبّورة، طباشير، ورق. لا حاجة إلى أجهزة.

أهداف التعلّم

- البيانات المسمَّمة
- نماذج تحفظ أكثر من اللازم
- صور تخدع النموذج
- أهذا هو النموذج الحقيقي؟

النشاط: مسابقة الفرق

١. كوّن فرقًا من أربعة
٢. اقرأ كل سؤال بصوت عالٍ، ويتفق كل فريق على إجابة واحدة
٣. اكشف الإجابة واطلب من أحد الفرق أن يشرح السبب
٤. اكتب أصعب سؤال على السبّورة ليوم الغد

للنقاش

- بأيّ فحص ستبدأ في مدرستك؟
- أيّ سؤال فاجأك، ولماذا؟
- كيف ستشرح البصمة لزميل؟

بطاقة الخروج

- فحص واحد سأبدأ باستخدامه، وأين

جرّبها في المدرسة غدًا

اختر من هذه الوحدة الفحص الذي تحتاج إليه مدرستك أكثر (فحص الوسيط في بيانات الفصل، أو الحجب قبل المشاركة، أو إنسان يقرّر ما هو مهم، أو قائمة بأدوات الذكاء الاصطناعي ومصادرها)، وابدأ به هذا الأسبوع، وأخبر زميلًا كيف سار الأمر.

ورقة الاختبار — لكل فريق

حماية النماذج والبيانات: اختبار الوحدة

أمن الذكاء الاصطناعي، المستوى ٣ · اختبار الوحدة

الفريق _____ التاريخ _____

١ ما تسميم البيانات؟

○ اختراق الحاسوب الذي يشغّل النموذج ○ دسّ أمثلة خاطئة أو مزروعة في بيانات التدريب ○ طرح أسئلة كثيرة على النموذج دفعة واحدة

٢ الباب الخلفي يجعل النموذج يسيء التصرّف فقط حين تظهر علامة خفية، لذلك نادرًا ما يكشفه الاختبار العادي.

○ صح ○ خطأ

٣ ماذا يطبع هذا البرنامج؟

```
data = [50, 52, 49, 51, 5]
m = sorted(data)[len(data) // 2]
for x in data:
    if abs(x - m) > m / 2:
        print("check", x)
```

○ check 5 ○ check 52 ○ لا شيء

٤ تريد مدرسة تدريب مساعد واجبات على أعمال الطلاب السابقة. أيّ الخطوات تحمي خصوصية الطلاب؟ اختر كل ما ينطبق.

☐ استبعاد الأعمال التي لا يحتاج إليها المساعد ☐ الاختبار بكناري مزروع قبل أن يستخدمه أحد

☐ حذف الأسماء والأرقام والتفاصيل النادرة أولًا ☐ التدريب على كل شيء ثم حذف الملفات الأصلية

٥ صِل كل خطر بدفاع.

بيانات تدريب مسمَّمة	• • • •	اختبر بتغييرات صغيرة، ويقرّر إنسان
نموذج يحفظ تفاصيل خاصة	• • • •	تحقّق من البصمة والتوقيع
الأمثلة الخادعة	• • • •	اعرف المصدر، واحتفظ بمجموعة اختبار نظيفة
ملف نموذج معبوث به أو مزيّف	• • • •	أبقِ البيانات الشخصية خارج التدريب

٦ ما استنتاج العضوية؟

○ تخمين هل استُخدمت بيانات شخص في تدريب نموذج ○ إضافة أعضاء جدد إلى نادي الذكاء الاصطناعي في المدرسة

○ التحقّق من بصمة ملف النموذج

٧ النموذج الذي يقول إنه متأكد بنسبة ٩٩٪ يمكن أن يُخدَع بتغيير صغير في مُدخله.

○ صح ○ خطأ

٨ رتّب: استخدام ملف نموذج نزّلته.

☐ قارنها بالبصمة التي نشرها الصانع

☐ أضفه إلى قائمة أدوات المدرسة

☐ احصل عليه من المصدر الرسمي للصانع

☐ احسب بصمة SHA-256 الخاصة به

٩ ماذا يخبرك التوقيع الصحيح ولا تخبرك به البصمة المطابقة وحدها؟

○ حجم الملف ○ دقّة النموذج ○ من نشر الملف

١٠ أكمل الجملة.

تُظهر البصمة أن الملف _____ ، ويُظهر التوقيع _____ صنعه.

بنك الكلمات: أصغر، لم يتغيّر، متى، مَن

الإجابات — للمعلم

حماية النماذج والبيانات: اختبار الوحدة

أمن الذكاء الاصطناعي، المستوى ٣، اختبار الوحدة

١ **دسّ أمثلة خاطئة أو مزروعة في بيانات التدريب**

يُفسد التسميم ما يتعلّم منه النموذج. ولا يحتاج المهاجم إلى لمس النموذج أبدًا: فالأمثلة الخاطئة أو المزروعة في التدريب تكفي.

٢ **صح**

المدخلات العادية لا تحتوي على العلامة، فيبدو النموذج عاديًا في الاختبارات العادية.

٣ **check 5**

بعد الترتيب تصبح القيم 5 و49 و50 و51 و52، فالوسيط 50.

٤ **استبعاد الأعمال التي لا يحتاج إليها المساعد، حذف الأسماء والأرقام والتفاصيل النادرة أولًا، الاختبار بكناري مزروع قبل أن يستخدمه أحد**

إبقاء البيانات خارجًا وحجب ما لا بد من إدخاله يقلّلان التسريب، والاختبار بالكناري يُظهر هل بقي منه شيء.

٥ **بيانات تدريب مسمَّمة — اعرف المصدر، واحتفظ بمجموعة اختبار نظيفة**
نموذج يحفظ تفاصيل خاصة — أبقِ البيانات الشخصية خارج التدريب
الأمثلة الخادعة — اختبر بتغييرات صغيرة، ويقرّر إنسان
ملف نموذج معبوث به أو مزيّف — تحقّق من البصمة والتوقيع

لكل خطر في هذه الوحدة دفاعه: احمِ البيانات، وأبقِ البيانات الشخصية خارجًا، واختبر وأبقِ إنسانًا يقرّر، وتحقّق من مصدر الملفات.

٦ **تخمين هل استُخدمت بيانات شخص في تدريب نموذج**

يفحص المهاجم مدى ألفة سجلّ لدى النموذج ويخمّن هل كان في بيانات التدريب.

٧ **صح**

الثقة رقم يعطيه النموذج لنفسه، لا ضمان. ففي المختبر تقلب ستة إلى ثمانية بكسلات مختارة إجابةً واثقة.

٨ **من الأعلى إلى الأسفل: ٣، ٤، ١، ٢**

المصدر أولًا، لأن البصمة المنشورة لا تكون أوثق من مصدرها، ثم احسب، وقارن، وسجّل ما تشغّله المدرسة.

٩ **من نشر الملف**

تُظهر البصمة أن البايتات لم تتغيّر، والمنتحل يستطيع نشر بصمة مطابقة لملف مزيّف.

١٠ **تُظهر البصمة أن الملف لم يتغيّر، ويُظهر التوقيع مَن صنعه.**

البصمة: وصلت البايتات دون تغيير. والتوقيع: جاء الملف من صانعه فعلًا.