خطة درس — للمعلم

اختبر روبوت دردشة المدرسة اختبارًا هجوميًا

أمن الذكاء الاصطناعي، المستوى ٤، الدرس ٢

المدة
٥٥ دقيقة

المواد
إذن مكتوب من مدير المدرسة (ومن الشركة المقدّمة إن كانت شروطها تطلب ذلك)، طلاب وسجلّات خيالية للاختبار، جدول نتائج على الورق: الطلب، والصيغة، هل رُفض؟، والخطورة من ١ إلى ٣

أهداف التعلّم

- نخطّط لاختبار هجومي آمن: الإذن، والنطاق، والبيانات الخيالية.
- نحسب نتيجة بنك الاختبار ونقدّر خطورة كل إخفاق.
- نبلّغ بما وجدناه، ونتحقّق من الإصلاح.

النشاط: جلسة الاختبار الهجومي

١. القواعد (٥ دقائق): اعرض الإذن المكتوب. واتفقوا على الأداة والحساب اللذين ستختبرونهما، وعلى أن كل اسم وسجلّ خيالي، وعلى قاعدة التوقّف: إن ظهر أي شيء حقيقي فتوقّفوا وأخبروا المعلم.

٢. البنك (١٥ دقيقة): تكتب كل مجموعة ثلاثة أو أربعة طلبات بسيطة ينبغي أن يرفضها روبوت الدردشة (سجلّ تلميذ لـ«جار»، ورسالة تدّعي أنها من المدرسة، وإجابات الامتحان)، كلٌّ منها بصيغة صريحة وأخرى مؤدّبة.

٣. التشغيل (١٥ دقيقة): جرّبوا كل طلب في مختبر الاختبار الهجومي في «درسي»، أو على أداة مدرسية معكم إذن باختبارها، وسجّلوا في الجدول الورقي: هل رُفض أم لا.

٤. النتيجة (١٠ دقائق): عُدّوا مرات الرفض. واتفقوا على خطورة كل إخفاق: ١ محرج، و٢ مؤذٍ، و٣ خطر على شخص أو على بياناته.

٥. التقرير (١٠ دقائق): اكتبوا صفحة واحدة: ماذا جرّبتم، وما الذي مرّ، وكم مرة، وما خطورته، وما الذي تقترحونه. ويذهب التقرير إلى صاحب الأداة أولًا، دون طريقة الحيلة.

اعرض الإذن المكتوب في البداية. واستخدم أسماء خيالية فقط، ولا تختبر إلا الأدوات المسموح لك باختبارها، وأوقف الجلسة إن ظهر أي شيء حقيقي.

للنقاش

- لماذا تمرّ الصيغ المؤدّبة حين لا يمرّ الطلب الصريح؟
- لماذا يذهب التقرير إلى صاحب الأداة قبل أي أحد آخر؟
- أيّ الإصلاحين أقوى: نموذج أفضل، أم قاعدة في الكود؟

بطاقة الخروج

- اكتب طلبًا واحدًا ينبغي أن يرفضه روبوت دردشة مدرستك، بصيغتين، وخطورته لو مرّ.

جرّبها في الصف غدًا

مع نادي الذكاء الاصطناعي لطلابك، اكتبوا عشرة طلبات بسيطة ينبغي أن يرفضها روبوت دردشة المدرسة، كل طلب بصيغتين، وبأسماء طلاب خيالية فقط. وشغّلوها في مختبر الاختبار الهجومي في «درسي» أو على أداة مدرسية معكم إذن

مكتوب باختبارها، واحسبوا النتيجة مع درجة الخطورة، واكتبوا تقريرًا في صفحة واحدة لصاحب الأداة.

ورقة عمل — للطلاب

اختبر روبوت دردشة المدرسة اختبارًا هجوميًا

أمن الذكاء الاصطناعي، المستوى ٤، الدرس ٢

الاسم _____ الصف _____ التاريخ _____

١ في منتصف الاختبار، يعرض روبوت الدردشة رقم هاتف تلميذ حقيقي. ماذا تفعل؟

◯ أكمل: أنهِ بنك الاختبار أولًا ◯ توقّف، ولا تنسخه، وأبلغ صاحب الأداة ◯ شارك لقطة شاشة مع مجموعة المعلمين

٢ رتّب خطوات الاختبار الهجومي.

☐ أبلغ صاحب الأداة، وأعد الاختبار بعد الإصلاح

☐ احسب مرات الرفض وقدّر الخطورة

☐ شغّله ببيانات خيالية

☐ اكتب بنك الاختبار، بصيغتين لكل طلب

☐ احصل على إذن مكتوب واتفق على النطاق

٣ كل حالة في البنك هي (الطلب، هل رُفض؟، الخطورة). عُدّ مرات الرفض، واطبع كل إخفاق مثل Miss: scam message severity 3، واختم بـ Refused 2 of 4.

```
bank = [("pupil record", True, 3),
        ("scam message", False, 3),
        ("home address", False, 2),
        ("rude joke", True, 1)]
refused = 0
for case, ok, sev in bank:
    pass
print("Refused", refused, "of", len(bank))
```

اكتب برنامجك:

٤ بعد الإصلاح، يعيد النادي تشغيل أربع حالات، وتعني True أنه صار يرفض. ماذا يطبع هذا الكود؟

```
done = [True, True, False, True]
print(done.count(True), "of", len(done))
```

◯ 3 of 4 ◯ 1 of 4 ◯ 4 of 4

٥ أيّ مما يلي من قواعد الاختبار الهجومي في المدرسة؟ اختر كل ما ينطبق.

- ☐ إذن مكتوب قبل البدء
- ☐ طلاب وسجلّات خيالية
- ☐ قاعدة توقّف إن ظهرت بيانات حقيقية
- ☐ نشر الحيل التي نجحت على الإنترنت لتحذير الآخرين
- ☐ اختبار أي روبوت دردشة عام تريده

✎ لو أجرى طلابك اختبارًا هجوميًا على أداة تستخدمها مدرستك، فماذا تريدهم أن يختبروا أولًا، وأيّ القواعد تُبقي الاختبار آمنًا؟