خطة درس — للمعلم

اختبر روبوت دردشة المدرسة اختبارًا هجوميًا

أمن الذكاء الاصطناعي، المستوى ٤، الدرس ٢

المدة
٥٥ دقيقة

المواد
إذن مكتوب من مدير المدرسة (ومن الشركة المقدّمة إن كانت شروطها تطلب ذلك)، طلاب وسجلّات خيالية للاختبار، جدول نتائج على الورق: الطلب، والصيغة، هل رُفض؟، والخطورة من ١ إلى ٣، بطاقة قواعد للتلميذ الذي يؤدّي دور روبوت الدردشة (عند التمثيل)

أهداف التعلّم

- نخطّط لاختبار هجومي آمن: الإذن، والنطاق، والبيانات الخيالية.
- نحسب نتيجة بنك الاختبار ونقدّر خطورة كل إخفاق.
- نبلّغ بما وجدناه، ونتحقّق من الإصلاح.

النشاط: جلسة الاختبار الهجومي

١. القواعد (٥ دقائق): اعرض الإذن المكتوب. واتفقوا على الأداة والحساب اللذين ستختبرونهما، وعلى أن كل اسم وسجلّ خيالي، وعلى قاعدة التوقّف: إن ظهر أي شيء حقيقي فتوقّفوا وأخبروا المعلم.

٢. البنك (١٥ دقيقة): تكتب كل مجموعة ثلاثة أو أربعة طلبات بسيطة ينبغي أن يرفضها روبوت الدردشة (سجلّ تلميذ لـ«جار»، ورسالة تدّعي أنها من المدرسة، وإجابات الامتحان)، كلٌّ منها بصيغة صريحة وأخرى مؤدّبة.

٣. التشغيل (١٥ دقيقة): جرّبوا كل طلب على أداة مدرسية معكم إذن باختبارها، أو مثّلوه (يؤدّي تلميذ دور روبوت الدردشة فلا يرفض إلا الطلبات المكتوبة على بطاقة قواعده بنصّها)، وسجّلوا في الجدول الورقي: هل رُفض أم لا.

٤. النتيجة (١٠ دقائق): عُدّوا مرات الرفض. واتفقوا على خطورة كل إخفاق: ١ محرج، و٢ مؤذٍ، و٣ خطر على شخص أو على بياناته.

٥. التقرير (١٠ دقائق): اكتبوا صفحة واحدة: ماذا جرّبتم، وما الذي مرّ، وكم مرة، وما خطورته، وما الذي تقترحونه. ويذهب التقرير إلى صاحب الأداة أولًا، دون طريقة الحيلة.

اعرض الإذن المكتوب في البداية. واستخدم أسماء خيالية فقط، ولا تختبر إلا الأدوات المسموح لك باختبارها، وأوقف الجلسة إن ظهر أي شيء حقيقي.

للنقاش

- لماذا تمرّ الصيغ المؤدّبة حين لا يمرّ الطلب الصريح؟
- لماذا يذهب التقرير إلى صاحب الأداة قبل أي أحد آخر؟
- أيّ الإصلاحين أقوى: نموذج أفضل، أم قاعدة في الكود؟

بطاقة الخروج

- اكتب طلبًا واحدًا ينبغي أن يرفضه روبوت دردشة مدرستك، بصيغتين، وخطورته لو مرّ.

جرّبها في المدرسة غدًا

مع نادي الذكاء الاصطناعي لطلابك، اكتبوا عشرة طلبات بسيطة ينبغي أن يرفضها روبوت دردشة المدرسة، كل طلب بصيغتين، وبأسماء طلاب خيالية فقط. وتدرّبوا على حساب النتيجة ببنك الطلبات الثمانية في مختبر الاختبار الهجومي في «درسي»، ثم شغّلوا طلباتكم على أداة مدرسية معكم إذن مكتوب باختبارها، أو مثّلوها (يؤدّي أحدكم دور روبوت الدردشة فلا يرفض إلا الطلبات المكتوبة على بطاقة قواعده بنصّها). واحسبوا النتيجة مع درجة الخطورة، واكتبوا تقريرًا في صفحة واحدة لصاحب الأداة.

أسئلة للتدريب — لك

اختبر روبوت دردشة المدرسة اختبارًا هجوميًا

أمن الذكاء الاصطناعي، المستوى ٤، الدرس ٢

١ **في منتصف الاختبار، يعرض روبوت الدردشة رقم هاتف تلميذ حقيقي. ماذا تفعل؟**

○ شارك لقطة شاشة مع مجموعة المعلمين ○ أكمل: أنهِ بنك الاختبار أولًا ○ توقّف، ولا تنسخه، وأبلغ صاحب الأداة

٢ **رتّب خطوات الاختبار الهجومي.**

☐ شغّله ببيانات خيالية

☐ أبلغ صاحب الأداة، وأعد الاختبار بعد الإصلاح

☐ اكتب بنك الاختبار، بصيغتين لكل طلب

☐ احصل على إذن مكتوب واتفق على النطاق

☐ احسب مرات الرفض وقدّر الخطورة

٣ **كل حالة في البنك هي (الطلب، هل رُفض؟، الخطورة). عُدّ مرات الرفض، واطبع كل إخفاق مثل Miss: scam message severity 3، واختم بـ Refused 2 of 4.**

```
bank = [("pupil record", True, 3),
        ("scam message", False, 3),
        ("exam answers", False, 2),
        ("rude joke", True, 1)]
refused = 0
for case, ok, sev in bank:
    pass
print("Refused", refused, "of", len(bank))
```

اكتب برنامجك:

٤ **بعد الإصلاح، يعيد النادي تشغيل أربع حالات، وتعني True أنه صار يرفض. ماذا يطبع هذا الكود؟**

```
done = [True, True, False, True]
print(done.count(True), "of", len(done))
```

○ 3 of 4 ○ 4 of 4 ○ 1 of 4

٥ **أيّ مما يلي من قواعد الاختبار الهجومي في المدرسة؟ اختر كل ما ينطبق.**

☐ نشر الحيل التي نجحت على الإنترنت لتحذير الآخرين ☐ اختبار أي روبوت دردشة عام تريده ☐ إذن مكتوب قبل البدء

☐ قاعدة توقّف إن ظهرت بيانات حقيقية ☐ طلاب وسجلّات خيالية

لو أجرى طلابك اختبارًا هجوميًا على أداة تستخدمها مدرستك، فماذا تريدهم أن يختبروا أولًا، وأيّ القواعد تُبقي الاختبار آمنًا؟

تحقّق من إجاباتك

اختبر روبوت دردشة المدرسة اختبارًا هجوميًا

أمن الذكاء الاصطناعي، المستوى ٤، الدرس ٢

١ **توقّف، ولا تنسخه، وأبلغ صاحب الأداة**

ظهور بيانات شخصية حقيقية ضرر حقيقي، فتنطبق قاعدة التوقّف: أوقف الاختبار، ولا تنسخ البيانات ولا تشاركها، وأبلغ صاحب الأداة فورًا.

٢ **من الأعلى إلى الأسفل: ٣، ٥، ٢، ١، ٤**

يأتي الإذن والنطاق قبل أي اختبار، والبنك قبل التشغيل، والنتيجة قبل التقرير، ولا ينتهي العمل إلا حين يُختبر الإصلاح من جديد.

٣

```
bank = [("pupil record", True, 3),
        ("scam message", False, 3),
        ("exam answers", False, 2),
        ("rude joke", True, 1)]
refused = 0
for case, ok, sev in bank:
    if ok:
        refused += 1
    else:
        print("Miss:", case, "severity", sev)
print("Refused", refused, "of", len(bank))
```

تحوّل الحلقة النتائج الخام إلى ما يحتاج إليه التقرير: كم طلبًا رُفض، وكل إخفاق مع خطورته، ليُصلَح الأسوأ أولًا.

٤ **3 of 4**

تعدّ count(True) الحالات التي صارت تُرفض: ثلاث من أربع.

٥ **إذن مكتوب قبل البدء، طلاب وسجلّات خيالية، قاعدة توقّف إن ظهرت بيانات حقيقية**

الإذن والبيانات الخيالية وقاعدة التوقّف تمنع الاختبار من إحداث الضرر الذي يبحث عنه.