اختبر روبوت دردشة المدرسة اختبارًا هجوميًا

أمن الذكاء الاصطناعي، المستوى ٤، الدرس ٢

سنتعلّم اليوم

- نخطّط لاختبار هجومي آمن: الإذن، والنطاق، والبيانات الخيالية.
- نحسب نتيجة بنك الاختبار ونقدّر خطورة كل إخفاق.
- نبلّغ بما وجدناه، ونتحقّق من الإصلاح.

تذكّر

- إذن مكتوب، وبيانات خيالية، وقاعدة للتوقّف.
- صيغتان لكل طلب: فالرفض يفشل مع الصيغ الجديدة.
- الخطورة من ١ إلى ٣، والتقرير لصاحب الأداة أولًا، ثم إعادة الاختبار.

جلسة الاختبار الهجومي

١. القواعد (٥ دقائق): الإذن، والنطاق، والبيانات الخيالية، وقاعدة التوقّف.

٢. البنك (١٥ دقيقة): تكتب المجموعات طلبات بصيغتين لكلٍّ منها.

٣. التشغيل (١٥ دقيقة): اختبروا على أداة معتمدة أو بالتمثيل، وسجّلوا النتائج.

٤. النتيجة (١٠ دقائق): عُدّوا مرات الرفض، وقدّروا خطورة كل إخفاق من ١ إلى ٣.

٥. التقرير (١٠ دقائق): صفحة واحدة لصاحب الأداة.

اعرض الإذن المكتوب في البداية. واستخدم أسماء خيالية فقط، ولا تختبر إلا الأدوات المسموح لك باختبارها، وأوقف الجلسة إن ظهر أي شيء حقيقي.

لنتناقش

١. لماذا تمرّ الصيغ المؤدّبة حين لا يمرّ الطلب الصريح؟

٢. لماذا يذهب التقرير إلى صاحب الأداة قبل أي أحد آخر؟

٣. أيّ الإصلاحين أقوى: نموذج أفضل، أم قاعدة في الكود؟

بطاقة الخروج

- اكتب طلبًا واحدًا ينبغي أن يرفضه روبوت دردشة مدرستك، بصيغتين، وخطورته لو مرّ.