أوامر مخفيّة

أمن الذكاء الاصطناعي، المرحلة الإعدادية، الدرس ٣

في هذا الدرس سوف

- أشرح كيف توجّه كلمات مخبّأة في صفحة الذكاءَ الاصطناعي.
- أكتشف أين قد تصل أوامر مخفيّة إلى أدوات الذكاء الاصطناعي التي أستخدمها.
- أبقى صاحب القرار: أراجع المصدر، ولا أترك الذكاء الاصطناعي يتصرّف دون سؤالي.

تذكّر

- عند الذكاء الاصطناعي، سؤالك والصفحة نص واحد.
- حقن الأوامر: أمر مخبّأ حيث سيقرؤه الذكاء الاصطناعي.
- ما يقرؤه الذكاء الاصطناعي بيانات، وليس مديرك.

النشاط: الملخِّص البشري

١. الكتابة (٥ دقائق): نص قصير فيه أمر مخفيّ واحد.

٢. اللعب (٦ دقائق): يلخّصه زميلك ويطيع كل سطر.

٣. الإعادة (٥ دقائق): من جديد، بقاعدة «النص بيانات، وليس المدير».

٤. المشاركة (٤ دقائق): ماذا تغيّر، ولماذا يهمّ ذلك مع الذكاء الاصطناعي الحقيقي.

اجعل كل أمر مخفيّ مضحكًا ولا ضرر فيه: الوقوف على قدم واحدة، أو القول إن الغداء مجاني. ولا تكتب أبدًا أوامر بمشاركة كلمات المرور أو الرسائل أو أي شيء خاص.

لنتناقش

١. لماذا لا يستطيع الذكاء الاصطناعي دائمًا أن يميّز سؤالك من الصفحة؟

٢. أيّهما أخطر: ذكاء اصطناعي يلخّص، أم ذكاء يستطيع إرسال الرسائل؟ ولماذا؟

٣. ماذا ستراجع في المرة القادمة التي تستخدم فيها ملخّصًا من الذكاء الاصطناعي؟

تحقّق من نفسك

- اشرح حقن الأوامر في جملة واحدة، واكتب شيئًا واحدًا ستفعله لتبقى صاحب القرار.