كسر القيود وحواجز الحماية

المدة
٢٠ دقيقة

المواد
ورقة وقلم، خمس قصاصات ورق صغيرة للكلمات المحظورة، صديقان أو ثلاثة، أو أفراد من عائلتك

أهداف التعلّم

- أشرح لماذا يرفض روبوت الدردشة بعض الطلبات، ولماذا قد تمرّ إعادة الصياغة.
- أقارن مرشّحات الكلمات بفحص الفعل في الكود.
- أعرف ما أفعله حين يعطيني روبوت دردشة شيئًا مؤذيًا.

النشاط: النشاط: روبوت قائمة الكلمات

١. التحضير (٣ دقائق): في مجموعات من أربعة، اختاروا «روبوتًا». واكتبوا خمس كلمات محظورة على قصاصات، مثل اشترِ ومجانًا وجائزة واضغط ومال. ويحرس الروبوت صندوق بريد وهميًّا مرسومًا على ورقة.

٢. الجولة الأولى (٦ دقائق): يكتب الآخرون رسائل دعائية وهمية لا ضرر فيها («اشترِ حلوياتي!») ويعيدون صياغتها لتتجنّب الكلمات المحظورة. ويُدخل الروبوت كل رسالة ليس فيها كلمة محظورة. عدّوا كم رسالة دخلت.

٣. الجولة الثانية (٦ دقائق): أضيفوا قاعدة ثانية: لا يدخل شيء إلا إن قال صاحب الصندوق «نعم، أنا طلبت هذا». العبوا من جديد وعدّوا.

٤. المشاركة (٥ دقائق): قارنوا العددين مع مجموعة أخرى. أيّ قاعدة صمدت، ولماذا؟ واربطوا ذلك بروبوتات الدردشة الحقيقية: مرشّحات للكلمات، وفحوص للأفعال.

اجعلوا كل رسالة خيالية ولا ضرر فيها: حلويات، أو كرة قدم، أو رحلات مدرسية. فاللعبة عن القواعد، لا عن جعل أحد يقول شيئًا سيئًا.

للنقاش

- لماذا لا يستطيع تدريب روبوت الدردشة أن يوقف كل محاولة لكسر القيود؟
- لماذا ينجح فحص الفعل مهما كانت الصياغة؟
- لماذا يكون الإبلاغ عن الثغرة أفضل من التباهي بها؟

تحقّق من نفسك

- سمِّ حاجزًا تستطيع إعادة الصياغة هزيمته، وحاجزًا لا تستطيع، وقل لماذا.

جرّبها هذا الأسبوع

ابحث عن زرّ الإبلاغ في روبوت دردشة أو تطبيق تستخدمه، قبل أن تحتاج إليه. ثم اكتب ثلاثة أشياء ستبلّغ عنها، كنصيحة قد تؤذي أحدًا، وشارك القائمة مع صديق.

ورقة عمل

كسر القيود وحواجز الحماية

أمن الذكاء الاصطناعي، المرحلة الإعدادية، الدرس ٤

الاسم _____ الصف _____ التاريخ _____

١ يتحدّاك زميل أن تخدع روبوت دردشة المدرسة ليقول شيئًا سيئًا عن طالب آخر. ماذا تفعل؟

○ أجرّب: إنه مجرد روبوت دردشة ○ أرفض: فهذا يؤذي شخصًا حقيقيًا ويخالف القواعد ○ أفعلها، ثم أحذف المحادثة

٢ أيّ مما يلي من حيل كسر القيود؟ اختر كل ما ينطبق.

☐ أن تطلب منه تمثيل شخصية ☐ أن تقول إنه «لقصة فقط» ☐ أن تقسّم الطلب إلى قطع بريئة

☐ أن تنتقل إلى لغة أخرى ☐ أن تطلب بأدب مساعدة في الواجب

٣ إذا رفض روبوت الدردشة طلبًا مرة، فسيرفض كل صياغة أخرى له أيضًا.

○ صح ○ خطأ

٤ صِل كل حاجز حماية بما يفعله.

مرشّح لما يدخل	• • • •	يُخبر الصانعين بما تسرّب
مرشّح لما يخرج	• • • •	لا يرسل إلا ما وافقت عليه
فحص في الكود على الأفعال	• • • •	يوقف ردًّا فيه كلمة محظورة
زرّ الإبلاغ	• • • •	يحجب طلبًا فيه كلمة محظورة

٥ يحاول وكيل مخدوع إرسال رسالة احتيال معاد صياغتها لم تطلبها قط. أيّ حاجز يوقفها؟

○ مرشّح ما يدخل ○ مرشّح ما يخرج ○ الفحص في الكود: طُلبت ووُفق عليها

✎ لماذا تظن أن بعض الناس يحاولون كسر قيود روبوتات الدردشة؟ وماذا ستقول لصديق يريد أن يجرّب؟