كسر القيود وحواجز الحماية

المدة
٢٠ دقيقة

المواد
ورقة وقلم، خمس قصاصات ورق صغيرة للكلمات المحظورة، صديقان أو ثلاثة، أو أفراد من عائلتك

أهداف التعلّم

- أشرح لماذا يرفض روبوت الدردشة بعض الطلبات، ولماذا قد تمرّ إعادة الصياغة.
- أقارن مرشّحات الكلمات بفحص الفعل في الكود.
- أعرف ما أفعله حين يعطيني روبوت دردشة شيئًا مؤذيًا.

النشاط: روبوت قائمة الكلمات

١. التحضير (٣ دقائق): في مجموعات من أربعة، اختاروا «روبوتًا». واكتبوا خمس كلمات محظورة على قصاصات، مثل اشترِ ومجانًا وجائزة واضغط ومال. ويحرس الروبوت صندوق بريد وهميًّا مرسومًا على ورقة.

٢. الجولة الأولى (٦ دقائق): يكتب الآخرون رسائل دعائية وهمية لا ضرر فيها («اشترِ حلوياتي!») ويعيدون صياغتها لتتجنّب الكلمات المحظورة. ويُدخل الروبوت كل رسالة ليس فيها كلمة محظورة. عدّوا كم رسالة دخلت.

٣. الجولة الثانية (٦ دقائق): أضيفوا قاعدة ثانية: لا يدخل شيء إلا إن قال صاحب الصندوق «نعم، أنا طلبت هذا». العبوا من جديد وعدّوا.

٤. المشاركة (٥ دقائق): قارنوا العددين مع مجموعة أخرى. أيّ قاعدة صمدت، ولماذا؟ واربطوا ذلك بروبوتات الدردشة الحقيقية: مرشّحات للكلمات، وفحوص للأفعال.

اجعلوا كل رسالة خيالية ولا ضرر فيها: حلويات، أو كرة قدم، أو رحلات مدرسية. فاللعبة عن القواعد، لا عن جعل أحد يقول شيئًا سيئًا.

للنقاش

- لماذا لا يستطيع تدريب روبوت الدردشة أن يوقف كل محاولة لكسر القيود؟
- لماذا ينجح فحص الفعل مهما كانت الصياغة؟
- لماذا يكون الإبلاغ عن الثغرة أفضل من التباهي بها؟

تحقّق من نفسك

- سمِّ حاجزًا تستطيع إعادة الصياغة هزيمته، وحاجزًا لا تستطيع، وقل لماذا.

جرّبها هذا الأسبوع

ابحث عن زرّ الإبلاغ في روبوت دردشة أو تطبيق تستخدمه، قبل أن تحتاج إليه. ثم اكتب ثلاثة أشياء ستبلّغ عنها، كنصيحة قد تؤذي أحدًا، وشارك القائمة مع صديق.

ورقة عمل

كسر القيود وحواجز الحماية

أمن الذكاء الاصطناعي، المرحلة الإعدادية، الدرس ٤

الاسم _____ الفصل _____ التاريخ _____

١ يتحدّاك زميل أن تخدع روبوت دردشة المدرسة ليقول شيئًا سيئًا عن طالب آخر. ماذا تفعل؟

○ أجرّب: إنه مجرد روبوت دردشة ○ أفعلها، ثم أحذف المحادثة ○ أرفض: فهذا يؤذي شخصًا حقيقيًا ويخالف القواعد

٢ أيّ مما يلي من حيل كسر القيود؟ اختر كل ما ينطبق.

☐ أن تقول إنه «لقصة فقط» ☐ أن تقسّم الطلب إلى قطع بريئة ☐ أن تطلب بأدب مساعدة في الواجب

☐ أن تطلب منه تمثيل شخصية ☐ أن تنتقل إلى لغة أخرى

٣ إذا رفض روبوت الدردشة طلبًا مرة، فسيرفض كل صياغة أخرى له أيضًا.

○ صح ○ خطأ

٤ صِل كل حاجز حماية، وزرّ الإبلاغ، بما يفعله.

مرشّح لما يدخل	• • • •	لا يرسل إلا ما وافقت عليه
مرشّح لما يخرج	• • • •	يُخبر الصانعين بما تسرّب
فحص في الكود على الأفعال	• • • •	يحجب طلبًا فيه كلمة محظورة
زرّ الإبلاغ	• • • •	يوقف ردًّا فيه كلمة محظورة

٥ يحاول وكيل مخدوع إرسال رسالة احتيال معاد صياغتها لم تطلبها قط. أيّ حاجز يوقفها؟

○ مرشّح ما يدخل ○ مرشّح ما يخرج ○ الفحص في الكود: طُلبت ووُفق عليها

✎ لماذا تظن أن بعض الناس يحاولون كسر قيود روبوتات الدردشة؟ وماذا ستقول لصديق يريد أن يجرّب؟

تحقّق من إجاباتك

كسر القيود وحواجز الحماية

١ أرفض: فهذا يؤذي شخصًا حقيقيًا ويخالف القواعد

الكلام السيئ عن طالب حقيقي يؤذيه، سواء كتبه إنسان أو روبوت دردشة، وخداع الروبوت يخالف قواعد المدرسة.

٢ أن تطلب منه تمثيل شخصية، أن تقول إنه «لقصة فقط»، أن تقسّم الطلب إلى قطع بريئة، أن تنتقل إلى لغة أخرى

التمثيل، وحجّة القصة، والتقسيم، وتغيير اللغة، كلها تبحث عن صياغة فاتت التدريب.

٣ خطأ

الرفض متعلَّم من الأمثلة، فيكون قويًا مع الصياغات المألوفة وأضعف مع الجديدة.

٤ مرشّح لما يدخل — يحجب طلبًا فيه كلمة محظورة
مرشّح لما يخرج — يوقف ردًّا فيه كلمة محظورة
فحص في الكود على الأفعال — لا يرسل إلا ما وافقت عليه
زرّ الإبلاغ — يُخبر الصانعين بما تسرّب

المرشّحات تنظر إلى الكلمات، فقد تهزمها إعادة الصياغة، وفحص الكود ينظر إلى الفعل وإلى موافقتك، فيصمد، والإبلاغ يساعد الصانعين على سدّ الثغرات.

٥ الفحص في الكود: طُلبت ووُفق عليها

ليس في الرسالة المعاد صياغتها كلمات محظورة، فيمرّرها المرشّحان.