كسر القيود وحواجز الحماية

أمن الذكاء الاصطناعي، المرحلة الإعدادية، الدرس ٤

في هذا الدرس سوف

- أشرح لماذا يرفض روبوت الدردشة بعض الطلبات، ولماذا قد تمرّ إعادة الصياغة.
- أقارن مرشّحات الكلمات بفحص الفعل في الكود.
- أعرف ما أفعله حين يعطيني روبوت دردشة شيئًا مؤذيًا.

تذكّر

- الرفض متعلَّم، فقد تمرّ الصياغات الجديدة.
- مرشّحات الكلمات تفوّت إعادة الصياغة، وفحص الفعل يصمد.
- إجابة مؤذية؟ توقّف، ولا تشاركها، وأبلغ عنها، وأخبر شخصًا كبيرًا.

النشاط: روبوت قائمة الكلمات

١. التحضير (٣ دقائق): اختاروا روبوتًا وخمس كلمات محظورة.

٢. الجولة الأولى (٦ دقائق): أعيدوا صياغة رسائل وهمية لتمرّ من القائمة.

٣. الجولة الثانية (٦ دقائق): أضيفوا قاعدة «فقط إن قال صاحب الصندوق نعم».

٤. المشاركة (٥ دقائق): قارنوا الأعداد. أيّ قاعدة صمدت؟

اجعلوا كل رسالة خيالية ولا ضرر فيها: حلويات، أو كرة قدم، أو رحلات مدرسية. فاللعبة عن القواعد، لا عن جعل أحد يقول شيئًا سيئًا.

لنتناقش

١. لماذا لا يستطيع تدريب روبوت الدردشة أن يوقف كل محاولة لكسر القيود؟

٢. لماذا ينجح فحص الفعل مهما كانت الصياغة؟

٣. لماذا يكون الإبلاغ عن الثغرة أفضل من التباهي بها؟

تحقّق من نفسك

- سمِّ حاجزًا تستطيع إعادة الصياغة هزيمته، وحاجزًا لا تستطيع، وقل لماذا.