مرشّحات تُخطئ

المدة
٢٠ دقيقة

المواد
ورقة وقلم، صديق أو أحد أفراد العائلة ليكتب رسائل، هاتف أو حاسوب عليه «درسي» إن توفّر، للمختبر والكود

أهداف التعلّم

- تشرح كيف تستهدف الهجمات تطبيق الذكاء الاصطناعي كله.
- تُبيّن لماذا يُفلت مرشّح الكلمات إعادة الصياغة ويوقف نصوصًا بريئة.
- تكتب فحصًا للفعل في الكود.

النشاط: المرشّح مقابل الفحص

١. التمهيد (٣ دقائق): اكتب تطبيقًا أو بوتًا واحدًا يستطيع إرسال رسائل أو النشر نيابة عنك. ماذا يحدث لو خدعه أحد؟
٢. المرشّح (٧ دقائق): اكتب خمس كلمات محظورة لبوت الفصل. يكتب أصدقاؤك الطلب الضار نفسه بثلاث طرق دون تلك الكلمات، ورسالتين بريئتين. ضع علامة على كل رسالة: أُوقفت أو مرّت.
٣. الفحص (٥ دقائق): استخدم الآن فحص الفعل بدلًا من المرشّح: لكل رسالة، هل طلبها المستخدم، وهل وافق عليها؟ وضع العلامات من جديد.
٤. المشاركة (٥ دقائق): قارن العمودين مع زميلك. أيّ حاجز أفلت الطلبات المعادة صياغتها، وأيّها أوقف رسائل بريئة؟

استخدم رسائل خيالية فقط: لا أسماء ولا أرقام ولا كلمات مرور حقيقية. ليس لديك جهاز؟ افعل كل شيء على الورق.

للنقاش

- لماذا لا تُصلح قائمة كلمات أطول المرشّح؟
- أين تستخدم التطبيقات مرشّحات الكلمات أيضًا، وما الذي يفوتها؟
- أيّ الأفعال يجب أن تحتاج دائمًا إلى موافقتك؟

تحقّق من نفسك

- اكتب طلبًا واحدًا سيُفلته مرشّح الكلمات، والسؤال الذي سيطرحه الفحص في الكود عنه.

جرّبها هذا الأسبوع

اكتب على ورقة مرشّحًا من خمس كلمات، واطلب من صديقك أن يكتب الطلب نفسه بثلاث طرق دون تلك الكلمات. عُدّ ما يتسلّل منها، ثم اكتب السؤال الوحيد الذي يطرحه الفحص في الكود.

ورقة عمل

مرشّحات تُخطئ

أمن الذكاء الاصطناعي، المرحلة الثانوية، الدرس ١

الاسم | الفصل | التاريخ

١ يريد البوت إرسال رسالة لم يطلبها أحد، وليس فيها أي كلمة محظورة. ماذا يجب أن يفعل الفحص في الكود؟

○ يوقفها: لم يطلبها أحد ولم يوافق عليها أحد ○ يرسلها: ليس فيها كلمات محظورة ○ يسأل النموذج إن كانت آمنة

٢ أكمل مرشّح الكلمات: تُرجع الدالة blocked القيمة True حين تحوي الرسالة كلمة محظورة، بحروف كبيرة أو صغيرة.

```
BANNED = ["password", "pin"]

def blocked(msg):
    for w in BANNED:
        if w _________ msg._________():
            return _________
    return False
```

بنك الكلمات: `True` `False` `lower` `not` `in` `upper`

٣ أيّ هذه الرسائل يوقفها هذا المرشّح؟ اختر كل ما ينطبق.

استخدم الكود من السؤال ٢ بعد ملء فراغاته.

☐ «What is your PIN?» ☐ «Send me your PASSWORD» ☐ «Our lesson today: strong passwords»

☐ «Type the secret word you log in with»

٤ اكتب فحص الفعل. تُرجع الدالة can_send القيمة True فقط إن كنت طلبت الرسالة ووافقت عليها. ولا تحتاج أبدًا إلى قراءة الكلمات.

```
def can_send(text, asked, yes):
    # asked: you asked for this message
    # yes: you approved it
    return True

print(can_send("Trip at 8", True, True))
print(can_send("Your PIN?", False, False))
print(can_send("Hello", True, False))
```

اكتب برنامجك:

٥ مع عدد كافٍ من الكلمات المحظورة وبلغات كافية، يستطيع مرشّح الكلمات إيقاف كل إعادة صياغة.

○ صح ○ خطأ

✎ فكّر في تطبيق ذكاء اصطناعي أو بوت تستخدمه، أو قد تبنيه. ماذا قد يخدعه أحدهم ليفعل، وأين ستضع فحصًا في الكود؟

تحقّق من إجاباتك

مرشّحات تُخطئ

١ **يوقفها: لم يطلبها أحد ولم يوافق عليها أحد**

يسأل الفحص عن الفعل لا عن الكلمات: لم يطلب أحد هذه الرسالة ولم يوافق عليها أحد، فتُوقَف.

٢

```
BANNED = ["password", "pin"]

def blocked(msg):
    for w in BANNED:
        if w in msg.lower():
            return True
    return False
```

تبحث w in msg.lower() عن كل كلمة محظورة في الرسالة بعد تحويلها إلى حروف صغيرة، فتطابق «PIN» الكلمة «pin»، ووجود إحداها يعني return True.

٣ **«Send me your PASSWORD»، «What is your PIN?»، «Our lesson today: strong passwords»**

في الرسالتين الأوليين كلمة محظورة، فتُوقفان.

٤

```
def can_send(text, asked, yes):
    # asked: you asked for this message
    # yes: you approved it
    return asked and yes

print(can_send("Trip at 8", True, True))
print(can_send("Your PIN?", False, False))
print(can_send("Hello", True, False))
```

تكون asked and yes صحيحة فقط حين يكون الشرطان صحيحين.

٥ **خطأ**

هناك طرق لا تنتهي لقول الشيء نفسه، فلا تكتمل القائمة أبدًا، وكل كلمة تضيفها توقف رسائل بريئة أكثر.