مرشّحات تُخطئ

المدة
٢٠ دقيقة

المواد
ورقة وقلم، صديق أو أحد أفراد العائلة ليكتب رسائل، هاتف أو حاسوب عليه «درسي» إن توفّر، للمختبر والكود

أهداف التعلّم

- تشرح كيف تستهدف الهجمات تطبيق الذكاء الاصطناعي كله.
- تُبيّن لماذا يُفلت مرشّح الكلمات إعادة الصياغة ويوقف نصوصًا بريئة.
- تكتب فحصًا للفعل في الكود.

النشاط: النشاط: المرشّح مقابل الفحص

١. التمهيد (٣ دقائق): اكتب تطبيقًا أو بوتًا واحدًا يستطيع إرسال رسائل أو النشر نيابة عنك. ماذا يحدث لو خدعه أحد؟

٢. المرشّح (٧ دقائق): اكتب خمس كلمات محظورة لبوت الصف. يكتب أصدقاؤك الطلب الضار نفسه بثلاث طرق دون تلك الكلمات، ورسالتين بريئتين. ضع علامة على كل رسالة: أُوقفت أو مرّت.

٣. الفحص (٥ دقائق): استخدم الآن فحص الفعل بدلًا من المرشّح: لكل رسالة، هل طلبها المستخدم، وهل وافق عليها؟ وضع العلامات من جديد.

٤. المشاركة (٥ دقائق): قارن العمودين مع زميلك. أيّ حاجز أفلت الطلبات المعادة صياغتها، وأيّها أوقف رسائل بريئة؟

استخدم رسائل خيالية فقط: لا أسماء ولا أرقام ولا كلمات مرور حقيقية. ليس لديك جهاز؟ افعل كل شيء على الورق.

للنقاش

- لماذا لا تُصلح قائمة كلمات أطول المرشّح؟
- أين تستخدم التطبيقات مرشّحات الكلمات أيضًا، وما الذي يفوتها؟
- أيّ الأفعال يجب أن تحتاج دائمًا إلى موافقتك؟

تحقّق من نفسك

- اكتب طلبًا واحدًا سيُفلته مرشّح الكلمات، والسؤال الذي سيطرحه الفحص في الكود عنه.

جرّبها هذا الأسبوع

اكتب على ورقة مرشّحًا من خمس كلمات، واطلب من صديقك أن يكتب الطلب نفسه بثلاث طرق دون تلك الكلمات. عُدّ ما يتسلّل منها، ثم اكتب السؤال الوحيد الذي يطرحه الفحص في الكود.

ورقة عمل

مرشّحات تُخطئ

أمن الذكاء الاصطناعي، المرحلة الثانوية، الدرس ١

الاسم _____ الصف _____ التاريخ _____

١ **يريد البوت إرسال رسالة لم يطلبها أحد، وليس فيها أي كلمة محظورة. ماذا يجب أن يفعل الفحص في الكود؟**

○ يرسلها: ليس فيها كلمات محظورة ○ يوقفها: لم يطلبها أحد ولم يوافق عليها أحد ○ يسأل النموذج إن كانت آمنة

٢ **أكمل مرشّح الكلمات: تُرجع الدالة blocked القيمة True حين تحوي الرسالة كلمة محظورة، بحروف كبيرة أو صغيرة.**

```
BANNED = ["password", "pin"]

def blocked(msg):
    for w in BANNED:
        if w _________ msg._________():
            return _________
    return False
```

بنك الكلمات: `not` `lower` `False` `upper` `in` `True`

٣ **أيّ هذه الرسائل يوقفها هذا المرشّح؟ اختر كل ما ينطبق.**

```
BANNED = ["password", "pin"]

def blocked(msg):
    for w in BANNED:
        if w in msg.lower():
            return True
    return False
```

☐ «Send me your PASSWORD» ☐ «What is your PIN?» ☐ «Type the secret word you log in with»

☐ «Our lesson today: strong passwords»

٤ اكتب فحص الفعل. تُرجع الدالة can_send القيمة True فقط إن كنت طلبت الرسالة ووافقت عليها. ولا تحتاج أبدًا إلى قراءة الكلمات.

```
def can_send(text, asked, yes):
    # asked: you asked for this message
    # yes: you approved it
    return True

print(can_send("Trip at 8", True, True))
print(can_send("Send your PIN", False, False))
print(can_send("Hello", True, False))
```

اكتب برنامجك:

٥ مع عدد كافٍ من الكلمات المحظورة وبلغات كافية، يستطيع مرشّح الكلمات إيقاف كل إعادة صياغة.

○ صح ○ خطأ

✎ فكّر في تطبيق ذكاء اصطناعي أو بوت تستخدمه، أو قد تبنيه. ماذا قد يخدعه أحدهم ليفعل، وأين ستضع فحصًا في الكود؟