مرشّحات تُخطئ

أمن الذكاء الاصطناعي، المرحلة الثانوية، الدرس ١

في هذا الدرس سوف

- تشرح كيف تستهدف الهجمات تطبيق الذكاء الاصطناعي كله.
- تُبيّن لماذا يُفلت مرشّح الكلمات إعادة الصياغة ويوقف نصوصًا بريئة.
- تكتب فحصًا للفعل في الكود.

تذكّر

- كسر القيود يقنع النموذج بالتجاوز، والحقن يخبّئ أوامر فيما يقرؤه.
- مرشّحات الكلمات تُفلت إعادة الصياغة وتوقف نصوصًا بريئة.
- افحص الفعل في الكود: هل طلبت؟ وهل وافقت؟

النشاط: المرشّح مقابل الفحص

١. التمهيد (٣ دقائق): سمِّ تطبيقًا يرسل رسائل نيابة عنك.

٢. المرشّح (٧ دقائق): اكتب خمس كلمات محظورة، ويعيد أصدقاؤك صياغة طلب.

٣. الفحص (٥ دقائق): مرّر الرسائل نفسها على «هل طُلبت؟ هل وُوفق عليها؟».

٤. المشاركة (٥ دقائق): قارن ما أوقفه كل حاجز.

استخدم رسائل خيالية فقط: لا أسماء ولا أرقام ولا كلمات مرور حقيقية. ليس لديك جهاز؟ افعل كل شيء على الورق.

لنتناقش

١. لماذا لا تُصلح قائمة كلمات أطول المرشّح؟

٢. أين تستخدم التطبيقات مرشّحات الكلمات أيضًا، وما الذي يفوتها؟

٣. أيّ الأفعال يجب أن تحتاج دائمًا إلى موافقتك؟

تحقّق من نفسك

- اكتب طلبًا واحدًا سيُفلته مرشّح الكلمات، والسؤال الذي سيطرحه الفحص في الكود عنه.