الأدوات اللازمة فقط

أمن الذكاء الاصطناعي، المرحلة الثانوية، الدرس ٢

في هذا الدرس سوف

- تميّز أدوات القراءة من أدوات الفعل.
- تعطي الوكيل أقل الأدوات، بقائمة سماح في الكود.
- تشترط موافقة إنسان قبل أن تعمل أي أداة فاعلة.

تذكّر

- أدوات القراءة قد تسرّب، وأدوات الفعل قد تُدار ضدّك.
- أقل الصلاحيات: أقل الأدوات، لأقصر وقت.
- قائمة سماح وموافقة إنسان، يتحقّق منهما الكود.

النشاط: خطة الصلاحيات

١. التمهيد (٣ دقائق): اكتب ما يستطيع فعله تطبيق واحد على هاتفك.

٢. التخطيط (٧ دقائق): اختر وكيلًا، واكتب أدواته، وصنّفها قراءة أو فعلًا.

٣. الهجوم (٥ دقائق): اختبر خطتك بثلاث نتائج مُتلاعَب بها.

٤. المشاركة (٥ دقائق): قارن نطاق الضرر مع زميلك.

لا تستخدم هاتف العائلة إلا مع صاحبه. والنتائج المُتلاعَب بها خيالية: اكتبها على الورق.

لنتناقش

١. لماذا أداة القراءة أكثر أمانًا من أداة الفعل؟

٢. لماذا يجب أن يتحقّق الكود من الموافقة، لا النموذج؟

٣. أيّ تطبيق على هاتفك يملك صلاحيات أكثر مما يحتاج؟

تحقّق من نفسك

- اكتب قائمة السماح لمهمة واحدة، وحدّد الأداة التي تحتاج إلى موافقة.