ملاحظات الدرس — لك

تحقّق قبل أن تثق بنموذج

أمن الذكاء الاصطناعي، المرحلة الثانوية، الدرس ٤

المدة
٢٠ دقيقة

المواد
ورقة وقلم، هاتف العائلة مع صاحبه، أو حاسوب ناديك، هاتف أو حاسوب عليه «درسي» إن توفّر، للمختبر والكود

أهداف التعلّم

- تشرح كيف يمكن مهاجمة سلسلة توريد الذكاء الاصطناعي.
- تحسب بصمة SHA-256 وتقارنها في بايثون.
- تشرح ما يضيفه التوقيع، وتحتفظ بقائمة نماذج.

النشاط: افحص السلسلة

١. التمهيد (٣ دقائق): فكّر في ثلاثة تطبيقات على هاتفك (أو هاتف العائلة بإذن صاحبه). واكتب من أين جاء كلٌّ منها: من المتجر الرسمي، أم من ملف أرسله أحد، أم من موقع.

٢. البصمة (٧ دقائق): في خطوة الكود في «درسي»، احسب بصمة b"leafnet v2" ثم بصمة b"leafnet v3"، وقارن بينهما. ليس لديك جهاز؟ اصنع بصمة ورقية: اجمع أرقام عدد طويل، ثم غيّر رقمًا واحدًا، ولاحظ تغيّر المجموع.

٣. القائمة (٥ دقائق): ابدأ قائمة نماذج من أربعة أعمدة: الاسم، والنسخة، والمصدر، وأول ثمانية أحرف من البصمة إن توفّرت.

٤. المشاركة (٥ دقائق): بادل قائمتك مع زميلك. أيّ بند ستحذفه أو تستبدله من المصدر الرسمي، ولماذا؟

لا تنظر في هاتف العائلة إلا مع صاحبه، ولا تثبّت أي شيء جديد في أثناء النشاط.

للنقاش

- لماذا لا تستطيع البصمة وحدها إثبات من صنع الملف؟
- لماذا النسخ «الاحترافية» المجانية المتداولة في المجموعات خطيرة إلى هذا الحد؟
- ماذا ستضع في قائمة نماذج عائلتك؟

تحقّق من نفسك

- اكتب الفحصين اللذين ستجريهما قبل تشغيل نموذج نزّلته، وما يُثبته كلٌّ منهما.

جرّبها هذا الأسبوع

مع صاحب الهاتف، انظر إلى تطبيقات الذكاء الاصطناعي على هاتف العائلة. واكتب لكل منها من أين جاء: من المتجر الرسمي، أم من ملف متداول، أم من موقع. واحذف أي ملف متداول لا تستطيع التحقّق منه، وابدأ قائمة النماذج الخاصة بك.

ورقة عمل

تحقّق قبل أن تثق بنموذج

أمن الذكاء الاصطناعي، المرحلة الثانوية، الدرس ٤

الاسم | الفصل | التاريخ

١ تطابقت بصمة نموذج مع البصمة المنشورة بجانبه، على موقع لا تعرفه. هل تثق به؟

○ ليس بعد: تحقّق من المصدر الرسمي ومن التوقيع ○ نعم: البصمة مطابقة ○ نعم، إن عمل دون أخطاء

٢ أكمل الدالة fp لتُرجع بصمة SHA-256 للبيانات في صورة ٦٤ حرفًا ست عشريًا.

```
import hashlib, binascii

def fp(data):
    h = hashlib._____(data).digest()
    return binascii._____(h).decode()
```

بنك الكلمات: `lower` `sha256` `digest` `md5` `hexlify`

٣ ماذا يطبع هذا البرنامج؟

هنا الكود من السؤال ٢ بعد ملء فراغاته.

```
a = fp(b"model")
b = fp(b"Model")
print(len(a), a == b)
```

○ 5 False ○ 64 False ○ 64 True

٤ يحتفظ ناديك بقائمة نماذج: اسم كل نموذج وبصمته المنشورة، في القاموس LIST، فـ LIST[name] هي بصمة ذلك النموذج. اكتب الدالة verify: أرجِع "unknown" إن لم يكن النموذج في القائمة، و"changed" إن لم تطابق بصمة الملف، و"ok" في غير ذلك.

هنا الكود من السؤال ٢ بعد ملء فراغاته.

```
LIST = {"leafnet": fp(b"leafnet v2")}
def verify(name, data):
    # "unknown", "changed" or "ok"
    return "ok"
print(verify("leafnet", b"leafnet v3"))
```

اكتب برنامجك:

٥ صِل كل خطر في سلسلة التوريد بالفحص الذي يكشفه.

نسخة مزيّفة من منتحل	فضّل الملفات التي لا تحوي إلا أرقامًا
ملف تغيّر في الطريق	احتفظ بقائمة النماذج
ملف يشغّل كودًا عند تحميله	تحقّق من توقيع الناشر
نسيان ما ثبّتّه	قارن البصمة

أيّ التطبيقات أو أدوات الذكاء الاصطناعي على هاتفك جاءت من ملف متداول أو من موقع، لا من المتجر الرسمي؟ وكيف تستطيع التحقّق منها؟

تحقّق من إجاباتك

تحقّق قبل أن تثق بنموذج

١ **ليس بعد: تحقّق من المصدر الرسمي ومن التوقيع**

لا معنى للبصمة إلا إن جاءت من الناشر الحقيقي.

٢

```
import hashlib, binascii

def fp(data):
    h = hashlib.sha256(data).digest()
    return binascii.hexlify(h).decode()
```

تحسب hashlib.sha256 البصمة المكوّنة من ٣٢ بايتًا، وتحوّل binascii.hexlify هذه البايتات إلى ٦٤ حرفًا ست عشريًا، وتجعلها ()decode. نصًا يمكنك مقارنته.

٣ **64 False**

طول كل بصمة SHA-256 هو ٦٤ حرفًا ست عشريًا، مهما قصرت البيانات.

٤

```
import hashlib, binascii
def fp(data):
    h = hashlib.sha256(data).digest()
    return binascii.hexlify(h).decode()
LIST = {"leafnet": fp(b"leafnet v2")}
def verify(name, data):
    if name not in LIST:
        return "unknown"
    if fp(data) != LIST[name]:
        return "changed"
    return "ok"
print(verify("leafnet", b"leafnet v3"))
```

النموذج الذي لم تُدرجه مجهول، فلا تشغّله.

٥ **نسخة مزيّفة من منتحل — تحقّق من توقيع الناشر**
ملف تغيّر في الطريق — قارن البصمة
ملف يشغّل كودًا عند تحميله — فضّل الملفات التي لا تحوي إلا أرقامًا
نسيان ما ثبّتّه — احتفظ بقائمة النماذج

لكل خطر فحصه: التوقيع يُظهر من نشر الملف، والبصمة تُظهر أنه لم يتغيّر، والصيغ التي لا تحوي إلا أرقامًا لا تستطيع تشغيل كود، والقائمة تُظهر ما لديك ومتى تغيّر.