تحقّق قبل أن تثق بنموذج

المدة
٢٠ دقيقة

المواد
ورقة وقلم، هاتف العائلة مع صاحبه، أو حاسوب ناديك، هاتف أو حاسوب عليه «درسي» إن توفّر، للمختبر والكود

أهداف التعلّم

- تشرح كيف يمكن مهاجمة سلسلة توريد الذكاء الاصطناعي.
- تحسب بصمة SHA-256 وتقارنها في بايثون.
- تشرح ما يضيفه التوقيع، وتحتفظ بقائمة نماذج.

النشاط: النشاط: افحص السلسلة

١. التمهيد (٣ دقائق): فكّر في ثلاثة تطبيقات على هاتفك (أو هاتف العائلة بإذن صاحبه). واكتب من أين جاء كلٌّ منها: من المتجر الرسمي، أم من ملف أرسله أحد، أم من موقع.

٢. البصمة (٧ دقائق): في خطوة الكود في «درسي»، احسب بصمة b"leafnet v2" ثم بصمة b"leafnet v3"، وقارن بينهما. ليس لديك جهاز؟ اصنع بصمة ورقية: اجمع أرقام عدد طويل، ثم غيّر رقمًا واحدًا، ولاحظ تغيّر المجموع.

٣. القائمة (٥ دقائق): ابدأ قائمة نماذج من أربعة أعمدة: الاسم، والنسخة، والمصدر، وأول ثمانية أحرف من البصمة إن توفّرت.

٤. المشاركة (٥ دقائق): بادل قائمتك مع زميلك. أيّ بند ستحذفه أو تستبدله من المصدر الرسمي، ولماذا؟

لا تنظر في هاتف العائلة إلا مع صاحبه، ولا تثبّت أي شيء جديد في أثناء النشاط.

للنقاش

- لماذا لا تستطيع البصمة وحدها إثبات من صنع الملف؟
- لماذا النسخ «الاحترافية» المجانية المتداولة في المجموعات خطيرة إلى هذا الحد؟
- ماذا ستضع في قائمة نماذج عائلتك؟

تحقّق من نفسك

- اكتب الفحصين اللذين ستجريهما قبل تشغيل نموذج نزّلته، وما يُثبته كلٌّ منهما.

جرّبها هذا الأسبوع

مع صاحب الهاتف، انظر إلى تطبيقات الذكاء الاصطناعي على هاتف العائلة. واكتب لكل منها من أين جاء: من المتجر الرسمي، أم من ملف متداول، أم من موقع. واحذف أي ملف متداول لا تستطيع التحقّق منه، وابدأ قائمة النماذج الخاصة بك.

ورقة عمل

تحقّق قبل أن تثق بنموذج

أمن الذكاء الاصطناعي، المرحلة الثانوية، الدرس ٤

الاسم _____ الصف _____ التاريخ _____

١ تطابقت بصمة نموذج مع البصمة المنشورة بجانبه، على موقع لا تعرفه. هل تثق به؟

◯ نعم: البصمة مطابقة ◯ ليس بعد: تحقّق من المصدر الرسمي ومن التوقيع ◯ نعم، إن عمل دون أخطاء

٢ أكمل الدالة fp لتُرجع بصمة SHA-256 للبيانات في صورة ٦٤ حرفًا ست عشريًا.

```
import hashlib, binascii

def fp(data):
    h = hashlib._____(data).digest()
    return binascii._____(h).decode()
```

بنك الكلمات: `hexlify` `sha256` `digest` `md5` `lower`

٣ ماذا يطبع هذا البرنامج؟

```
import hashlib, binascii

def fp(data):
    h = hashlib.sha256(data).digest()
    return binascii.hexlify(h).decode()

a = fp(b"model")
b = fp(b"Model")
print(len(a), a == b)
```

◯ 64 False ◯ 64 True ◯ 5 False

٤ يحتفظ ناديك بقائمة نماذج: اسم كل نموذج وبصمته المنشورة. اكتب الدالة verify: أرجِع "unknown" إن لم يكن النموذج في القائمة، و"changed" إن لم تطابق بصمة الملف، و"ok" في غير ذلك.

```
import hashlib, binascii
def fp(data):
    h = hashlib.sha256(data).digest()
    return binascii.hexlify(h).decode()
LIST = {"leafnet": fp(b"leafnet v2")}
def verify(name, data):
    # "unknown", "changed" or "ok"
    return "ok"
print(verify("leafnet", b"leafnet v3"))
```

اكتب برنامجك:

٥ صِل كل خطر في سلسلة التوريد بالفحص الذي يكشفه.

نسخة مزيّفة من منتحل	احتفظ بقائمة النماذج
ملف تغيّر في الطريق	فضّل الملفات التي لا تحوي إلا أرقامًا
ملف يشغّل كودًا عند تحميله	قارن البصمة
نسيان ما ثبّتّه	تحقّق من توقيع الناشر

أيّ التطبيقات أو أدوات الذكاء الاصطناعي على هاتفك جاءت من ملف متداول أو من موقع، لا من المتجر الرسمي؟ وكيف تستطيع التحقّق منها؟