ملاحظات الدرس — لك

كيفِ يُهاجَم الذكاء الاصطناعي وكيف يُدافَع عنه: اختبار الوحدة

أمن الذكاء الاصطناعي، المرحلة الثانوية، اختبار الوحدة

المدة
٢٠ دقيقة

المواد
ورق وقلم. لا حاجة إلى جهاز.

أهداف التعلّم

- مرشّحات تُخطئ
- الأدوات اللازمة فقط
- البيانات المسمّمة
- تحقّق قبل أن تثق بنموذج

النشاط: النشاط: دافع عن بوت الفصل

١. التمهيد (٣ دقائق): تذكّر دفاعًا واحدًا من كل درس.

٢. التخطيط (٧ دقائق): صمّم دفاعات لبوت فصل خيالي.

٣. الهجوم (٥ دقائق): يجرّب زميلك أربع هجمات على الورق.

٤. المشاركة (٥ دقائق): أيّ دفاع أوقف كل هجوم؟

استخدم بوتات ورسائل وملفات خيالية فقط.

للنقاش

- أيّ دفاع في هذه الوحدة فاجأك أكثر من غيره؟
- متى يكون الفحص في الكود أفضل من قاعدة يقرؤها النموذج؟
- كيف تشرح مبدأ أقل الصلاحيات لطالب أصغر منك؟

تحقّق من نفسك

- أنفع دفاع تعلّمته في هذه الوحدة، وأين سأستخدمه.

جرّبها هذا الأسبوع

اختر من هذه الوحدة الدفاع الذي ستستخدمه أكثر من غيره (فحص الفعل، أو قائمة السماح، أو فحص الجيران، أو البصمة)، واشرحه لأحد في البيت بمثال حقيقي هذا الأسبوع.

ورقة عمل

كيفِ يُهاجَم الذكاء الاصطناعي وكيف يُدافَع عنه: اختبار الوحدة

أمن الذكاء الاصطناعي، المرحلة الثانوية، اختبار الوحدة

الاسم _____ الصف _____ التاريخ _____

١ ما حقن الأوامر؟

- ○ أوامر مخبّأة في نص يقرؤه تطبيق ذكاء اصطناعي، على أمل أن يتبعها النموذج
- ○ فيروس يستنزف بطارية الهاتف
- ○ طلب طويل جدًا يُبطئ النموذج

٢ صِل كل هجوم بالدفاع الذي يصمد أمامه.

رسالة احتيال معاد صياغتها	قارن بصمته
وكيل يحمل عشر أدوات	فحص الجيران وتسميات الأغلبية
تسميات مقلوبة في بيانات التدريب	قائمة سماح لكل مهمة
ملف نموذج تغيّر في الطريق	فحص الفعل في الكود

٣ ماذا يطبع هذا البرنامج؟

```
def can_send(text, asked, yes):
    return asked and yes

print(can_send("password", True, True))
print(can_send("Hello", False, True))
```

- ○ True ثم False
- ○ False ثم True
- ○ False ثم False

٤ لا يمكن لأداة القراءة أن تسبّب أي ضرر أبدًا.

- ○ صح
- ○ خطأ

٥ أيّ مما يلي من تسميم البيانات؟ اختر كل ما ينطبق.

- ☐ زميل يقلب تسميات في بيانات الفصل مازحًا
- ☐ تقييمات مزيّفة تُنشر لتدريب نموذج متجر
- ☐ صور تدريب فيها ملصق مزروع يغيّر الإجابة
- ☐ مطر يجعل صورة واحدة ضبابية