ملاحظات المراجعة — لك

كيفِ يُهاجَم الذكاء الاصطناعي وكيف يُدافَع عنه: اختبار الوحدة

أمن الذكاء الاصطناعي، المرحلة الثانوية، اختبار الوحدة

المدة
٢٠ دقيقة

المواد
ورق وقلم. لا حاجة إلى جهاز.

أهداف التعلّم

- مرشّحات تُخطئ
- الأدوات اللازمة فقط
- البيانات المسمّمة
- تحقّق قبل أن تثق بنموذج

النشاط: دافع عن بوت الفصل

١. التمهيد (٣ دقائق): تذكّر دفاعًا واحدًا من كل درس.
٢. التخطيط (٧ دقائق): صمّم دفاعات لبوت فصل خيالي.
٣. الهجوم (٥ دقائق): يجرّب زميلك أربع هجمات على الورق.
٤. المشاركة (٥ دقائق): أيّ دفاع أوقف كل هجوم؟

استخدم بوتات ورسائل وملفات خيالية فقط.

للنقاش

- أيّ دفاع في هذه الوحدة فاجأك أكثر من غيره؟
- متى يكون الفحص في الكود أفضل من قاعدة يقرؤها النموذج؟
- كيف تشرح مبدأ أقل الصلاحيات لطالب أصغر منك؟

تحقّق من نفسك

- أنفع دفاع تعلّمته في هذه الوحدة، وأين سأستخدمه.

جرّبها هذا الأسبوع

اختر من هذه الوحدة الدفاع الذي ستستخدمه أكثر من غيره (فحص الفعل، أو قائمة السماح، أو فحص الجيران، أو البصمة)، واشرحه لأحد في البيت بمثال حقيقي هذا الأسبوع.

ورقة الاختبار

كيفِ يُهاجَم الذكاء الاصطناعي وكيف يُدافَع عنه: اختبار الوحدة

أمن الذكاء الاصطناعي، المرحلة الثانوية، اختبار الوحدة

الاسم _____ الفصل _____ التاريخ _____

١ ما حقن الأوامر؟

○ فيروس يستنزف بطارية الهاتف ○ طلب طويل جدًا يُبطئ النموذج

○ أوامر مخبّأة في نص يقرؤه تطبيق ذكاء اصطناعي، على أمل أن يتبعها النموذج

٢ صِل كل هجوم بالدفاع الذي يصمد أمامه.

رسالة احتيال معاد صياغتها	قائمة سماح لكل مهمة
وكيل يحمل عشر أدوات	قارن بصمته
تسميات مقلوبة في بيانات التدريب	فحص الفعل في الكود
ملف نموذج تغيّر في الطريق	فحص الجيران وتسميات الأغلبية

٣ ماذا يطبع هذا البرنامج؟

```
def can_send(text, asked, yes):
    return asked and yes

print(can_send("password", True, True))
print(can_send("Hello", False, True))
```

○ False ثم True ○ False ثم False ○ True ثم False

٤ قد تؤدي أداة القراءة إلى ضرر، مع أنها لا تستطيع أن تفعل شيئًا.

○ صح ○ خطأ

٥ أيّ مما يلي من تسميم البيانات؟ اختر كل ما ينطبق.

☐ تقييمات مزيّفة تُنشر لتدريب نموذج متجر ☐ مطر يجعل صورة واحدة ضبابية

☐ صور تدريب فيها ملصق مزروع يغيّر الإجابة ☐ زميل يقلب تسميات في بيانات الفصل مازحًا

٦ يرفض فحص قائمة السماح هذا الأدوات التي تحتاجها المهمة ويسمح بغيرها. أيّ سطر فيه الخطأ؟

ضع دائرة حول السطر الذي فيه الخطأ، ثم اكتبه صحيحًا:

```
1  def check(task, tool, yes):
2      if tool in TOOLS[task]:
3          return "not allowed"
4      if tool in ACTS and not yes:
5          return "ask first"
6      return "ok"
```

---

٧ ماذا يطبع هذا البرنامج؟

```
def suspects(xs, lab):
    out = []
    for i in range(1, len(lab) - 1):
        left, me, right = lab[i-1:i+2]
        if left != me and right != me:
            out.append(xs[i])
    return out

print(suspects([1, 2, 3, 4, 5], "SSHSS"))
```

○ [2, 4] ○ [3] ○ []

٨ رتّب: استخدام نموذج نزّلته.

- ☐ احسب بصمته
- ☐ نزّله من المصدر الرسمي
- ☐ أضفه إلى قائمة نماذجك
- ☐ قارنها بالبصمة المنشورة، وتحقّق من التوقيع

٩ إن طابقت بصمة نموذج البصمة المنشورة بجانبه، فلا بد أنه من الناشر الحقيقي.

○ صح ○ خطأ

١٠ أكمل الجملة.

تُثبت البصمة أن للملف نفسَ _____ ، ويُثبت التوقيع _____ صنعه.

بنك الكلمات: الحجم، البايتات، متى، مَن

تحقّق من إجاباتك

كيفِ يُهاجَم الذكاء الاصطناعي وكيف يُدافَع عنه: اختبار الوحدة

أمن الذكاء الاصطناعي، المرحلة الثانوية، اختبار الوحدة

١ **أوامر مخبّأة في نص يقرؤه تطبيق ذكاء اصطناعي، على أمل أن يتبعها النموذج**

يخبّئ حقن الأوامر تعليمات في صفحة ويب أو مستند أو نتيجة أداة.

٢ **رسالة احتيال معاد صياغتها — فحص الفعل في الكود**
وكيل يحمل عشر أدوات — قائمة سماح لكل مهمة
تسميات مقلوبة في بيانات التدريب — فحص الجيران وتسميات الأغلبية
ملف نموذج تغيّر في الطريق — قارن بصمته

إعادة الصياغة تتغلّب على قوائم الكلمات لا على فحص الفعل، وقائمة السماح تقلّص ما يبلغه الوكيل المخدوع، وفحص الجيران والتسميات بالأغلبية تكشف التسميات المسمّمة، والبصمة تُظهر أن الملف تغيّر.

٣ **True ثم False**

يتجاهل الفحص النص: فالرسالة الأولى طُلبت ووُوفق عليها، فالنتيجة True مع أنها تقول «password».

٤ **صح**

لا تستطيع أداة القراءة أن تفعل شيئًا، لكن الحيلة قد تجعل الوكيل يسرّب ما قرأته الأداة أو يكرّره.

٥ **زميل يقلب تسميات في بيانات الفصل مازحًا، تقييمات مزيّفة تُنشر لتدريب نموذج متجر، صور تدريب فيها ملصق مزروع يغيّر الإجابة**

التسميات المقلوبة، والتقييمات المزيّفة، والعلامة المزروعة (الباب الخلفي)، كلها تُدخل أمثلة خاطئة في بيانات التدريب عمدًا.

٦ **السطر 2:** `if tool not in TOOLS[task]:`

يجب رفض الأداة حين لا تكون في قائمة المهمة.

٧ **[3]**

وحدها H التي في الوسط على جانبيها S، فلا تُعلَّم إلا قيمتها 3.

٨ **من الأعلى إلى الأسفل: ٢، ١، ٤، ٣**

ابدأ من المصدر الرسمي، ثم احسب البصمة، وقارنها وتحقّق من التوقيع قبل أن تشغّل أي شيء، ثم سجّله لتنتبه إن تغيّر يومًا.

٩ **خطأ**

مَن نشر الملف قد ينشر بصمته أيضًا. فالبصمة تُثبت فقط أن البايتات لم تتغيّر، أما التوقيع أو المصدر الرسمي فيُظهر من صنعه.

١٠ **تُثبت البصمة أن للملف نفسَ البايتات، ويُثبت التوقيع مَن صنعه.**

أي تغيير في الملف يغيّر بصمته، فالتطابق يعني البايتات نفسها.