كيف يُهاجَم الذكاء الاصطناعي وكيف يُدافَع عنه: مراجعة

أمن الذكاء الاصطناعي، المرحلة الثانوية، اختبار الوحدة

في هذه الوحدة

- مرشّحات تُخطئ
- الأدوات اللازمة فقط
- البيانات المسمّمة
- تحقّق قبل أن تثق بنموذج

الأفكار الكبرى

- افحص الفعل في الكود، لا الكلمات
- أقل الأدوات: قائمة سماح وموافقة إنسان
- البيانات المسمّمة: الكود يُشير، والإنسان يقرّر
- طابق بصمة البايتات، وتحقّق من التوقيع

النشاط: دافع عن بوت الصف

استخدم بوتات ورسائل وملفات خيالية فقط.

١. التمهيد (٣ دقائق): تذكّر دفاعًا واحدًا من كل درس.

٢. التخطيط (٧ دقائق): صمّم دفاعات لبوت صفّ خيالي.

٣. الهجوم (٥ دقائق): يجرّب زميلك أربع هجمات على الورق.

٤. المشاركة (٥ دقائق): أيّ دفاع أوقف كل هجوم؟

لنتناقش

١. أيّ دفاع في هذه الوحدة فاجأك أكثر من غيره؟

٢. متى يكون الفحص في الكود أفضل من قاعدة يقرؤها النموذج؟

٣. كيف تشرح مبدأ أقل الصلاحيات لطالب أصغر منك؟

تحقّق من نفسك

- أنفع دفاع تعلّمته في هذه الوحدة، وأين سأستخدمه.