ملاحظات الدرس — لك

نمذجة التهديدات لتطبيق ذكاء اصطناعي

أمن الذكاء الاصطناعي، الجامعة، الدرس ١

المدة
٢٠ دقيقة

المواد
ورق وأقلام، أو سبّورة بيضاء، تطبيق ذكاء اصطناعي تستخدمه أو تبنيه (تنظر إليه بصفتك مستخدمًا فقط)، أسئلة STRIDE الستة (في الشرائح)

أهداف التعلّم

- ترسم مسارات بيانات تطبيق ذكاء اصطناعي وحدود الثقة فيه.
- تجد التهديدات عند كل حدّ بأسئلة STRIDE، وترتّبها.
- تقلّص نطاق الضرر بالتصميم.

النشاط: نموذج تهديدات في عشرين دقيقة

١. الرسم (٦ دقائق): على صفحة واحدة، ارسم كل أجزاء التطبيق الذي اخترته (المستخدم، والتطبيق، والنموذج، وأدواته، ومستنداته، والمحتوى الخارجي الذي يقرؤه)، وسهمًا لكل مسار بيانات بينها.

٢. الحدود (٤ دقائق): ضع دائرة حول كل موضع تدخل منه بيانات لا تتحكّم فيها: الرسائل، والملفات المرفوعة، وصفحات الويب، ونتائج الأدوات. وتذكّر أن النموذج ليس حدًّا: فكل ما في سياقه قد يوجّهه.

٣. STRIDE (٦ دقائق): لكل حرف، اكتب تهديدًا واقعيًا واحدًا عند حدودك، وأعطه درجة الاحتمال × الأثر، من ١ إلى ٣ لكلٍّ منهما. وعلّم كل مسار من نص غير موثوق إلى جزء يتصرّف.

٤. الإصلاح (٤ دقائق): اختر تغيير التصميم الوحيد الذي يقلّص نطاق الضرر أكثر من غيره (إزالة أداة، أو القراءة فقط، أو الموافقة في الكود)، وقل كيف ستختبره.

استخدم تطبيقًا تبنيه، أو تصميمًا من خيالك. ولا تفحص نظامًا حيًّا لغيرك أبدًا.

للنقاش

- لماذا لا يُعدّ النموذج حدّ ثقة؟
- أيّ حرف من STRIDE كان إيجاد تهديد له الأصعب؟
- ما الذي يستطيع تطبيقك فعله ولا تحتاج إليه مهمته؟

تحقّق من نفسك

- سمِّ مسارًا واحدًا من نص غير موثوق إلى فعل في تطبيقك، والتغيير الذي يقطعه.

جرّبها هذا الأسبوع

مع زميلين، ارسموا مسارات البيانات لتطبيق ذكاء اصطناعي تستخدمونه في دراستكم، وضعوا دائرة حول كل حدّ ثقة، واطرحوا أسئلة STRIDE الستة، واتفقوا على التغيير الوحيد الذي يقلّص نطاق ضرره أكثر من غيره.

ورقة عمل

نمذجة التهديدات لتطبيق ذكاء اصطناعي

أمن الذكاء الاصطناعي، الجامعة، الدرس ١

الاسم _____ الصف _____ التاريخ _____

١ **لا يحتاج مساعد المقرر إلا إلى الإجابة عن الأسئلة من الملازم. أيّ تغيير يقلّص نطاق الضرر أكثر من غيره؟**

◯ تحذير في تعليمات النظام ◯ إزالة أداة البريد الإلكتروني ◯ نموذج أكبر وأذكى

٢ **صِل كل تهديد من STRIDE بما قد يبدو عليه في مساعد المقرر.**

الانتحال	• • • •	صفحة ويب تجعله يرسل بريدًا	
العبث	• • • •	يكشف درجات طالب آخر	
كشف المعلومات	• • • •	شخص يعدّل الملازم التي يقرؤها	
رفع الصلاحيات	• • • •	رسالة تدّعي أنها من المحاضر	

٣ **يسرد نموذج التهديدات لمساعد المقرر مساراته. أكمل at_risk(flows, untrusted, acts): تتبّع المسارات خطوة خطوة من الأجزاء غير الموثوقة، وأعِد الأجزاء الفاعلة التي تبلغها مرتّبة. والبداية لا تنظر إلا إلى خطوة واحدة، فيفوتها المسار من web إلى model ثم إلى email.**

```
FLOWS = [("model", "email"), ("web", "model"),
         ("student", "model"), ("model", "search")]

def at_risk(flows, untrusted, acts):
    reach = set(untrusted)
    for a, b in flows:
        if a in untrusted:
            reach.add(b)
    return sorted(c for c in acts if c in reach)

for c in at_risk(FLOWS, {"web"}, {"email"}):
    print("at risk:", c)
```

اكتب برنامجك:

٤ يشغّل مساعد المقرر استدعاءات أدواته بهذا الكود. أيّ تهديد من STRIDE يتركه مفتوحًا أكثر من غيره؟

```
def run_tool(call):
    if call["tool"] == "email":
        send(call["to"], call["body"])
    return "done"
```

○ الإنكار: لا شيء يسجّل من أرسل ماذا ○ تعطيل الخدمة: الكود بطيء جدًا ○ الانتحال: إنه يتحقّق من كلمة مرور

٥ رتّب خطوات نمذجة التهديدات.

☐ أعطِ أعلاها ضابطًا واختبارًا

☐ رتّب التهديدات بحسب الاحتمال × الأثر

☐ اطرح أسئلة STRIDE عند كلٍّ منها

☐ حدّد حدود الثقة

☐ ارسم مسارات البيانات

✎ فكّر في تطبيق ذكاء اصطناعي تستخدمه في دراستك. من أين يدخله نص غير موثوق، وما أسوأ ما قد يُدفع إلى فعله؟