نمذجة التهديدات لتطبيق ذكاء اصطناعي

أمن الذكاء الاصطناعي، الجامعة، الدرس ١

في هذا الدرس سوف

- ترسم مسارات بيانات تطبيق ذكاء اصطناعي وحدود الثقة فيه.
- تجد التهديدات عند كل حدّ بأسئلة STRIDE، وترتّبها.
- تقلّص نطاق الضرر بالتصميم.

تذكّر

- النموذج ليس حدّ ثقة: سياقه يوجّه أدواته.
- STRIDE: الانتحال، والعبث، والإنكار، وكشف المعلومات، وتعطيل الخدمة، ورفع الصلاحيات.
- إصلاح التصميم أقوى من إصلاح التعليمات: أزِل الأدوات، واجعلها للقراءة فقط، واشترط الموافقة في الكود.

نموذج تهديدات في عشرين دقيقة

١. الرسم (٦ دقائق): كل أجزاء التطبيق وكل مسارات البيانات.

٢. الحدود (٤ دقائق): ضع دائرة حيث تدخل البيانات الخارجية.

٣. STRIDE (٦ دقائق): تهديد واحد لكل حرف، بدرجة الاحتمال × الأثر.

٤. الإصلاح (٤ دقائق): التغيير الوحيد الذي يقلّص نطاق الضرر أكثر.

استخدم تطبيقًا تبنيه، أو تصميمًا من خيالك. ولا تفحص نظامًا حيًّا لغيرك أبدًا.

لنتناقش

١. لماذا لا يُعدّ النموذج حدّ ثقة؟

٢. أيّ حرف من STRIDE كان إيجاد تهديد له الأصعب؟

٣. ما الذي يستطيع تطبيقك فعله ولا تحتاج إليه مهمته؟

تحقّق من نفسك

- سمِّ مسارًا واحدًا من نص غير موثوق إلى فعل في تطبيقك، والتغيير الذي يقطعه.