قائمة OWASP لأخطر عشرة مخاطر في تطبيقات النماذج اللغوية

أمن الذكاء الاصطناعي، الجامعة، الدرس ٢

في هذا الدرس سوف

- تسمّي مخاطر OWASP العشرة لتطبيقات النماذج اللغوية، مع مثال لكلٍّ منها.
- تعامل مخرجات النموذج بوصفها غير موثوقة: ترمّزها قبل استخدامها.
- تُبقي الأسرار وقواعد الوصول خارج التعليمات.

تذكّر

- ما يدخل: الحقن، والتسميم، والتضمينات. وما يخرج: الكشف، وتسريب التعليمات، والتعامل مع المخرجات، والمعلومات المضلّلة. والنظام: سلسلة التوريد، والصلاحيات، والاستهلاك.
- مخرجات النموذج مدخلات غير موثوقة.
- افترض أن تعليمات النظام ستُقرأ.

مراجعة المخاطر العشرة

١. الفرز (٥ دقائق): عشر بطاقات للمخاطر في ما يدخل وما يخرج والنظام.

٢. المراجعة (٨ دقائق): هل يمكن أن يقع كلٌّ منها في تطبيقك؟

٣. الإصلاح (٥ دقائق): إجراء وقائي لأعلى ثلاثة مخاطر.

٤. الاختبار (دقيقتان): كيف تُثبت أن إجراءً وقائيًا واحدًا يعمل؟

راجع تطبيقك أنت أو تصميمًا من خيالك. ولا تختبر تطبيقًا حيًّا دون إذن مكتوب أبدًا.

لنتناقش

١. لماذا يُعدّ ردّ النموذج غير موثوق، مع أن تطبيقك هو من طلبه؟

٢. أيّ خطر أسهل إصلاحًا بالتصميم؟

٣. لماذا لا تحمي عبارة «لا تكشف هذا أبدًا» السرّ؟

تحقّق من نفسك

- اكتب خطرًا واحدًا من العشرة ينطبق على تطبيق تستخدمه، وإجراءه الوقائي.