مهاجمة النماذج وتحصينها

المدة
٢٠ دقيقة

المواد
ورق وقلم للجدول، نموذج بنيته، أو تطبيق المختبر، هاتف أو حاسوب لخطوات الكود، إن توفّر

أهداف التعلّم

- تشرح الخداع والاستخراج واستدلال العضوية.
- تحسب أسوأ دفع صغير لنموذج خطي.
- تختار الدفاعات وتقيس ثمنها.

النشاط: ادفع الدرجة بيدك

١. التمهيد (٣ دقائق): اسأل: نموذج متأكد بنسبة ٩٩٪، فهل يقلبه تغيير صغير جدًا؟ اجمع التخمينات وأسبابها.

٢. الدرجة (٦ دقائق): احسب الدرجة بيدك: ٢ × ١، ثم سالب ١ × ١، ثم ١ × ١، ثم اطرح ١، فتكون الدرجة ١. وهي موجبة، فالإجابة «نعم».

٣. الدفع (٦ دقائق): حرّك كل مُدخل ٠٫٥ عكس إشارة وزنه: تصبح المدخلات ٠٫٥ و١٫٥ و٠٫٥، وتصبح الدرجة سالب ١: فتنقلب الإجابة.

٤. الشهادة (٥ دقائق): الهبوط يساوي ٤ مضروبة في (٢ + ١ + ١)، أي ٤٤. وتبقى الإجابة آمنة ما دام ٤٤ أقل من ١، أي لكل ٤ أصغر من ٠٫٢٥. وقارن ذلك بالدالة robust() في خطوة الكود.

اعمل على الورق: الأرقام صغيرة عمدًا.

للنقاش

- لماذا لا تعني الإجابة الواثقة إجابة متينة؟
- أيّ دفاع ستدفع ثمنه، وكم سيكلّف؟
- لماذا تساعد الدرجات الدقيقة المهاجم؟

تحقّق من نفسك

- الوزنان ٣ وسالب ٢، والمدخلان ١ و١، والانحياز صفر، و٤ تساوي ٠٫٥: اكتب أسوأ دفع والدرجة الجديدة.

جرّبها هذا الأسبوع

اختبر نموذجًا بسيطًا بنيته، أو نموذج المختبر، مرتين: على مدخلات سليمة وعلى مدخلات مدفوعة قليلًا. اكتب الدقتين، ثم أضف دفاعًا واحدًا وقِس ثمنه.

ورقة عمل

مهاجمة النماذج وتحصينها

أمن الذكاء الاصطناعي، الجامعة، الدرس ٣

الاسم _____ الصف _____ التاريخ _____

١ تُرجع الواجهة البرمجية لنموذجك درجات الثقة الدقيقة لأي أحد، دون حدود. أيّ الهجمات يسهّل ذلك أكثر من غيرها؟

◯ الاستخراج واستدلال العضوية ◯ تسميم بيانات تدريبه ◯ نسخة مزيّفة في سلسلة التوريد

٢ تمثّل score(w, b, x) نموذجًا خطيًا. أكمل nudge(w, x, eps) ليتحرّك كل مُدخل بمقدار eps عكس إشارة وزنه: التغيير الصغير الذي يخفض الدرجة أكثر من غيره. والبداية تتحرّك في الاتجاه الخطأ.

```
def score(w, b, x):
    return sum(a * c for a, c in zip(w, x)) + b

def nudge(w, x, eps):
    sign = lambda a: (a > 0) - (a < 0)
    return [c + eps * sign(a)
            for a, c in zip(w, x)]

w, b, x = [2, -1, 1], -1, [1, 1, 1]
print(score(w, b, x))
print(score(w, b, nudge(w, x, 0.5)))
```

اكتب برنامجك:

٣ أكمل robust(): لا يستطيع أي دفع بحجم eps أن يقلب الإجابة حين تكون الدرجة أبعد عن الصفر من أكبر هبوط ممكن.

```
def robust(w, b, x, eps):
    drop = eps * _____ (abs(a) for a in w)
    return abs(score(w, b, x)) _____ drop
```

بنك الكلمات: `>` `sum` `max` `<`

٤ صِل كل هجوم على نموذج بدفاع يستهدف ما يحتاج إليه.

الخداع بالأمثلة الخادعة	• • • •	ضوضاء الخصوصية أثناء التدريب
الاستخراج بالاستعلام الكثيف	• • • •	حدود للطلبات وإرجاع التصنيف فقط
استدلال العضوية	• • • •	التدريب على الأمثلة الخادعة، وإنسان يراجع

٥ **التدريب على الأمثلة الخادعة يجعل خداع النموذج مستحيلًا.**

○ صح ○ خطأ

✎ **فكّر في نموذج تهمّ إجابته أناسًا تعرفهم: مصحّح امتحانات، أو تطبيق قروض، أو تطبيق محاصيل. أيّ الهجمات الثلاثة يقلقك أكثر فيه، وأيّ دفاع ستدفع ثمنه؟**