مهاجمة النماذج وتحصينها

المدة
٢٠ دقيقة

المواد
ورق وقلم للجدول، نموذج بنيته، أو تطبيق المختبر، هاتف أو حاسوب لخطوات الكود، إن توفّر

أهداف التعلّم

- تشرح الخداع والاستخراج واستدلال العضوية.
- تحسب أسوأ دفع صغير لنموذج خطي.
- تختار الدفاعات وتقيس ثمنها.

النشاط: ادفع الدرجة بيدك

١. التمهيد (٣ دقائق): اسأل: نموذج متأكد بنسبة ٩٩٪، فهل يقلبه تغيير صغير جدًا؟ اجمع التخمينات وأسبابها.

٢. الدرجة (٦ دقائق): احسب الدرجة بيدك: ٢ × ١، ثم سالب ١ × ١، ثم ١ × ١، ثم اطرح ١، فتكون الدرجة ١. وهي موجبة، فالإجابة «نعم».

٣. الدفع (٦ دقائق): حرّك كل مُدخل ٠٫٥ عكس إشارة وزنه: تصبح المدخلات ٠٫٥ و١٫٥ و٠٫٥، وتصبح الدرجة سالب ١: فتنقلب الإجابة.

٤. الشهادة (٥ دقائق): الهبوط يساوي إبسلون مضروبًا في (٢ + ١ + ١)، أي ٤ × إبسلون. وتبقى الإجابة آمنة ما دام ٤ × إبسلون أقل من ١، أي لكل إبسلون أصغر من ٠٫٢٥. وقارن ذلك بالدالة robust() في خطوة الكود.

اعمل على الورق: الأرقام صغيرة عمدًا.

للنقاش

- لماذا لا تعني الإجابة الواثقة إجابة متينة؟
- أيّ دفاع ستدفع ثمنه، وكم سيكلّف؟
- لماذا تساعد الدرجات الدقيقة المهاجم؟

تحقّق من نفسك

- الوزنان ٣ وسالب ٢، والمدخلان ١ و١، والانحياز صفر، وإبسلون يساوي ٠٫٥: اكتب أسوأ دفع والدرجة الجديدة.

جرّبها هذا الأسبوع

اختبر نموذجًا بسيطًا بنيته، أو نموذج المختبر، مرتين: على مدخلات سليمة وعلى مدخلات مدفوعة قليلًا. اكتب الدقتين، ثم أضف دفاعًا واحدًا وقِس ثمنه.

ورقة عمل

مهاجمة النماذج وتحصينها

الاسم _____ الفصل _____ التاريخ _____

١ **تُرجع الواجهة البرمجية لنموذجك درجات الثقة الدقيقة لأي أحد، دون حدود. أيّ الهجمات يسهّل ذلك أكثر من غيرها؟**

○ الاستخراج واستدلال العضوية ○ تسميم بيانات تدريبه ○ نسخة مزيّفة في سلسلة التوريد

٢ **تمثّل score(w, b, x) نموذجًا خطيًا. أكمل nudge(w, x, eps) ليتحرّك كل مُدخل بمقدار eps عكس إشارة وزنه: التغيير الصغير الذي يخفض الدرجة أكثر من غيره. والبداية تتحرّك في الاتجاه الخطأ.**

```
def score(w, b, x):
    s = sum(a * c for a, c in zip(w, x))
    return s + b

def nudge(w, x, eps):
    sign = lambda a: (a > 0) - (a < 0)
    return [c + eps * sign(a)
            for a, c in zip(w, x)]

w, b, x = [2, -1, 1], -1, [1, 1, 1]
print(score(w, b, x))
print(score(w, b, nudge(w, x, 0.5)))
```

اكتب برنامجك:

٣ **أكمل robust(): لا يستطيع أي دفع بحجم eps أن يقلب الإجابة حين تكون الدرجة أبعد عن الصفر من أكبر هبوط ممكن.**

```
def robust(w, b, x, eps):
    drop = eps * _____(abs(a) for a in w)
    return abs(score(w, b, x)) _____ drop
```

بنك الكلمات: `>` `sum` `<` `max`

٤ **صِل كل هجوم على نموذج بدفاع يستهدف ما يحتاج إليه.**

الخداع بالأمثلة الخادعة	• • • •	ضوضاء الخصوصية أثناء التدريب
الاستخراج بالاستعلام الكثيف	• • • •	التدريب على الأمثلة الخادعة، وإنسان يراجع
استدلال العضوية	• • • •	حدود للطلبات وإرجاع التسمية فقط

٥ **التدريب على الأمثلة الخادعة يجعل خداع النموذج أصعب، لكن بعض الهجمات ما زال يمرّ.**

○ صح ○ خطأ

✎ **فكّر في نموذج تهمّ إجابته أناسًا تعرفهم: مصحّح امتحانات، أو تطبيق قروض، أو تطبيق محاصيل. أيّ الهجمات الثلاثة يقلقك أكثر فيه، وأيّ دفاع ستدفع ثمنه؟**

تحقّق من إجاباتك

مهاجمة النماذج وتحصينها

أمن الذكاء الاصطناعي، الجامعة، الدرس ٣

١ الاستخراج واستدلال العضوية

يَنسخ الاستخراج النموذج من إجابات كثيرة، ويقرأ استدلال العضوية مدى ثقته في سجلّ ما.

٢

```
def score(w, b, x):
    s = sum(a * c for a, c in zip(w, x))
    return s + b

def nudge(w, x, eps):
    sign = lambda a: (a > 0) - (a < 0)
    return [c - eps * sign(a)
            for a, c in zip(w, x)]

w, b, x = [2, -1, 1], -1, [1, 1, 1]
print(score(w, b, x))
print(score(w, b, nudge(w, x, 0.5)))
```

تحريك كل مُدخل عكس إشارة وزنه يخفض كل حدّ من حدود الدرجة معًا بمقدار eps × |w|، فتهبط الدرجة بمقدار eps × sum(|w|): من 1 إلى سالب 1 هنا، فتنقلب الإجابة.

٣

```
def robust(w, b, x, eps):
    drop = eps * sum(abs(a) for a in w)
    return abs(score(w, b, x)) > drop
```

أكبر هبوط يسبّبه دفع بحجم eps هو eps × sum(|w|).

٤ الخداع بالأمثلة الخادعة — التدريب على الأمثلة الخادعة، وإنسان يراجع
الاستخراج بالاستعلام الكثيف — حدود للطلبات وإرجاع التسمية فقط
استدلال العضوية — ضوضاء الخصوصية أثناء التدريب

كل دفاع يستهدف ما يحتاج إليه هجومه: مدخلات مخادعة، أو إجابات كثيرة بدرجات دقيقة، أو نموذج يتذكّر سجلّات أفراد بعينهم.

٥ صح

إنه يرفع مستوى الصعوبة: ففي المختبر، عند عشرة بكسلات و«قوة الدفع» على ١، تهبط الهجمات التي تخدع النموذج من نحو ٨٢٪ إلى نحو ١٤٪.