مهاجمة النماذج وتحصينها

أمن الذكاء الاصطناعي، الجامعة، الدرس ٣

في هذا الدرس سوف

- تشرح الخداع والاستخراج واستدلال العضوية.
- تحسب أسوأ دفع صغير لنموذج خطي.
- تختار الدفاعات وتقيس ثمنها.

تذكّر

- الثقة ليست متانة.
- في الدرجة الخطية، يحرّك أسوأ دفع كل مُدخل بمقدار إبسلون عكس وزنه، فتهبط الدرجة بمقدار إبسلون × مجموع |w|.
- لكل دفاع ثمن من الدقة أو الفائدة أو الراحة: قِسه.

ادفع الدرجة بيدك

اعمل على الورق:

الأرقام صغيرة عمدًا.

١. التمهيد (٣ دقائق): هل الثقة بنسبة ٩٩٪ تعني الأمان؟

٢. الدرجة (٦ دقائق): الأوزان ٢ وسالب ١ و١، والانحياز سالب ١، والمدخلات كلها ١.

٣. الدفع (٦ دقائق): حرّك كل مُدخل ٠٫٥ عكس وزنه، واحسب الدرجة من جديد.

٤. الشهادة (٥ دقائق): كم يجب أن يصغر إبسلون حتى لا تنقلب الإجابة؟

لنتناقش

١. لماذا لا تعني الإجابة الواثقة إجابة متينة؟

٢. أيّ دفاع ستدفع ثمنه، وكم سيكلّف؟

٣. لماذا تساعد الدرجات الدقيقة المهاجم؟

تحقّق من نفسك

- الوزنان ٣ وسالب ٢، والمدخلان ١ و١، والانحياز صفر، وإبسلون يساوي ٠٫٥: اكتب أسوأ دفع والدرجة الجديدة.