مهاجمة النماذج وتحصينها

أمن الذكاء الاصطناعي، الجامعة، الدرس ٣

في هذا الدرس سوف

- تشرح الخداع والاستخراج واستدلال العضوية.
- تحسب أسوأ دفع صغير لنموذج خطي.
- تختار الدفاعات وتقيس ثمنها.

تذكّر

- الثقة ليست متانة.
- في الدرجة الخطية، يحرّك أسوأ دفع كل مُدخل بمقدار ε عكس وزنه، فتهبط الدرجة بمقدار ε × مجموع |w|.
- لكل دفاع ثمن من الدقة أو الفائدة أو الراحة: قِسه.

ادفع الدرجة بيدك

اعمل على الورق:

الأرقام صغيرة عمدًا.

١. التمهيد (٣ دقائق): هل الثقة بنسبة ٩٩٪ تعني الأمان؟

٢. الدرجة (٦ دقائق): الأوزان ٢ وسالب ١ و١، والانحياز سالب ١، والمدخلات كلها ١.

٣. الدفع (٦ دقائق): حرّك كل مُدخل ٠٫٥ عكس وزنه، واحسب الدرجة من جديد.

٤. الشهادة (٥ دقائق): كم يجب أن تصغر ε حتى لا تنقلب الإجابة؟

لنتناقش

١. لماذا لا تعني الإجابة الواثقة إجابة متينة؟

٢. أيّ دفاع ستدفع ثمنه، وكم سيكلّف؟

٣. لماذا تساعد الدرجات الدقيقة المهاجم؟

تحقّق من نفسك

- الوزنان ٣ وسالب ٢، والمدخلان ١ و١، والانحياز صفر، وع تساوي ٠٫٥: اكتب أسوأ دفع والدرجة الجديدة.