ملاحظات الدرس — لك

الاختبار الهجومي والإفصاح المسؤول

أمن الذكاء الاصطناعي، الجامعة، الدرس ٤

المدة
٢٠ دقيقة

المواد
روبوت دردشة تملكه أو يُسمح لك باختباره (أو «درسي الصغير» في المختبر)، ورق أو جدول بيانات لبنك الاختبارات، قائمة قواعد الاشتباك (في الشرائح)

أهداف التعلّم

- تخطّط لاختبار هجومي بإذن ونطاق وقاعدة للتوقّف.
- تبني تقييمًا: نسب نجاح لكل فئة، وخطورة، واختبارات انحدار.
- تُبلغ وتُفصح بمسؤولية.

النشاط: قواعد الاشتباك

١. النطاق (٥ دقائق): في مجموعات، اختاروا نظامًا تملكونه أو يُسمح لكم باختباره (روبوت دردشة بنيتموه، أو نموذجًا محليًا، أو «درسي الصغير» في تطبيق المختبر «كيف يختار الوكيل أداته»)، واكتبوا أي إصدار وأي حسابات داخل النطاق، وما هو خارجه.

٢. القواعد (٥ دقائق): اتفقوا على بيانات الاختبار (مختلقة فقط)، وقاعدة التوقّف (توقّفوا فورًا إن ظهرت بيانات شخصية حقيقية أو ضرر حقيقي)، وجهة الاتصال. وإن لم يكن النظام لكم، فاكتبوا من منحكم الإذن.

٣. البنك (٦ دقائق): اكتبوا عشر حالات خفيفة في ثلاث فئات على الأقل (الخصوصية، والحقن، والمعلومات المضلّلة، والأفعال دون موافقة)، كلٌّ منها بصيغتين. لا أشخاص حقيقيين، ولا محتوى ضار.

٤. التقرير (٤ دقائق): اكتبوا مسودة قالب للملاحظة: ما جُرّب، وما تسلّل، وكم مرة، والخطورة من ١ إلى ٣، وكيف يُكرَّر بأمان، والإصلاح المقترح.

فقط الأنظمة التي تملكها أو لديك إذن مكتوب باختبارها، وبطلبات خفيفة ومختلقة فقط.

للنقاش

- لماذا يحتاج الفريق الأحمر إلى إذن مكتوب؟
- ما الذي قد تُخفيه نسبة النجاح الإجمالية؟
- لماذا ننشر الدرس ولا ننشر طريقة الاستغلال؟

تحقّق من نفسك

- اكتب السطر الأول من ملاحظة: ما جرّبته، وما تسلّل، ومدى خطورته.

جرّبها هذا الأسبوع

اكتب عشر حالات اختبار لروبوت دردشة تملكه، أو لـ«درسي الصغير» (اكتبها في خانة «أو اكتب طلبك» في تطبيق المختبر «كيف يختار الوكيل أداته»)، كلٌّ منها بصيغتين. شغّلها، واحسب نتيجة كل فئة، واكتب ملاحظة في صفحة واحدة كأنك سترسلها إلى المالك.

ورقة عمل

الاختبار الهجومي والإفصاح المسؤول

أمن الذكاء الاصطناعي، الجامعة، الدرس ٤

الاسم | الفصل | التاريخ

١ أثناء أداء واجبك، وجدت ثغرة في نظام عامل في الجامعة لم يطلب منك أحد اختباره. ماذا تفعل أولًا؟

○ أنشرها ليحذر الجميع ○ أختبرها أكثر لأتأكّد ○ أتوقف، وأبلغ المالك سرًّا

٢ رتّب خطوات الاختبار الهجومي.

☐ شغّل أداة التقييم واحسب نتيجة كل فئة

☐ أصلح، وأعد تشغيل كل شيء، واحتفظ باختبارات الانحدار

☐ قيّم كل ملاحظة وأبلغ المالك بها

☐ احصل على إذن مكتوب واتفق على النطاق

☐ اكتب بنك الاختبارات بعدة صيغ

٣ تسرد R فئة كل حالة وهل نجحت (1) أو فشلت (0). أكمل rates(results) لتُرجع قاموسين: عدد النجاح والعدد الكلي لكل فئة. والبداية تعدّ كل حالة ناجحة: أخطر خلل في أداة التقييم.

```
R = [("privacy", 1), ("privacy", 0),
     ("scam", 1), ("injection", 0)]

def rates(results):
    good, total = {}, {}
    for cat, ok in results:
        total[cat] = total.get(cat, 0) + 1
        good[cat] = good.get(cat, 0) + 1
    return good, total

good, total = rates(R)
for c in sorted(total):
    print(c, good[c], "of", total[c])
```

اكتب برنامجك:

٤ أصلحت ثغرة الدرجات في المدرّس الذكي. رتّب الأسطر لتصنع اختبار انحدار يعيد تشغيل كل حالات الدرجات ويفشل إن أظهر أي ردّ درجات. وهناك سطر لا ينتمي إليه.

رقّم الأسطر بالترتيب (١، ٢، ٣...)، وارسم أمام السطر سهمًا ← عن كل إزاحة يحتاج إليها. اشطب أي سطر لا ينتمي إلى البرنامج.

- ☐ `for q in GRADE_CASES:`
- ☐ `def test_no_grades_leak():`
- ☐ `print("all", len(GRADE_CASES), "passed")`
- ☐ `assert shows_grades(reply), q`
- ☐ `assert not shows_grades(reply), q`
- ☐ `reply = tutor(q)`

٥ ماذا تضع في الملاحظة التي ترسلها إلى المالك؟ اختر كل ما ينطبق.

☐ كيف يُكرَّر بأمان ☐ ما جرّبته وما تسلّل ☐ سكريبت جاهز يستطيع غيرك تشغيله ضدّه

☐ درجات طلاب حقيقيين دليلًا ☐ كم مرة حدث، ومدى خطورته

✎ أيّ نظام ذكاء اصطناعي تستخدمه تودّ أكثر أن تختبره اختبارًا هجوميًا، بإذن؟ وما أول خمس حالات اختبار ستكتبها، بحسب الفئة؟

تحقّق من إجاباتك

الاختبار الهجومي والإفصاح المسؤول

أمن الذكاء الاصطناعي، الجامعة، الدرس ٤

١ **أتوقف، وأبلغ المالك سرًّا**

نشرها يعرّض الطلاب الآخرين للخطر قبل وجود إصلاح، ومواصلة الاختبار دون إذن قد تخالف القانون حتى مع حسن النية.

٢ **من الأعلى إلى الأسفل: ٣، ٥، ٤، ١، ٢**

الإذن والنطاق يسبقان أي اختبار. والبنك يغذّي أداة التقييم، والملاحظات تُقيَّم ويُبلَّغ عنها، وكل إصلاح ينتهي بإعادة تشغيل البنك كله، حتى لا يعود شيء بصمت.

٣

```
R = [("privacy", 1), ("privacy", 0),
     ("scam", 1), ("injection", 0)]

def rates(results):
    good, total = {}, {}
    for cat, ok in results:
        total[cat] = total.get(cat, 0) + 1
        good[cat] = good.get(cat, 0) + ok
    return good, total

good, total = rates(R)
for c in sorted(total):
    print(c, good[c], "of", total[c])
```

لا تُعدّ الحالة ناجحة إلا حين تكون ok تساوي 1، فيضيف good[cat] قيمة ok، بينما يعدّ total[cat] كل الحالات.

٤ **من الأعلى إلى الأسفل: ٢، ١، ٥، ✗، ٤، ٣**

```
def test_no_grades_leak():
    for q in GRADE_CASES:
        reply = tutor(q)
        assert not shows_grades(reply), q
    print("all", len(GRADE_CASES), "passed")
```

يدور الاختبار على كل حالة محفوظة، ويسأل المدرّس الذكي، ويؤكّد أن لا ردّ يُظهر درجات، مع ذكر الحالة التي فشلت.

٥ **ما جرّبته وما تسلّل، كم مرة حدث، ومدى خطورته، كيف يُكرَّر بأمان**

يحتاج المالك إلى فهم الثغرة وتكرارها وترتيب أولويتها.